

Beantwortung von SPARQL-Abfragen mit der Regel-Engine Nemo

Martin Voigt

Geboren am: 20.08.1997 in Radebeul Studiengang: Diplom Informatik Matrikelnummer: 4607543 Immatrikulationsjahr: 2016

Diplomarbeit

zur Erlangung des akademischen Grades

Diplom-Informatiker (Dipl.-Inf.)

Gutachter

Prof. Dr. Markus Krötzsch

Betreuer

Dipl.-Math. Maximilian Marx

Eingereicht am: 23. Januar 2025

Zusammenfassung

Nemo ist eine Datalog-Engine, welche spezielle Unterstützung für RDF-Daten bietet. Dies wirft die Frage auf, inwieweit sich SPARQL-Queries mit dieser Engine umsetzen lassen.

Dazu werden in dieser Arbeit die einzelnen Features der SPARQL-Query-Sprache betrachtet und vorgestellt, wie SPARQL-Queries zu Nemo-Programmen übersetzt werden können. Die Implementierung der Übersetzung ist mittels einer dafür entwickelten Nemo Template Language erfolgt. In einer Evaluation wird gezeigt, dass die Übersetzung von vielen Queries konform nach dem SPARQL 1.1 Standard ist und bis RDF Graphen von über 3 Milliarden Tripel skaliert.

Selbstständigkeitserklärung Hiermit versichere ich, dass ich das vorliegende Dokument mit dem Titel Beantwortung von SPARQL-Abfragen mit der Regel-Engine Nemo selbstständig und ohne unzulässige Hilfe Dritter verfasst habe. Es wurden keine anderen als die in diesem Dokument angegebenen Hilfsmittel und Quellen benutzt. Die wörtlichen und sinngemäß übernommenen Zitate habe ich als solche kenntlich gemacht. Es waren keine weiteren Personen an der geistigen Herstellung des vorliegenden Dokumentes beteiligt. Mir ist bekannt, dass die Nichteinhaltung dieser Erklärung zum nachträglichen Entzug des Hochschulabschlusses führen kann. Dresden, 23. Januar 2025

Martin Voigt

Inhaltsverzeichnis

1	nleitung	9
	1 Zielstellung 2 Umgang mit dieser Arbeit 3 RDF 4 SPARQL 5 Datalog 1.5.1 Datalog mit Prädikat-Attributen 1.5.2 Nemo 6 Existierende SPARQL zu Datalog Implementierungen	1 2 2 3 4
2	esign des SPARQL zu Nemo Übersetzungstools 1 Grundlegendes Setup des Programms 2 Nemo Template Language 2.2.1 VarSets 2.2.2 Prädikat-Typen 2.2.3 Interne Nemo-Repräsentation 2.2.4 Nemo Template Language Makros 2.2.5 Interne Nemo-Repräsentation zu Nemo-Programm 3 SPARQL Ergebnistypen in Datalog 4 Überblick der Übersetzung 5 Testsuite 1 Testsuite	770235990
3	Inplementierung der SPARQL Features 3 1 Umgang mit Unbound-Werten 3 2 Umgang mit Fehlern 3 3 Umgang mit Variablen 3 4 Expressions 3 3.4.1 Variablen 3 3.4.2 NamedNode und Literal 4 3.4.3 Effective Boolean Value 4 3.4.4 And und Or 4 3.4.5 Not 4 3.4.7 If 4 3.4.8 Bound 4 3.4.9 Exists 4	566780023467

		3.4.10 Vergleichsoperatoren	50
			51
		l	52
			54
	3.5		59
			50
			51
			52
			53
	3.6		53
			54
			55
		0	56
	3.7	I and the second se	56
			57
			57
		3	59
			74
			75 77
			77 78
			30
			31
		J	33
			33
		00 0	36
	3.8	,	93
	5.0		93
			93
) 94
		3.0.3 Construct	<i>/</i> -
4	Eval	uation	95
	4.1	Evaluierung der SPARQL Konformität	95
	4.2		99
5	7.1.6	ammonfaceung und Aushlick	09
Э	Zusa	ammenfassung und Ausblick 1	JY

1 Einleitung

In diesem Kapitel werden die Grundlagen für diese Arbeit gelegt. Dies betrifft zum einen die Arbeit auf organisatorischer Ebene mit Zielstellung (Abschnitt 1.1) und Handreichungen zum Umgang mit dem Text (Abschnitt 1.2), und zum anderen die inhaltliche Ebene mit Einführungen zu RDF (Abschnitt 1.3), SPARQL (Abschnitt 1.4) und Datalog (Abschnitt 1.5). Außerdem werden in Abschnitt 1.6 verwandte Arbeiten erwähnt.

1.1 Zielstellung

Wesentliche Teile der Zielstellung dieser Arbeit ergeben sich aus der Aufgabenstellung. Grundsätzliches Ziel ist es, SPARQL-Queries (Abschnitt 1.4) in Nemo-Programme (Unterabschnitt 1.5.2) umzuwandeln, welche den gleichen Output erzeugen.

Konkret werden die einzelnen Punkte der Aufgabenstellung hier zusammengefasst und jeweils mit der konkreten Umsetzung in Verbindung gebracht:

- 1. SPARQL-Anfragen erzeugen eine n-stellige Tabelle. Das erzeugte Nemo-Programm soll ein Prädikat haben, das dieselben Tupel enthält wie die Zeilen dieser Tabelle.
 - In der Arbeit wird gezeigt, wie sich aus theoretischer Sicht ein Zusammenhang zwischen den Solution Mappings, welche im Standard das Ergebnis einer SPARQL-Query bilden, und Datalog Prädikaten, herstellen lässt. Besonders im Vordergrund steht dies in Unterabschnitt 1.5.1.
- 2. Die Arbeit soll eine Teilmenge von SPARQL-Anfragen bestimmen, für die das korrekt möglich ist, eventuell unter bestimmten Annahmen, z.B., dass manche von Nemos eingebauten Funktionen noch minimal angepasst werden, um genau den SPARQL-Standard umzusetzen.
 - Durch eine konkrete Implementierung konnte bis auf einige Details gezeigt werden, dass unter der Annahme, dass Nemo alle SPARQL Funktionen und Aggregationen implementiert und diese Standard konform sind, alle SPARQL 1.1 Query-Language-Anfragen (ohne Berücksichtigung optionaler Features) in Nemo übersetzbar sind. Die wichtigsten Details, für welche dies nicht gezeigt wurde, sind zum einen die FROM Clause und Graph Management Features und zum anderen das Variablen-Scoping der EXISTS Expression (Unterabschnitt 3.4.9), welches einen veränderten grundlegenden Ansatz erfordert. Es ist nicht zu erwarten, dass so ein Ansatz unmöglich ist.

- Für die reale Implementierung und verwendete Nemo Version wurde eine Anstrengung unternommen, Abweichungen zum SPARQL Standard zu finden und in einigen Fällen, trotz Abweichungen der Nemo Implementierung vom SPARQL Standard eine konforme Übersetzung durchzuführen. Diese Abweichungen werden an den entsprechenden Stellen dieser Arbeit erwähnt. In der real verwendeten Nemo Version lassen sich, trotz Turing-Vollständigkeit von Nemo, einige SPARQL-Queries grundsätzlich nicht übersetzen. Durch die fehlenden Funktionen StrLang(), welche aus gegebenen Zeichenketten eine Zeichenkette mit Language Tag erstellt, und StrDt(), welche einen Literal mit Datentyp erstellt, ist es z.B. unmöglich, einige Literals im Ergebnis zu erzeugen, wenn diese nicht bereits in der Eingabe vorkommen. Nemo befindet sich in aktiver Entwicklung und es werden im Folge dieser Arbeit Issues zu entsprechenden Abweichungen vom SPARQL Standard angelegt. Es ist zu erwarten, dass die Annahme, dass Nemo alle Funktionen SPARQL konform unterstützt, in Zukunft mehr und mehr berechtigt ist.
- 3. Es soll eine prototypische Implementierung erstellt werden, z.B. in Rust unter Verwendung der Bibliothek Oxigraph.
 - Es wurde eine prototypische Implementierung in Rust erstellt (siehe Kapitel 3). Dabei wurde die spargebra Bibliothek zum Umgang mit SPARQL-Queries verwendet, die für die Oxigraph Bibliothek entwickelt wurde und von ihr zum Transformieren einer SPARQL-Query in SPARQL-Algebra verwendet wird.
- 4. Die Implementierung soll verwendet werden, um eine Menge realer Anfragen zu übersetzen, z.B. die Beispielqueries des Wikidata SPARQL Endpoints oder Queries aus bekannten SPARQL-Benchmarks.
 - Es wurde eine Evaluation auf den Wikidata Beispielqueries und der Offiziellen w3c SPARQL 1.1 Test Suite durchgeführt. (Kapitel 4)

In der Aufgabenstellung sind zwei Tiefen der Implementierung vorgeschlagen:

- · Minimale Lösung: Übersetzung von Basic Graph Patterns und Property Paths
- Umfangreiche Arbeit: Minimale Lösung mit zusätzlicher Berücksichtigung von FILTER, Subqueries und Aggregaten

Es wurde die umfangreiche Arbeit umgesetzt und, wie bereits erwähnt, auch alle weiteren Features des SPARQL 1.1 Standards (ASK Query, DESCRIBE Query, CONSTRUCT Query, Query mit/ohne DISTINCT oder REDUCED, UNION, OPTIONAL, EXTEND, MINUS, VALUES, LIMIT, OFFSET, ORDER BY, was sich als besonders herausfordernd gezeigt hat, und Expressions inklusive In, Exists, Bound, If und Coalesce) berücksichtigt. Um die Menge an Features in der vorgegebenen Zeit umsetzen zu können, wurde eine Nemo Template Language mittels Rust-Makros implementiert (siehe Abschnitt 2.2).

Der Mehrwert einer SPARQL Implementierung in Datalog ist zum einen darin zu sehen, dass zusätzliches logisches Schließen vor Ausführung der Query, wie bei in Datalog umsetzbaren SPARQL Entailment Regimes, oder nach Ausführung der Query auf den Ergebnissen ohne weitere Programme möglich wird.

Außerdem können durch die Transformation von SPARQL zu Datalog auch SPARQL-Queries, wie eine Regel, Teil des logischen Schließens in Datalog werden. Für diesen Anwendungsfall ist eine SPARQL-Query Implementierung ohne stratifizierte Negation und Aggregation (siehe Unterabschnitt 1.5.2) nützlich. Deswegen wurde zusätzlich zur Aufgabenstellung bei der Implementierung darauf geachtet, nach Möglichkeit eine Implementierung der Features zu finden, welche nicht zu einem nichtstratifizierten Programm führen, wenn der Eingabegraph

vom Ergebnis der Query abhängt. Ein sehr grober schematischer Aufbau eines solchen Datalogprogramms wird in Abbildung 1.1 dargestellt.

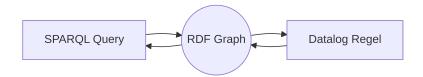


Abbildung 1.1: Rekursive SPARQL Query und Datalog Regel hängen vom Graph ab und liefern Ergebnisse für den Graphen

1.2 Umgang mit dieser Arbeit

Innerhalb dieser Arbeit werden einige Begriffe definiert und in anderen Kapiteln verwendet. Damit deutlich wird, dass es sich jeweils um einen konkret definierten Begriff handelt, sind diese Begriffe, wie im Beispiel "repräsentiert ?", durch einen Pfeil markiert. Der Pfeil verlinkt zur Definition. Unterstützt der verwendete PDF-Viewer Link-Preview, kann somit, durch das Halten der Maus über den Pfeil, die Definition angezeigt werden. Alternativ kann der Begriff im Anhang unter "Begriffsverzeichnis" (Abschnitt 5) nachgeschlagen werden. Generell werden in dieser Arbeit häufig andere Kapitel referenziert. Dies zeigt wichtige Voraussetzungen für ein Kapitel auf und kann auch als Gedächtnisstütze dienen. Bei linearem Lesen der Kapitel sollten jedoch alle relevanten Grundlagen für ein Kapitel bereits bekannt sein.

1.3 RDF

Ein *Triple-Graph* ✓ ist eine Menge an Triples.

Typischerweise wird ein Graph durch seine Kanten und Knoten definiert. Ausgehend von der oben genannten Definition sind unterschiedliche Definitionen für die Knoten eines Triple-Graphen denkbar. SPARQL definiert beispielsweise nodes (G) eines Triple-Graphen G:

 $nodes(G) = \{ n \mid n \text{ is an RDF term that is used as a subject or object of a triple of G} \}$

Ein "RDF term" ist dabei eine IRI¹, ein Literal² oder ein BNode³.

Einige Notationen im Zusammenhang mit RDF erlauben eine verkürzte Notation von IRIs, indem ein wiederkehrendes Präfix einen kürzeren Namen bekommt. Im Laufe der Arbeit werden folgende RDF-Präfixe teilweise, ohne auf deren Definition einzugehen, verwendet:

Prefix	Namespace-IRI
ex:	https://example.org/
xsd:	http://www.w3.org/2001/XMLSchema#

¹IRIs sind innerhalb dieser Arbeit gleichbedeutend mit allgemein bekannten URLs. IRIs unterstützen jedoch zusätzliche Features, wie Unicode-Symbole.

²ein konkreter Wert eines Datentyps

³Ein "Blanker" Knoten ohne Bedeutung außerhalb des aktuellen Graphen

Nach dieser Definition steht beispielsweise ex:abc für die IRI https://example.org/abc.

In RDF heißt die erste Stelle eines Triples im Graph "subject", die zweite "predicate" und die dritte "object". Dies ist angelehnt an die englische Grammatik. Hier ein deutsches Beispiel: "Mein Stift hat die Farbe Blau.", dies kann als Triple ("Mein Stift", "hat die Farbe", "Blau") ausgedrückt werden.

1.4 SPARQL

Eine wichtige Query-Sprache für RDF ist SPARQL. SPARQL ist in seiner grundlegenden Struktur, z. B. Verwendung von Keywords wie SELECT oder ORDER BY, ähnlich zu SQL, der allgemein bekannten Query Sprache für relationale Datenbanken. Die konkreten Features sind jedoch angepasst auf Graphdatenbanken, welche auf RDF (Abschnitt 1.3) basieren. So gibt es Features, welche ein gegebenes Graph Pattern in einem Graphen finden oder Features zum Finden von Knoten, welche durch einen Pfad mit bestimmter Struktur verbunden sind. In dieser Arbeit wird sich auf den SPARQL 1.1 Standard [8] bezogen. Der Standard beschreibt außer einer Query-Syntax auch die SPARQL Algebra, welche eine Zwischenrepräsentation bietet, die es erlaubt, existierende Query-Parser und Algebra-Transformationen in einer Datenbankimplementierung zu verwenden.

Das Ergebnis einer SPARQL-Query ist laut Standard eine (möglicherweise ungeordnete) Sequenz von "solution mappings". Ein Solution Mapping ist dabei eine Funktion, welche für eine gegebene Variable aus der Query einen RDF-Wert ergibt. Ein Solution Mapping muss dabei nicht für jede Variable der Query einen Wert ergeben. Für einige Variablen kann es nicht definiert sein. Diese Definition gilt auch für das Ergebnis von vielen Operationen der SPARQL-Algebra.

Im Rahmen dieser Arbeit ist an einigen Stellen im Zusammenhang mit SPARQL-Queries von einem *Query-Ergebnis* [→] die Rede. Dies ist hier als eine Menge von Tupels definiert, mit der Intuition, dass sich das Ergebnis als Tabelle darstellen lässt und jede Zeile der Tabelle ein Tupel ist. Es ist jedoch nicht trivial, Ergebnisse von SPARQL-Queries oder Subqueries als Tupel darzustellen. Im Laufe dieser Arbeit wird eine konkrete Umsetzung vorgestellt. Ein Überblick wird in Unterabschnitt 1.5.1 gegeben. Dort wird der Zusammenhang zwischen beiden Ergebnisdefinitionen hergestellt.

1.5 Datalog

Datalog ist eine Regelsprache, bei der aus bereits bekannten Fakten durch Regeln neue Fakten abgeleitet werden können. Die hier vorgestellte Datalog-Definition folgt der von Ceri und anderen [3] vorgestellten Beweis-theoretischen Sichtweise. Sie wurde in dieser Arbeit umfangreich angepasst, um den Fokus auf relationale Betrachtungen, welche im Zusammenhang mit SPARQL relevant sind, zu legen.

Fakten in Datalog sind n-Tupel, die einem n-stelligen Prädikat zugeordnet sind. Syntaktisch wird dabei das Prädikat vor das Tupel geschrieben. So ist beispielsweise parent (ann, dorothy), das Tupel (ann, dorthy), welches dem zweistelligen Prädikat parent zugeordnet wird. Fakten können durch eine Funktion l_i , welche jedem Prädikat p die Menge der zugeordneten Tupels $l_i(p)$ zuordnet, beschrieben werden. Explizit im Datalog-Programm geschriebene initiale Fakten werden durch die Funktion l_0 beschrieben.

Datalog Regeln haben folgende syntaktische Form:

$$p_{0x}(t_1,...,t_x) := p_{1y}(t_1,...,t_y),...,p_{mz}(t_1,...,t_z)$$

 p_{jn} steht für ein n-stelliges Prädikat. Die Terme Terme t_1, \ldots, t_n können Konstanten oder Variablen sein. Variablen sind syntaktisch durch ein ?-Präfix markiert. Es wird davon gesprochen, dass in einer Regel, eine Konstante oder Variable an die Position eines Prädikats "gebunden \nearrow " wird. So wird z.B. t_1 an die erste Position des Prädikats gebunden. Der Teil vor dem ":-"-Symbol wird als Regel-Kopf \nearrow und der Teil danach als Regel-Körper \nearrow bezeichnet.

Wie durch eine Regel neue Fakten abgeleitet werden können, kann durch Funktionen l_i , wie oben eingeführt, beschrieben werden. Ein Tupel t ist in $l_i(p)$ genau dann, wenn t in $l_{i-1}(p)$ ist oder es gibt eine Regel und Variablenersetzung θ mit $p(t_1, \ldots, t_x)$ als Regel-Kopf, $t = (\theta(t_1), \ldots, \theta(t_x))$ und für jeden Teil des Regel-Körpers $p_{jn}(t_1, \ldots, t_n)$ gilt $(\theta(t_1), \ldots, \theta(t_n)) \in l_{i-1}(p_{jn})$. Eine Variablenersetzung erhält dabei alle nicht-Variablen. Für alle nicht-Variablen k gilt also $\theta(k) = k$. Es gibt eine Safety-Bedingung, welche erfüllt ist, wenn jede Variable, die im Regel-Kopf vorkommt, auch im Regel-Körper gebunden wird. Die Safety-Bedingung stellt sicher, dass keine Fakten mit beliebigen Konstanten, welche unabhängig vom Datalog-Programm sind, abgeleitet werden können.

Eine einfache Regel ist beispielsweise "dorothy hat dieselben Eltern wie hilary":

```
parent(?Parent, hilary) :- parent(?Parent, dorothy)
```

Es ist bekannt [3], dass sich in Datalog jeder ableitbare Fakt in endlich vielen Schritten ableiten lässt. Es gibt also ein q mit $l_i = l_{i+1} = l$ für i > q, wobei l_i die oben definierte Funktion ist, welche einem Prädikat alle bis zum i-ten Schritt abgeleiteten Tupel zuordnet. l wird "Lösung l" des Datalog Programms genannt. Ist l die Lösung l2 eines Programms und l2 ein Prädikat des Programms, so kann dies durch "l3 repräsentiert l4 l6 vir oder "l5 steht für l7 l7 ausgedrückt werden. Das bedeutet, ein Prädikat repräsentiert l6 eine Relation in einem Datalog-Programm. Außerdem wird l7 das "Ergebnis l2 " von l7 genannt.

Gibt es für eine Regel eine Variablenersetzung, sodass die dazugehörigen Tupel des Regel-Körpers sich im entsprechenden *Ergebnis* [↗] des Prädikats befinden, so wird dies dadurch beschrieben, dass die Regel "*zum Tragen* [↗] " kommt. Ist dies nicht der Fall, wird also die Regel nicht angewendet, wird dies durch "Die Regel kommt nicht *zum Tragen* [↗] " beschrieben.

In der Praxis gibt es zahlreiche Erweiterungen von Datalog, diese erhöhen mitunter die Ausdrucksstärke und führen häufig zu anderen Eigenschaften. Erlaubt eine Erweiterung beispielsweise das Erzeugen neuer Konstanten in rekursiven Regeln, ist im Allgemeinen eine endliche Ableitung aller Fakten nicht garantiert und eine, wie oben definierte Lösung des Datalog Programms, existiert in einigen Fällen nicht. Dennoch sind die in diesem Kapitel gegebenen Definitionen, unter Berücksichtigung einiger zusätzlicher Fälle, auch für die in dieser Arbeit betrachteten Erweiterungen relevant.

1.5.1 Datalog mit Prädikat-Attributen

Es ist möglich, jeder Position eines Datalog-Prädikats ein Attribut zuzuweisen. Dies beeinflusst nicht die *Lösung* [→] eines Datalog-Programms. Dafür vereinfacht es das Generieren von Regeln, besonders, wenn zum Zeitpunkt des Entwickelns der Regel die Arität oder konkrete Bedeutung der einzelnen Positionen eines Prädikates unbekannt sind.

Für gegebene Prädikate kann man eine Datalog-Variable für jedes Attribut festlegen und die Prädikate *gebunden* ✓ an die jeweiligen Variablen in einem *Regel-Körper* ✓ zusammenführen.

Dies definiert eine natürliche Art, Prädikate in einer Regel zu verknüpfen und entspricht einem Natural Join in SQL.

Sei P die Menge der Positionen (Indizes) eines Prädikats p, mit |P| der Arität von p. Sei A eine Menge von Attributen und W eine Menge von Werten. Ein n-tupel kann definiert werden als eine Funktion, deren Domain eine n-elementige Indexmenge ist. Nach dieser Definition ist ein Tupel im Ergebnis von p eine Funktion $P \to W$ und die Attributzuweisung für p eine Funktion $P \to A$. Schreibt man das Ergebnis von p als Tabelle mit jedem Tupel in einer Zeile, so kann die Attributzuweisung den Header der Tabelle bilden.

Prädikate mit Attributen ermöglichen es, Solution Mappings aus SPARQL (Abschnitt 1.4) darzustellen. Das *Query-Ergebnis* einer SPARQL-Query lässt sich wie ein Prädikat mit Attributen als Tabelle mit Header darstellen, wobei jede Zeile der Tabelle ein Solution Mapping darstellt. Formal ist ein Solution Mapping eine Funktion, z.B. μ , von bestimmten SPARQL-Variablen (V) zu RDF terms (W, siehe Abschnitt 1.3). Hat man ein Datalog Prädikat p (mit Indexmenge P) mit Tupel $t: P \to W$ im Ergebnis und P0 und P1 und P3 und P4 die Atributzuweiseung P5 v, so kann daraus ein Solution Mapping definiert werden: P5 und P6 (also P6). Eine Attributzuweisung wird hier als invertierbar angenommen, das bedeutet, jedes Attribut darf nur einmal verwendet werden.

Erweitert man die Definition für ein einzelnes Solution Mapping auf das gesamte *Ergebnis* eines Prädikats, korrespondiert das *Ergebnis* eines Prädikats zu einer Solution Sequence ohne Reihenfolge. Der SPARQL-Standard [8] definiert "A solution sequence is a list of solutions, possibly unordered", wobei jedes Solution Mapping hier immer für alle Variablen im Image der Attributzuweisung des Prädikats definiert ist. Wie andere SPARQL Ergebnisse dargestellt werden können, wird an den entsprechenden Stellen dieser Arbeit erläutert. Dies erfolgt insbesondere in Abschnitt 2.3 für Solution Mappings mit Reihenfolge, im Abschnitt 3.1 für Solution Mappings mit unterschiedlichen Domains und im Abschnitt 3.8 für SPARQL-Ergebnisse die keine Solution Sequences sind.

1.5.2 Nemo

Eine konkrete Datalog-Implementierung ist die Regel Engine mit dem Namen "Nemo" [4]. Ein Ziel von Nemo ist es, RDF-Knoten, wie Literale unterschiedlicher Datentypen, IRIs und BNodes, sowie SPARQL Funktionen direkt zu unterstützen. Dies macht Nemo besonders attraktiv für eine SPARQL zu Datalog Übersetzung.

Einige Features, um welche Datalog in Nemo erweitert wird, sind an dieser Stelle nennenswert.

Nemo unterstützt Constraints, wie folgende Beispielregel zeigt:

```
q(1, "1").

p(?a) := q(?a, ?b), ?b = STR(?a).
```

Der Constraint ?b = STR(?a) schränkt z.B. das Ergebnis auf solche ?a Werte ein, deren String Repräsentation der dazugehörige ?b Wert ist. Dabei ist es erlaubt, den Funktionsaufruf direkt in das Prädikat q zu schreiben:

```
p(?a) := q(?a, STR(?a)).
```

⁴Eine Verallgemeinerung, bei der Attribute mehrfach verwendet werden, aber alle Tupel den gleichen Wert an den entsprechenden Positionen haben, wäre möglich jedoch nicht praktisch sinnvoll. Die Verwendete Bibliothek spargebra sowie die Blazegraph Datenbank erlauben beispielsweise keine Variable doppelt im SELECT Pattern.

Nemo unterstützt stratifizierte Negation mit dem ~ Symbol, wie folgendes Beispiel zeigt:

```
a(1) . a(2) . b(1) . c(?x) :- a(?x), \sim b(?x) .
```

Das Nemo-Programm ergibt nur c(2) und nicht c(1), da es für c(1) ein entsprechendes b(1) gibt. Der Begriff "stratifiziert" bedeutet dabei eine Einschränkung, welche besagt, dass alle Prädikate des Programms in eine Sequenz von "Schichten" eingeteilt werden können. Hängt ein Prädikat negativ von einem anderen Prädikat ab, so muss sich dieses in eine höhere Schicht einteilen lassen. Im Beispiel hängt c negativ von b ab und muss somit in einer höheren Schicht sein. Die Stratifizierungsbedingung schließt nicht sinnvolle Datalog Programme, bei denen Prädikate zyklisch negativ von voneinander abhängen, wie das folgende, aus:

```
p(?x) :- \sim p(?x).
```

Nach der Stratifizierungsbedingung müsste p einer höheren Schicht als es selbst ist zugeordnet werden, was unmöglich ist. Positive, zyklische Abhängigkeiten innerhalb einer Schicht sind erlaubt. Beim Schreiben oder Generieren eines Nemo-Programms ist zu beachten, dass die Stratifizierungsbedingung erfüllt ist.

Nemo unterstützt Aggregation, wie folgendes Beispiel zeigt:

```
a(1) . a(2) .

b(\#sum(?x)) :- a(?x) .
```

Das Programm ergibt b(3). Es ist zu beachten, dass Aggregation, ähnlich wie Negation, eine höhere Schicht fordert. Im Beispiel muss b einer höheren Schicht als a zugewiesen sein.

Nemo unterstützt existentielle Regeln durch Variablen-Präfix!, wie folgendes Beispiel zeigt:

```
next(1, 2) . next(2, 3) . next(3, 1) .

next(?y, !z) :- next(?x, ?y) .
```

Die Regel besagt, dass für jedes ?y, welches an zweiter Stelle im next Prädikat vorkommt, auch ein Tupel mit ?y an erster Stelle existieren muss. Im Beispiel ist dies bereits für das next Prädikat erfüllt. Wäre es für einen Wert nicht erfüllt, würde Nemo einen neuen Wert !z als BNode generieren. Dies würde eine endlose next-Kette und damit ein nicht terminierendes Nemo Programm bewirken. Im Allgemeinen ist schwierig festzustellen, ob eine solche existentielle Bedingung bereits durch andere Regeln erfüllt wird. In der Praxis kann es vorkommen, dass Nemo durch eine existentielle Regel einen BNode generiert, obwohl zusätzlich durch eine andere Regel später auch ein entsprechender Wert existieren wird. Das Verhalten hängt also von der internen Anwendungsreihenfolge der Regeln ab.

Zum Zeitpunkt der dieser Arbeit (2025) ist Nemo in aktiver Entwicklung, mit häufigen Änderungen. Grundlage für diese Arbeit ist eine Version vom Juli 2024. Darauf aufbauend wurden die UCASE() und LCASE() Funktionen durch Vertauschen korrigiert und das Behandeln von Fehlern bei den SUBSTR() und SUBSTRING() Funktionen an den SPARQL-Standard angepasst. Die resultierende Version wird in dieser Arbeit, als Abhängigkeit für die Implementierung und für die Tests, verwendet. Sie ist unter

https://github.com/knowsys/nemo/tree/36ca7d40295203099db04a501642b4686b2f2009

einsehbar.

1.6 Existierende SPARQL zu Datalog Implementierungen

Die Idee, SPARQL in Datalog zu übersetzen existiert bereits, seit es SPARQL gibt. SPARQL wurde 2008 in der Version 1.0 standardisiert. Bereits 2007 stellte Simon Schenk in einem Konferenzpaper eine Definition der SPARQL Semantik, basierend auf einer Übersetzung nach Datalog, vor [6]. Ein Paper von Renzo Angles und Claudio Gutierrez aus dieser Zeit analysiert die Ausdrucksmächtigkeit von SPARQL und verwendet dafür eine Übersetzung nach Datalog [1]. Beide Paper enthalten keine reale Übersetzungsimplementierung. Außerdem ist anzumerken, dass sich der SPARQL 1.0 Standard signifikant leichter in Datalog ausdrücken lässt, da viele Features erst im SPARQL 1.1 Standard hinzugekommen sind. Beispielsweise erzeugen die Übersetzungen null Werte für den OPTIONAL Query-Pattern, welche allerdings für die restliche Query keine größere Rolle spielen, da es im SPARQL 1.0 Standard z.B. noch keine Subqueries gibt.

Eine aktuelle Übersetzung von SPARQL nach Datalog wird von Angles und Anderen mit dem SparqlLog System vorgestellt [2]. Die Übersetzung findet für die Datalog-Engine Vadalog statt. Es wird Multiplizität von Ergebnissen unterstützt, indem durch existentielle Regeln in Datalog IDs, welche die Ergebnisse unterscheiden, generiert werden. Für die Unterstützung von ORDER BY gereift die Implementierung auf die bereits in Vadalog verfügbare Sortierfunktion zurück, diese ist jedoch nicht SPARQL konform. SparqlLog implementiert einige Features des SPARQL 1.1 Standards nicht. Insbesondere sind hier CONSTRUCT Query, DESCRIBE Query, BIND, VALUES, HAVING, FILTER EXISTS / FILTER NOT EXISTS, Coalesce, IN, NOT IN, Group Graph Pattern, Subqueries und FROM zu nennen. Weitere Features sind weder als implementiert noch als nicht implementiert aufgelistet. Die Implementierungen der unterstützten Features ähneln sich teilweise denen in dieser Arbeit vorgestellten. So verwendet SparqlLog beispielsweise auch⁵ ein dreistelliges Prädikat, um mit Unbound-Werten umzugehen. In SparqlLog ist dieses jedoch, ohne auf nähere Details einzugehen, ein einmal berechnetes Prädikat, während in dieser Arbeit aufgrund der unterstützen Features innerhalb der Übersetzung mitunter mehrere Versionen eines äquivalenten Prädikats benötigt werden.

⁵siehe Unterabschnitt 3.7.3 in dieser Arbeit

2 Design des SPARQL zu Nemo Übersetzungstools

In Kapitel 1 wurde bereits das Ziel, ein Programm zu entwickeln, welches SPARQL-Queries zu Nemo Programmen transformiert, mit den relevanten Grundlagen vorgestellt. In diesem Kapitel werden nun grundlegende Designentscheidungen für ein solches Programm getroffen. Das Programm wird in der Programmiersprache Rust entwickelt. Die Betrachtung der Ein- und Ausgaben findet in Abschnitt 2.1 statt. Eine wichtige Designentscheidung besteht darin, die Nemo-Regeln mittels einer Nemo Template Language zu generieren. Diese wird in Abschnitt 2.2 beschrieben. Außerdem werden durch die Implementierung der Nemo Template Language wichtige Grundlagen gelegt, wie die vom Programm verarbeiteten Datenstrukturen aussehen. Diese werden ebenfalls in Abschnitt 2.2 vorgestellt. In Abschnitt 2.3 wird die Entscheidung darüber getroffen, wie die unterschiedlichen SPARQL Ergebnistypen, wie Ergebnisse mit Reihenfolge, in Nemo dargestellt werden.

Weiterhin schließt das Design ein wie der Übersetzungsvorgang grundsätzlich abläuft, dies wird in Abschnitt 2.4 vorgestellt, und wie die Tests stattfinden, was in Abschnitt 2.5 vorgestellt wird.

2.1 Grundlegendes Setup des Programms

Das Programm für die Übersetzung einer SPARQL-Query zu einem Nemo Programm verfügt nicht über Command-Line-Argumente oder ein komplexeres Userinterface. Wichtige Eingaben erfolgen direkt im Quelltext, indem die Funktion translate(query_str) aufgerufen wird. Allerdings gibt es die Möglichkeit, die SPARQL-Query aus stdin zu lesen und das Nemo Programm auf stdout zu schreiben, sodass eine einfache Interaktion mit anderen Programmen möglich wird. Außerdem gibt es eine Rust-Testsuite, welche Beispielqueries übersetzt und die resultierenden Nemo-Programme mittels Nemo auf testspezifischen Daten evaluiert und mit den jeweils erwarteten Ergebnissen vergleicht. (siehe Abschnitt 2.5)

2.2 Nemo Template Language

Die SPARQL zu Nemo Konvertierung ist, sehr grob betrachtet, eine String Transformation. Eine gegebener SPARQL-Query-String wird zu einem Nemo-Programmfragment-String konver-

tiert. Eine initiale Implementierung verwendete direkte die verfügbaren String-Manipulations-Features der Rust-Programmiersprache. Dies erschwert jedoch das Verständnis der Übersetzung stark, was die Anzahl der unterstützten Features aufgrund der Zeitvorgaben reduziert hätte.

Die "Nemo Template Language" wurde im Rahmen dieser Arbeit dazu entwickelt, Nemo-Programme, basierend auf Nemo-Programm-Templates, zu generieren. Sie stellt im Wesentlichen eine Abstraktion für die benötigten String Manipulationen beim Generieren von Nemo-Programmen dar. Dazu wird mittels Rust-Makros Rust-Programmcode generiert, welcher eine interne Repräsentation eines Nemo-Programms erzeugt, welche dann zum Generieren eines Nemo-Programm-Strings verwendet wird.

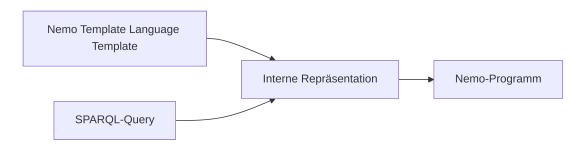


Abbildung 2.1: Transformation von SPARQL-Query zu Nemo-Programm

Die interne Repräsentation kann auch ohne Makros manipuliert werden. Dies ermöglicht es, weniger häufig verwendete Features zu unterstützen, für die sich keine Implementierung im Makro lohnt. Es wird eine nahezu nahtlose Verwendung von Rust-Makros mit manuell erstellten Teilen der internen Repräsentation unterstützt. Beispielsweise sind die grundlegenden Operatoren für intern repräsentierte Nemo Variablen überladen und eine Rust-Expression kann direkt innerhalb eines Nemo Templates verwendet werden. Außerdem gibt es zahlreiche Implementierungen des From Traits in Rust, welcher generische Implementierungen der Makros, inklusiv Unterstützung für Built-in Rust Typen, ermöglicht. Loops und Branches in der Template Language werden durch die Verwendung der entsprechenden Kontrollstrukturen in Rust umgesetzt. So können z.B. Regeln oder Regelteile unter Verwendung der Nemo Template Language in einem normalen Rust-Loop erzeugt und dann in weiteren Makroaufrufen verwendet werden.

Eine besondere Herausforderung stellt der Umgang mit Prädikaten dar, deren Arität erst während der Ausführung des Programms bekannt ist. Auf jeden Fall sind die Positionen und Arität des Ergebnisprädikats (siehe Abschnitt 1.1) ohne die SPARQL-Query nicht bekannt, da dies von den Variablen im SELECT in der Query abhängt. Gleiches gilt aber auch für fast alle Zwischenergebnisse, sodass nur bei einigen wenigen Regeln die Arität der Prädikate zur Zeit des Schreibens des Nemo Templates bekannt ist. Zwar ließe sich die Liste der Bindings für die Positionen jedes Prädikats mittels eines Loops in Rust generieren, dies wäre jedoch wieder nah an einer Implementierung mittels String Manipulation und würde somit die Vorteile der Nemo Template Language negieren. Stattdessen erlaubt die Nemo Template Language, die Regelstruktur in einer Nemo nahen Form zu schreiben und die konkrete Zuordnung zu den Prädikat-Positionen geschieht erst zur Übersetzungszeit. Damit dies möglich wird, betrachtet die Nemo Template Language alle Prädikate als Prädikate mit Attributen (Unterabschnitt 1.5.1), diese Attribute werden aus den Regeln automatisch von der Nemo Template Language abgeleitet.

So könnte beispielsweise eine Regel in Nemo Template Language Aussehen:

```
a(??x, ??y) :- b(??x, ??y), c(??x)
```

Dabei können Variablen mit ?? Präfix für mehrere Nemo Variablen stehen. Wie dies konkret funktioniert wird im Unterabschnitt 2.2.1 beschrieben, außerdem werden dort sowie in Unterabschnitt 2.2.4 weitere Features vorgestellt. Folgende Regel könnte aus dem Template oben resultieren:

```
a(?u, ?w, ?v) :- b(?u, ?w, ?v), c(?u, ?v).
```

Dabei steht ??x aus dem Template für ?u und ?v in Nemo, und ??y für ?w. Es ist zu beachten, dass im Template ??x vor ??y steht, dies jedoch nicht bedeuten muss, dass nicht ?w zwischen ?u und ?v stehen kann. Die Nemo-Regel wird anhand des Templates und der Information, welche Attribute die Prädikate b und c haben, gebildet. Ist a ein neues Prädikat, werden durch die Regel die Attribute von a inferiert.

Außerdem ist es möglich, Eigenschaften der jeweiligen Attribute automatisch zu tracken. Eine Eigenschaft ist dabei eine universell quantifizierte notwendige Aussage, welche wahr oder falsch sein kann. Ein Beispiel für so eine Aussage wäre:

"Alle Werte, die ein Attribut annehmen kann, sind notwendigerweise gerade Zahlen."

Es ist anzumerken, dass dies das Gegenteil folgender Aussage ist:

"Es existiert möglicherweise ein ungerader Wert."

Es können also durch Umformung auch einige existentiell quantifizierte Aussagen unterstützt werden. Diese existentielle Sichtweise zeigt, warum diese Art von Eigenschaften Performance relevant sind: Ist es unmöglich, dass ein Wert ungerade ist, müssen die Nemo-Regeln zum Behandeln ungerader Werte nicht generiert werden, was unter Umständen die Programmlaufzeit verbessert. Aus der Definition ergibt sich, dass bei einer Regel wie

```
a(?x) :- b(?x), c(?x).
```

die Eigenschaft für das Attribut ?x vom Prädikat a gilt, wenn sie für das Attribut von b oder c gilt und dass bei zwei Regeln die Eigenschaft aufgrund von Regel 1 und Regel 2 gelten muss, damit sie für das Prädikat gilt. Ist ein Prädikat nicht im Kopf einer Regel, repräsentiert ? es keine Tupel, somit wird jede über diese Tupel jede universell quantifizierte Aussage wahr. Es ergibt somit Sinn, dass die getrackten Eigenschaften wahr sind, solange nicht durch eine Regel abgeleitet wird, dass sie falsch sind oder explizit die Aussage auf Falsch gesetzt wird. Für alle komplizierteren Fälle, wie Negation, Funktionsaufrufe und Operatoren in Nemo, müssen die Eigenschaften, wenn nötig, manuell gesetzt werden.

Die Implementierung der Nemo Template Language findet im Projekt des Übersetzungstools in der Datei nemo_model.rs statt. Da die konkrete Implementierung nur indirekt relevant zur Beantwortung der Aufgabenstellung ist, werden hier nur entscheidende Konzepte und Algorithmen vorgestellt und weniger auf ihre konkrete Implementierung eingegangen. Die Implementierung umfasst über 2500 Zeilen und ist damit etwas länger als die eigentliche Übersetzung, welche fast 2000 Zeilen umfasst. Diese Zahlen vermitteln eine ungefähre Vorstellung für den Umfang der Implementierung.

2.2.1 VarSets

VarSets wurden bereits in der Einführung (Abschnitt 2.2) als Möglichkeit zum Umgang mit Prädikaten, deren Anzahl und Reihenfolge der Positionen zum Zeitpunkt des Templateschreibens unbekannt ist, vorgestellt. Ein erweitertes Beispiel für eine Regel in Nemo Template Language:

```
a(1+u, ?v, ??x, ??y) :- b(u, ??x, ??y), c(??x, ?v)
```

Außer den VarSets ??x und ??y gibt es im Beispiel auch die einzelne Variablen ?v und eine explizite Variable u. Dabei ist u zuvor in Rust durch let u = nemo_var!(b); definiert worden. Die mit ? beginnenden Variablen und VarSets sind nur innerhalb des Templates gültig und müssen nicht zuvor definiert werden.

Die allgemeine Struktur der Parameter eines Prädikats in Nemo Template Language besteht aus einem Präfix von positionsbasierten Variablen, einer Mitte aus VarSets und einem Suffix aus positionsbasierten Variablen. Explizite und einzelne Variablen sind dabei positionsbasiert. Im Beispiel bedeutet dies, dass 1+u, u und ?v nur in Präfix- oder Suffix-Position vorkommen. Eine positionsbasierte Variable ist nicht zwischen VarSets erlaubt. Dadurch können die Attribute vorne und hinten aufgrund ihrer Position direkt zu einzelnen Variablen zugeordnet werden und sind nicht an der Aufteilung in VarSets beteiligt.

Die Aufteilung der nicht positionsbasiert zugeordneten Prädikatatribute auf die VarSets ist potenziell nicht trivial. Im Beispiel ist das VarSet ??y dadurch definiert, dass ihm alle Attribute zugeordnet werden, die im Prädikat b vorkommen, aber nicht bereits dem VarSet ??x zugeordnet worden sind. Solche Aussagen könnten prinzipiell kettenreaktionsartig auf andere VarSets Einfluss haben und dazu führen, dass ein Verfahren zum logischen Schließen für die Aufteilung verwendet werden müsste. Dies wurde jedoch nicht implementiert und stattdessen eine einfache Semantik für VarSets verwendet. Nach dieser gehört jedes an VarSets beteiligtes Attribut prädikatübergreifend genau einem VarSet an. Durch diese einschränkende Annahme steht jedes VarSet für einen Bereich im Venn-Diagramm, welches sich aus den Mengen der Attribute für jedes Prädikat in der Regel ergibt. Es ist zu erwähnen, dass ein Venn-Diagramm potenziell exponentiell viele Bereiche haben kann, was zu vielen VarSets in einer Regel führen kann. Der Autor eines Templates muss darauf achten, dass alle real möglichen Bereiche des Venn-Diagramms durch genau ein VarSet abgedeckt werden. Die Praxis zeigt, dass einige Regeln etliche VarSets benötigen. Es stellt jedoch kein signifikantes Problem dar, da Regeln mit vielen Prädikaten häufig eine einfachere Struktur haben, im Hinblick auf Prädikate, welche gemeinsame Attribute beinhalten. Außerdem besteht stets die Möglichkeit eines manuellen Erstellens mittels Loop in Rust.

Aus dem Template oben kann sich folgende Beispiel Nemo-Regel ergeben:

```
a(?u + 1, ?m, ?n, ?o, ?p) :- b(?u, ?n, ?o, ?p), c(?n, ?o, ?m).
```

Die nicht positionsbasiert zugeordneten Attribute sind ?n, ?o und ?p in b und ?n und ?o in c. Daraus ergibt sich das einfache Venn-Diagramm in Abbildung 2.2, wobei die Menge der Attribute von c eine Teilmenge der Attribute von b ist. Es ergeben sich zwei Bereiche. Die Schnittmenge {?n, ?o} und die Menge der Attribute von b, die nicht in c sind, {?p}. Betrachtet man die VarSets im Template ergibt sich das ??x in b und c vorkommt und somit für die Schnittmenge {?n, ?o} steht und ??y nur in b aber nicht in c vorkommt und somit für {?p} steht.

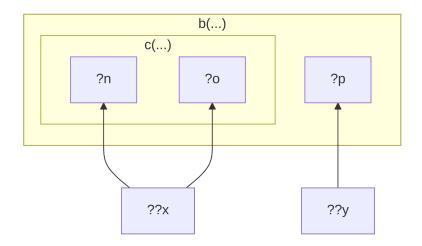


Abbildung 2.2: VarSets stehen für Bereiche im Venn-Diagramm aus den Attribut-Mengen der Prädikate

Die Zuordnung lässt sich durch Bitmanipulation implementieren. Jedem Prädikat der Regel wird eine Bit-Position zugeordnet. Für jedes Attribut werden für die Variablen, in denen es vorkommt, die Bits auf 1 gesetzt. Genauso werden für jedes VarSet die Positionen für alle Prädikate, in denen es vorkommt, auf 1 gesetzt. Dadurch ergibt sich ein u64 Bit Integer in Rust für jedes Attribut und jedes VarSet. Ein VarSet enthält dann genau alle Attribute mit der gleichen Zahl, die sich für das VarSet selbst ergibt. Gibt es zwei VarSets mit der gleichen Zahl oder für eine Zahl eines Attributs kein VarSet, führt dies zu einem Fehler zur Übersetzungszeit, also der Laufzeit des Übersetzungstools. Außerdem werden Regeln, bei denen 64 Bit nicht ausreichen, nicht unterstützt. Es ist durchaus möglich und praktisch relevant, dass ein VarSet keine Attribute enthält. Wenn das Prädikat im Kopf der Regel, im Beispiel a, bereits definiert ist, nimmt es auch am Prozess zur Auflösung der VarSets teil.

Ein Attribut kann zwar immer nur in einem VarSet sein, es ist jedoch möglich, dass es sowohl positionsbasiert ist, als auch in einem VarSet zugeordnet werden kann. Eine Regel wie a(attr):- b(??all_attrs)

kann somit dazu verwendet werden, ein zuvor definiertes Attribut attr, welches in den Attributen von b vorkommt, zu extrahieren, obwohl das Attribut sowohl explizit definiert als auch Teil des VarSets ist. Dieses grundsätzliche Verhalten, dass einzelne Variablen vollständig positionsbasiert sind und so auch für bereits anders vergebene Attribute stehen können, kann unter Umständen auch ungewollt sein. Existiert z.B. ein Prädikat p mit Attribut ?a, so ergibt das Regeltemplate

```
q(?x, ?y) := p(?x), p(?y)
```

das Prädikat q mit den Attributen ?a und ?a und das Nemo-Programm zum Template ist q(?a, ?a) := p(?a), p(?a).

da beide einzelnen Variablen an dasselbe Attribut ?a *gebunden* ✓ werden, was aus dem Regeltemplate unter Umständen nicht offensichtlich ist. Bei expliziten Variablen existiert eine höhere Kontrolle. Definiert man die Variablen

```
let x = nemo_var!(x); let y = nemo_var!(y);
ergibt das Template
q(x, y) :- p(x), p(y)
die Nemo Regel
q(?x, ?y) :- p(?x), p(?y) .
```

Das Prädikat q hat in diesem Beispiel die Attribute ?x und ?y. Ähnliches gilt auch für Expressions, da diesen jeweils eine eigene explizite Variable zugeordnet ist. Im Beispiel, welches am Anfang diese Kapitels eingeführt wurde, führt die Expression 1+u zu einem neuen Attribut ?SUM im resultierenden Prädikat a. Gibt es mehrere Summationen in der Regel, bekommen zwar alle ein Attribut, welches ?SUM heißt. Dies sind jedoch unterschiedliche Attribute und werden dann bei der Erstellung des Nemo-Programms im Kollisionsfall umbenannt.

Eine spezielle Form von VarSets sind RenameSets, diese werden mit ??* Präfix geschrieben statt nur ??. Es kann nur ein RenameSet pro Prädikat geben und jedes RenameSet darf nur einmal im Body einer Regel auftreten. Enthält ein Prädikat im Template ein RenameSet, trägt diese nicht zur Auflösung der VarSets bei. Alle Attribute, die nicht bereits einem VarSet des Prädikats zugeordnet werden, sind dann dem RenameSet zugeordnet. Die einem RenameSet zugeordneten Attribute werden zu neuen Variablen mit gleichem Namen gebunden und dann später durch die Namenskollisionsauflösung umbenannt. Dies stellt eine Möglichkeit dar, die Regel, dass jedem Attribut nur ein VarSet zugeordnet wird, aufzuweichen. Als Beispiel kann wieder das Prädikat p mit Attribut ?a verwendet werden. Das Template

```
q(?x, ?y) :- p(?x), p(?y)
führt zur Regel in Nemo:
q(?a, ?a) :- p(?a), q(?a).

Das Template mit RenameSet
q(?x, ??*y) :- p(?x), p(??*y)
führt hingegen zu dieser Regel in Nemo:
q(?a, ?a_1) :- p(?a), q(?a_1).
```

2.2.2 Prädikat-Typen

In der bisherigen Einführung zur Nemo Template Language wurde gezeigt, wie mit Prädikaten unterschiedlichster Formen in einem einzigen Template umgegangen werden kann. Ein Regeltemplate wie a (?x) :- p(?x, ??other) setzt allerdings eine gewisse Struktur der Prädikate, im Beispiel eine Semantik des Attributs an erster Stelle des Prädikats p, welche das Prädikat a rechtfertigt, voraus. Das Beispiel Template funktioniert für sehr unterschiedliche Strukturen von p Prädikaten. Alle diese Prädikate hätten jedoch die Gemeinsamkeit in der Bedeutung des ersten Attributes. Somit funktioniert das Regeltemplate mit einer bestimmten Klasse von Prädikaten, welche einem Typ angehören.

Ein Prädikat-Typ wird hier als eine Abfolge von benannten Keys (Strings) definiert, welche das Präfix bzw. Suffix in der Liste der Attribute eines Prädikats beschreiben. Bei der Regel a (?x) :- p(?x, ??other) könnte z.B. die erste Position des Prädikats p durch den key "count" beschrieben werden, wodurch a für alle counts aus p steht. Somit besteht der Prädikat-Typ darin, dass das Präfix der Liste der Attribute von p die einelementige Abfolge ist, welche nur "count" enthält.

In der Nemo Template Language können solche Prädikat-Typen explizit beschrieben und zur Rust-Compilezeit geprüft werden. Dazu können unterschiedliche Prädikate der Nemo Template Language Instanzen unterschiedlicher Typen in Rust sein. Der jeweilige Rust-Typ modelliert dabei den Prädikat-Typ. Alle diese Typen implementieren den TypedPredicate Trait. Dieser beinhaltet die Funktionalität, welche nötig ist, damit ein Prädikat in einem Regeltemplate verwendet werden kann. Der Basic Typ, welcher keine besonderen Keys beinhaltet, ist bereits in der Nemo Template Language definiert.

Ein Rust Typ, welche einen Prädikat-Typ modelliert, kann, wie in folgendem Beispiel gezeigt wird, durch Verwendung des nemo_predicate_type! Makros in einer einzigen Zeile erstellt werden:

```
nemo_predicate_type!(MyABCType = a b ... c);
```

Im Beispiel wird eine struct MyABCType erstellt und für diese der TypedPredicate Trait implementiert. Das Makro expandiert zu 99 Zeilen Rust-Code. Der MyABCType beschreibt, dass die ersten beiden Attribute den Key mit dem Namen "a" bzw. "b" haben und das letzte Attribut durch den Key "c" beschrieben werden kann. Die Implementierung der MyABCType struct beinhaltet die Methoden a(), b() bzw. c(), welche durch ein entsprechendes Regeltemplate aufgerufen werden. Der Compiler stellt sicher, dass die Methoden auch existieren. So wird spätestens zur Compilezeit, mit entsprechendem IDE Support jedoch bereits während des Schreibens des Regeltemplates, die Korrektheit des Prädikattyps geprüft. In einer Nemo Template Language Regel kann der Key eines Typs durch @-Syntax angegeben werden:

```
q(?y) :- p(@a: ?x, @b: ?y; ??vars; @c: ?z)
```

Das Beispiel extrahiert alle Werte für ein Attribut mit dem "b" Key aus dem Prädikat p, welches vom Typ MyABCType ist. Es ist zu beachten, dass das Präfix bzw. Suffix, welches durch @-Keys annotiert ist mittels : von den restlichen Variablen zu trennen ist.

Ein weiterer Vorteil, außer das Prüfen zur Compilezeit, entsteht durch die @? Syntax. Diese erlaubt eine Variable zu ignorieren, wenn der Typ des Prädikats den entsprechenden Key nicht unterstützt. Dies macht ein Regeltemplate noch flexibler und ermöglicht es in Rust, Funktionen mit generischen Parametern zu implementieren. Folgendes ist ein Beispiel für eine so generische Regel:

```
q(?y) :- p(@a: ?x, @b: ?y; ??vars; @?c: ?x)
```

Diese Regel extrahiert den "b" Wert. Nur falls p den Typ MyABCType hat, wird zusätzlich durch das Binden von ?x an die letzte Position, getestet, dass der erste und letzte Parameter den gleichen Wert haben. Damit unterstützt die Regel zusätzlich zum MyABCType auch den MYABType, welcher im Beispiel wie folgt, ohne den "c"-Key, definiert ist:

```
nemo_predicate_type!(MyABType = a b ...);
```

2.2.3 Interne Nemo-Repräsentation

Damit die Nemo Template Language funktioniert, wird eine interne Repräsentation von Nemo Regeln benötigt. Die Nemo Bibliothek, welche für die Tests ohnehin eine Abhängigkeit des Projekts ist, bietet ein vollständiges Modell für Nemo Regeln. Eine direkte Verwendbarkeit wurde untersucht und nicht als sinnvoll erachtet. Gründe dafür sind die Prädikate mit Attributen, das Tracken von Eigenschaften, welches zusätzliche Informationen benötigt und das grundlegende Konzept, Regeln in den Prädikaten des Regelkopfes zu speichern. Dies ermöglicht es in der Nemo Template Language nicht für jede Regel zusätzlich eine Collection von Regeln anzugeben, in die sie aufgenommen werden soll. Prädikate die später in bestimmten Fällen zu ignorieren sind, können mit Regeln erstellt werden, ohne das zugehörige Regeln später Teil des Nemo-Programms werden. Außerdem ist die Nemo eigene Repräsentation in einigen Punkten komplexer als für die SPARQL Übersetzung nötig. Insbesondere werden Filter-Conditions teilweise, und alle Sorten von Konstanten, im verwendeten Modell durch Strings beschrieben.

Folgende Grafik zeigt die wesentlichen Bestandteile des im Rahmen dieser Arbeit angefertigten Nemo Modells. Die Pfeile sind durch die Property beschriftet, welche zur Verknüpfung der Modellteile führt:

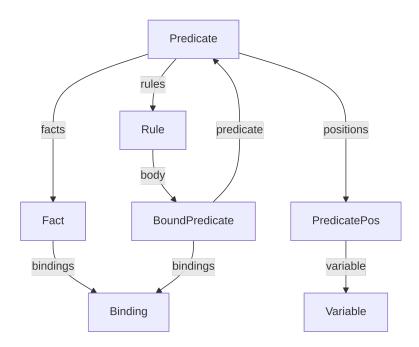


Abbildung 2.3: Übersicht der internen Nemo-Repräsentation

Es ist zu sehen, dass das Prädikat die zentrale Rolle in der Struktur bildet. Ein Prädikat enthält Regeln und Fakten, die es beschreiben. Außerdem werden dessen Positionen durch PredicatePos Instanzen repräsentiert, welche Eigenschaften tracken und ein Attribut, welches als "Variable" im Modell bezeichnet wird, referenzieren. Im Abschnitt 3.3 wird näher auf den Begriff "Variable" eingegangen. Eine Regel hat einen Regel-Kopf, welcher in der Grafik aus Gründen der Übersichtlichkeit nicht aufgenommen wurde und ähnlich zum Regel-Körper ist. Ein Prädikat im Regel-Körper wird durch eine BoundPredicate Instanz abgebildet, welche zu einem Predicate die Bindings in der Regel speichert. Ein BoundPredicate könnte beispielsweise die Information enthalten, dass die erste Position des Prädikats in der Regel an die Variable ?a gebunden wird, dabei wäre die Variable ?a ein Binding. Außer Prädikaten können im Regel Body auch Filter Conditions verwendet werden, die in der Grafik nicht dargestellt sind. Ein Fact unterstützt in Nemo nur Konstanten als Bindings.

Für Variable und Predicate wurde der Eq und Hash Trait implementiert, sodass Instanzen aufgrund ihrer Speicheradresse verglichen werden. Dies ermöglicht es, Variablen und Prädikate mit gleichem Namen zu unterstützen, welche dann im Rahmen der Namenskollisionsauflösung (Unterabschnitt 2.2.5) durch Anfügen eines Suffixes eindeutig gemacht werden. Dies ist notwendig, z.B. wenn ein Prädikat in einer Unterfunktion erstellt wird, welche mehrfach aufgerufen wird, was zu unterschiedlichen Prädikaten mit gleichem Namen führt. Außerdem werden Variable und Predicate nur sehr selten direkt verwendet. Meistens werden die jeweiligen Smart-Pointer-Wrapper VarPtr und PredicatePtr, welche in Rust gecloned werden können ohne die Speicheradresse und damit, aufgrund der Eq Implementierung, die Identität zu verlieren.

Constant String

Call

Binding

left Operation

right

Variable

VarPtr

Existential

Unterschiedliche Nemo Regel Features werden durch die Binding enum unterstützt:

Abbildung 2.4: Übersicht der Binding-Enumeration für Positionen in Prädikaten

Die enum Varianten Call und Operation sind in einer gleichnamigen struct implementiert, welche von der enum Variante nur referenziert wird. Diese Information ist aus Gründen der Übersichtlichkeit nicht in der Grafik abzulesen. Zahlreiche Typen implementieren den From Trait in Rust, um zu Binding konvertierbar zu sein, so z.B. unterschiedliche Builtin-Typen in Rust wie Zahlen, Strings und Boolean-Werte. Die Konstanten werden nach RDF Syntax als String gespeichert. Dies kann von der im Projekt verwendeten spargebra Rust-Bibliothek generiert und von Nemo interpretiert werden. Somit bildet es eine einfache und flexible Schnittstelle.

Zusätzlich zur Modellierung von Nemo Regeln werden auch Features der Nemo Template Language modelliert. Dazu gibt es die ProtoPredicate enum für Dinge, welche zu Prädikaten und Filtern in einem Regel-Körper führen und ProtoBinding enum für Dinge, die zu Bindings in einem Prädikat werden können. Konkret ist z.B. ein VarSet ein ProtoBinding, welches dann zu einzelnen Variablen in Nemo aufgelöst wird. ProtoPredicate und ProtoBinding sind insbesondere bei der Implementierung der Nemo Template Language Makros (Unterabschnitt 2.2.4) relevant.

2.2.4 Nemo Template Language Makros

Das Zentrum der Nemo Template Language bilden zwei Makros, welche es erlauben, ein Nemo Regel Template im Rust-Code zu verwenden. Wie in Unterabschnitt 2.2.3 beschrieben werden Regeln im Prädikat, welches den *Regel-Kopf* → bildet, gespeichert. Das nemo_def! Makro erlaubt es, ein Nemo Regel Template zu schreiben, wobei die resultierende Regel in einem neu definierten Prädikat gespeichert wird. Dem gegenüber steht das nemo_add! Makro, welches auch erlaubt, ein Nemo Regel Template zu schreiben, jedoch wird die

resultierende Regel einem existierenden Prädikat hinzugefügt. Bei der Erstellung eines neuen Prädikats müssen die Attribute für dieses auf Basis der Regel abgeleitet werden, dadurch verhält sich das nemo_def! Makro etwas anders. Insbesondere bei der Zuordnung der Attribute zu VarSets (Unterabschnitt 2.2.1) können nicht die Attribute des Prädikates im Regel-Kopf ↗ zur Bestimmung der VarSets, sondern werden die VarSets zur Bestimmung der Attribute des Prädikates im Regel-Kopf ↗ verwendet. Folgendes ist eine Regel, die für nemo_add! aber nicht für nemo_def! valide wäre:

```
// sowohl p als auch q sind Rust-Variablen im aktuellen Scope nemo\_add!(p(??a) := q(??a, ??b));
```

Würde dieses Regeltemplate mit dem nemo_def! Makro verwendet, wäre die Zuordnung der Attribute zu den VarSets ??a oder ??b nicht wohldefiniert, da beide sich nur durch den Regel-Kopf / unterscheiden.

Ein weiterer Unterschied der beiden Makros besteht darin, dass bei nemo_def! nach der Regel der Typ (Prädikat Typen in Unterabschnitt 2.2.2) separiert durch ; angegeben werden muss und optional der Name des Prädikats angegeben werden kann. Der Name der Rust Variable, in der das neue Prädikat mit der Regel gespeichert wird, ist durch den Namen des Prädikats, der im Template verwendet wird, gegeben. Wenn nicht ein anderer explizit angegeben wurde, wird dieser auch für das Prädikat später beim Erstellen des Nemo-Programms verwendet. Ein expliziter Name ist sinnvoll, wenn das Template in einer in mehreren Situationen verwendeten Funktion verwendet wird, das Prädikat aber zur besseren Verständlichkeit einen der konkreten Situation angepassten Namen haben soll. Gibt es mehrere Prädikate mit gleichen Namen, werden diese im Rahmen der Namenskollisionsvermeidung (siehe Unterabschnitt 2.2.5) durch ein Suffix umbenannt. Im Rahmen dieser Arbeit wird zur Beschreibung einer Nemo Regel der im Regel Template verwendete Prädikat Name verwendet, ohne gesondert darauf einzugehen, dass der tatsächliche Name im späteren Nemo-Programm sich davon unterscheiden könnte.

Trotz der genannten Unterschiede sind beide Makros sehr ähnlich. Ein nemo_def! Makroaufruf kann durch manuelles Erstellen des Prädikats und nachfolgendem nemo_add! Makroaufruf ersetzt werden. Dies wird in komplexeren Fällen auch nötig, da nicht immer die Attribute des neuen Prädikats aus einer einzelnen Regel abgeleitet werden können. In solchen Fällen muss das Prädikat manuell mit den entsprechenden Attributen erstellt werden. Beide Makros unterstützen neben Regeln auch einfache Fakten.

Alle Makros der Nemo Template Language sind als deklarative Makros in Rust implementiert. Hier ein Beispiel, wie ein nemo_def! Makro expandiert wird:

Rust erkennt dabei korrekt, dass der new_predicate Identifier aus dem ursprünglichen Makroaufruf kommt, builder jedoch nicht. Deswegen kann new_predicate in späterem Rust-Code verwendet werden, es kommt aber zu keinen Kollsionen, wenn mehrere Makros die Variable builder verwenden. Es ist erkennbar, dass eine einzelne Variable mit einfachem ? Präfix als NamedConnection bezeichnet wird, da sie eine einfache Verbindung anhand eines Namens zwischen Attributen unterschiedlicher Prädikate herstellt. existing_predicate hat in Rust einen Typ, der den TypedPredicate Trait implementiert, welcher das zugrundeliegende Prädikat über die get_predicate() Methode zur Verfügung stellt. new_predicate hat den Typ Basic, welcher ebenfalls den TypedPredicate Trait implementiert. Der zweite Parameter der finalize_atom Methode gibt an, ob das Prädikat mittels stratifizierter Negation negiert werden soll. Die Nemo Template Language unterstützt dies durch ~ wie in Nemo. Die to_predicate Funktion führt den Prozess des Auflösens der Nemo Template Language Features zu Nemo Features durch. Beispielsweise werden die Prädikat-Parameter Bindings der Nemo Template Language (ProtoBinding) zu validen Bindings in Nemo (Binding) aufgelöst. Dies schließt insbesondere das Auflösen der VarSets ein. Die äquivalente Funktion für nemo_add! ist perform_add().

Die verwendete IDE RustRover unterstützt Autovervollständigung, Syntaxhighlighting und Linting auch innerhalb von Makroaufrufen. Allerdings wird zum Zeitpunkt der Implementierung dies nicht für verschachtelte Makros unterstützt, außerdem ist die Möglichkeit der Abstraktion in Rust für Makros nicht umfangreich unterstützt. Deswegen wurden die nemo_add! und nemo_def! Makros in einer schwer wartbaren fraktalen Struktur geschrieben, wobei gleiche Pattern an allen Stellen, wo diese auftreten geinlined wurden. Dadurch umfassen beide Makro-Definitionen zusammen über 750 Zeilen. Die Namen für die Makrovariablen bilden dabei eine hierarchische Struktur. Eine der längsten Variablennamen ist beispielsweise head_aggregate_front_connection_name. Dies bezeichnet den connection_name, wenn dieser im Head der Regel innerhalb einer Aggregationsexpression im vorderen Teil des Prädikats, also vor den VarSets, steht. Die Sprache zur Definition deklarativer Makros in Rust schränkt die Möglichkeiten ein, welche Symbole in welcher Situation verwendet werden können, um ein effizientes Parsen zu garantieren. So müssen Aggregationsfunktionen in der Nemo Template Language mit Präfix % statt wie in Nemo mit Präfix # aufgerufen werden, da das # Symbol in Rust auch in Expressions zum Aufruf von Makros verwendet werden kann.

Neben den beiden Hauptmakros zur Regelerstellung gibt es noch zahlreiche weitere Makros, welche Teile von Regeln innerhalb von Rust-Code erstellen können:

Makro	Beschreibung und Beispiel		
nemo_declare!	erstellt ein Prädikat ohne eine dazugehörige Regel mit zuvor explizit erstellten Attributen.		
	<pre>Beispiel: nemo_declare!(p(a, b));</pre>		
nemo_var!	erstellt eine neue Nemo-Variable mit gegebenem Namen. Es werden auch existentielle Variablen unterstützt.		
	<pre>Beispiel: nemo_var!(x), nemo_var!(!x);</pre>		
nemo_iri!	erstellt eine Nemo IRI, optional mit einem Präfix, das zuvor in einer Rust-Variable definiert wurde.		
	<pre>Beispiel: nemo_iri(rdf => type)</pre>		

Makro	Beschreibung und Beispiel	
nemo_call!	erstellt einen Nemo-Funktionsaufruf, bei dem alle Parameter explizit definierte Variablen oder geschachtelte Rust-Expressions sein müssen.	
	Beispiel: nemo_call!(STR; s)	
nemo_filter!	erstellt eine Nemo-Filter-Kondition basierend auf Strings. Implizite Variablen wie ?1 werden unterstützt.	
	<pre>Beispiel: nemo_filter!("fullStr(", ?1, ") != fullStr(", ?r, ")")</pre>	
nemo_condition!	wie nemo_filter!, aber nur für drei Parameter (linke Seite, Operation, rechte Seite).	
	<pre>Beispiel: nemo_condition!(?1, " != ", ?r)</pre>	
nemo_predicate_type!	erstellt eine neue Rust-Struct, die den TypedPredicate-Trait implementiert.	
	<pre>Beispiel: nemo_predicate_type!(FirstParameterIsCountPredicate = count);</pre>	

Zwei Makros können verwendet werden, um mehrere Dinge mittels Rust-Code in einer Rust-Variable zu aggregieren und dann direkt eine Menge von Dingen auf einmal in einem Regeltemplate zu verwenden. Konkret sind dies das nemo_atoms! Makro, welches logische Atome, wie ein Prädikat mit gebunden Parametern oder einer Filter-Kondition aggregieren kann, und das nemo_terms! Makro, welches logische Terme, wie Variablen oder Funktions-aufrufe, aggregieren kann. Das nemo_atoms! Makro erstellt eine spezielle Multi Variante der ProtoPredicate Enumeration und das nemo_terms! Makro eine TermSet Instanz. Ein TermSet kann nicht nur in Regeln verwendet werden, sondern bietet auch Funktionalität zum Generieren von Attributen für die manuelle Erstellung eines Prädikats und zum Deduplizieren unter Beibehaltung der Reihenfolge. Das nemo_terms! Makro unterstützt zusätzlich einen Mappingsyntax wie nemo_terms! [term_list => transform_func] wobei die Elemente eines iterierbares Objekts term_list nicht direkt, sondern nach Aufruf der transform_func Funktion zum TermSet zusammengefasst werden. Beide Makros aggregieren Dinge, in dem sie jeweils ihren eigenen Ergebnistyp enthalten können. So kann z.B. ein Rust-Loop, welcher Nemo Atome aggregiert, aussehen:

```
let mut atoms = nemo_atoms![];
for element in some_list {
    atoms = nemo_atoms![atoms, element.get_atom()]
}
```

2.2.5 Interne Nemo-Repräsentation zu Nemo-Programm

Die Eingabe für das Generieren eines Nemo-Programms bildet ein Nemo Prädikat. Für dieses Prädikat werden die Regeln, von denen es abhängt, generiert. Rekursiv werden auch die Programme, für die Prädikate die in den Regeln vorkommen depth-first generiert. Dabei sind einige Dinge zu beachten:

- Für Regeln mit leerem *Regel-Körper* muss ein dummy() Prädikat generiert werden und in den *Regel-Körper* aufgenommen werden, da in Nemo ein *Regel-Körper* nicht leer sein darf. Eine leere Regel ist dabei unterschiedlich von einem Fakt, da in Nemo für Fakten andere Features unterstützt werden. Existentiell quantifizierte Variablen können in der verwendeten Nemo Version nicht in Fakten verwendet werden. Außerdem unterstützen Fakten keine Berechnungen, wie z.B. Funktionsaufrufe. Zwar ergibt jede Berechnung in einem Fakt eine Konstante, die prinzipiell auch im Vorhinein berechnet werden kann, allerdings ist eine Berechnung direkt in Nemo zu bevorzugen, da dies zu einer einheitlichen Implementierung der Berechnungen führt und den Implementierungsaufwand, die Berechnung während der Übersetzung zu unterstützen, erspart.
- Nemo unterstützt in der verwendeten Version keine Prädikate mit Arität null. In der Praxis kommet es jedoch bei der Übersetzung vor, dass ein Regeltemplate zur Arität null führt und dies auch das semantisch korrekte Ergebnis liefert. Solche Prädikate mit Arität null werden zum Zeitpunkt der Transformation mit einer Dummyposition versehen, welche immer an die Konstante arity_zero gebunden wird. Damit an allen Stellen mit Arität null gleich umgegangen wird, führt ausschließlich die Funktion make_non_empty() diese Ersetzung durch.
- Für unterschiedliche Prädikate mit gleichem Namen ist eine Namenskollisionsauflösung durchzuführen werden. Dazu werden alle bisher verwendeten Namen gespeichert und im Kollisionsfall ein numerisches Suffix angefügt. Dadurch ergeben sich Namen wie pred, pred_1, pred_2 für drei unterschiedliche Prädikate mit Namen pred. Unterschiedliche Variablen mit gleichen Namen müssen innerhalb einer Regel umbenannt werden. Dafür wird dieselbe Funktionalität wie für Prädikate verwendet. Der Zustand ist dabei lokal innerhalb einer Regle in einem VariableTranslator Objekt gespeichert.
- Es gibt Differenzen zwischen Nemo und SPARQL, welche Variablen-Namen gültig sind, z.B. erlaubt SPARQL eine Ziffer in erster Position des Variablennamens Nemo nicht. Insbesondere bei automatischen Variablen-Namen bei SPARQL-Transformationen in der spargebra Rust-Bibliothek tritt dies häufig auf, da diese zum Teil auf Basis von UUIDs oder BNode Namen generiert werden. Ein VariableTranslator Objekt löst dies, indem alle nicht alphanumerischen Symbole aus dem Variablennamen entfernt werden und falls die Variable nicht mit einem ASCII Buchstaben beginnt, das Präfix var_ angefügt wird. Dies ist ausreichend für die durchgeführten Tests, trifft jedoch nicht exakt die validen Variablennamen in Nemo. Beispielsweise ist der Umlaut "ö" ein alphanumerisches Zeichen, das zwar von SPARQL, aber nicht von Nemo unterstützt wird.

2.3 SPARQL Ergebnistypen in Datalog

Das Design der SPARQL zu Nemo Übersetzung erfordert eine Festlegung, wie SPARQL Ergebnisse dennoch möglich werden, obwohl sie, z.B. durch Beachtung der Reihenfolge, nicht direkt durch ein Nemo Prädikat repräsentiert → werden können. Ein Nemo Prädikate repräsentiert → eine Menge von Tupel. Somit lassen sich ungeordnete Ergebnisse einer

SPARQL-Query ohne Duplikaten direkt darstellen. Andere Typen lassen sich durch zusätzliche Prädikatpositionen mit spezieller Bedeutung darstellen. Hier die 4 Ergebnistypen:

Prädikat-Typ-Definition	Beschreibung
SolutionSet = SolutionMultiSet = count	Menge von Tupel: keine besonderen Positionen Menge mit Duplikaten: erste Position gibt Multiplizität an
SolutionSequence = index SolutionExpression = result	Geordnete Liste: erste Position gib Index an Berechnung: mögliche Eingabekombination gefolgt von Ergebnis.

Eine so definierte geordnete Liste kann auch Multiplizität darstellen, in dem das gleiche Ergebnis an mehreren Indizes auftritt. Weitere Details zu SolutionExpression werden im Abschnitt 3.4 vorgestellt. Eine SPARQL-Query ergibt grundsätzlich eine SolutionSequence. Eine Ausnahme dabei bildet ein Ergebnis vom Typ SolutionSet, wenn das DISTINCT Keyword verwendet wurde (siehe Unterabschnitt 3.7.1). Der SolutionMultiSet Typ wird ausschließlich für Zwischenergebnisse verwendet und bietet für viele SPARQL Operationen eine einfachere Implementierung, da sie ohne Reihenfolge definiert sind und Berechnungen mit Reihenfolge in Datalog häufig weniger effizient und komplexer zu implementieren sind.

2.4 Überblick der Übersetzung

Die Evaluierung einer SPARQL-Query kann grundsätzlich schematisch wie in Abbildung 2.5 dargestellt werden. Es werden nur SPARQL-Queries, welche auf einem Triple Graph angewendet werden betrachtet, Queries über mehrere Graphen oder Update-Queries werden in dieser Arbeit nicht berücksichtigt.

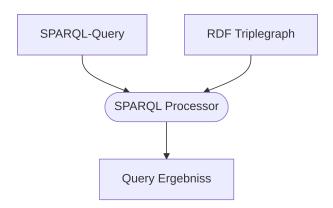


Abbildung 2.5: High-Level Queryevaluierungsablauf

Soll Nemo als SPARQL Processor verwendet werden, wird zusätzlich eine Übersetzung von SPARQL zu Nemo benötigt. Eine solche Übersetzung wurde im Rahmen dieser Arbeit entwickelt. Die Evaluierung einer SPARQL Query mit Nemo wird in Abbildung 2.6 dargestellt.

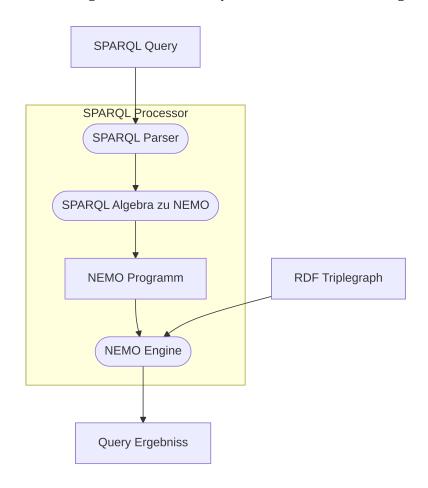


Abbildung 2.6: SPARQL2Nemo Queryevaluierungsablauf

Die Übersetzung ist grundsätzlich eine String-Transformation. Als Eingabe wird ein SPARQL-Query-String entgegengenommen und die Ausgabe ist ein Nemo-Programmfragment. Dieses verwendet ein definiertes dreistelliges Prädikat input_graph(s, p, o) welches den *Triple-Graph* auf dem die SPARQL-Query evaluiert werden soll *repräsentiert*.

Die Übersetzung eines SPARQL-Query-Strings zu einem Nemo String wird von der translate() Funktion durchführt. Diese sei hier vollständig abgebildet:

Außer einem Nemo-String kann die Funktion auch einen Fehler erzeugen, welcher entweder durch einen Fehler beim Parsen der Query oder durch einen Fehler beim Übersetzen zustande kommt. Der Übersetzungsprozess erfolgt in vier Schritten:

- 1. Parsing der SPARQL-Query: Dafür wird die Rust-Bibliothek spargebra [7] in der Version 0.2.8 verwendet, welche die Parsing Komponente von Oxigraph¹, einer Graphdatenbankimplementierung in Rust, ist. Spargebra behandelt bereits einige Fehlerfälle und führt im SPARQL Standard definierte Transformationen durch. Dies erleichtert weitere Schritte.
- 2. Erstellen des QueryTranslator: Der QueryTranslator wurde im Rahmen dieser Arbeit entwickelt und ist für die Übersetzung verantwortlich. Der QueryTranslator wird mit dem Prädikat, welches den Eingabe-Graphen repräsentiert ✓, konfiguriert. Außerdem wird im Konstruktor ein Prädikat für null Values (siehe Abschnitt 3.1) und ein VariableTranslator (siehe Abschnitt 3.3) erstellt.
- 3. Generieren der internen Nemo Repräsentation (Unterabschnitt 2.2.3) aus der SPARQL-Algebra: Die translate_query() Funktion gibt ein Prädikat, welches das SPARQL *Query-Ergebnis repräsentiert repräsentiert* , zurück. Da diese Übersetzung ein wesentlicher Inhalt dieser Arbeit ist, folgt ein näherer Überblick im Rest des Kapitels.
- 4. Erstellen eines Nemo-Programm-Strings aus der internen Nemo Repräsentation: Dies folgt dem bereits in Unterabschnitt 2.2.5 vorgestellten Vorgehen.

Um den SPARQL-Algebra Baum in die interne Nemo-Repräsentation zu übersetzen, werden die Knoten rekursiv bottom up übersetzt. Es wird für jeden Knoten der Algebra ein Prädikat in Nemo generiert, welches das Ergebnis der Evaluation des Teilbaums *repräsentiert* . Bei der Übersetzung einer Algebra Operation werden ausschließlich neue Prädikate im *Regel-Kopf* und Prädikate aus der Übersetzung des aktuellen Teilbaums, einschließlich der neuen Prädikate, im *Regel-Körper* verwendet. Durch die Baumstruktur der SPARQL-Algebra wird direkt ein kanonischer azyklischer Abhängigkeitsgraph der Prädikate des Nemo-Programms und damit eine Stratifizierung (siehe Unterabschnitt 1.5.2) impliziert. Ein nicht stratifiziertes Programm kann nur auftreten, wenn

- eine Implementierung eines einzelnen SPARQL-Algebra Knotens ein nicht stratifiziertes Programmfragment liefert;
- das input_graph Prädikat vom SPARQL Ergebnis Prädikat abhängt;
- von der strikten Struktur, z.B. durch Optimierungen, abgewichen wird.

2.5 Testsuite

Die Testsuite verwendet die in Rust verfügbaren Test-Features, insbesondere das #[test] Attribut. Fast alle Testcases sind SPARQL-Queries und Eingabedaten mit erwarteten Ergebnissen. Die SPARQL-Query wird zunächst übersetzt und dann mittels Nemo auf den Eingabedaten ausgeführt. Schließlich wird das Ergebnis mit dem erwarteten Ergebnis verglichen. Nemo wird in den Tests direkt importiert und verwendet, wodurch Nemo eine Abhängigkeit des Rust-Projekts wird. Es gibt grundsätzlich Tests für alle Übersetzungsfunktionen. Die Tests wurden während der Implementierung der Übersetzungsfunktionen mit entwickelt, was ein intensiveres Testen, von während der Implementierung als komplex empfundenen Programmteilen, ermöglicht. Die Tests tragen wesentlich zur Korrektheit der

¹https://github.com/oxigraph/oxigraph

Übersetzung bei. Es gibt eine gesonderte Evaluation, da die Testsuite nicht unabhängig ist, das heißt, fehlendes Verständnis für ein SPARQL-Feature kann sowohl zu einer falschen Implementierung als auch zu fehlenden dazu passenden Tests führen. Außerdem wurde die Implementierung kontinuierlich angepasst, sodass die Testsuite keine Fehler erkennt. Eine fehlende Generalisierung der Korrektheit auf reale Suchanfragen kann jedoch ohne separate Evaluation nicht beurteilt werden. Features, bei denen Limitierungen in Nemo oder der Implementierung bekannt sind, und daher im Test nicht erfolgreich sind, werden in der Testsuite nicht getestet.

Für die Testimplementierungen werden die Funktionen assert_sparq1() und assert_sparq1_multi() verwendet. Beide nehmen als Eingabe die SPARQL-Query als String, die Inputs als Nemo-Programm-Fragment, welches das Prädikat input_graph(?s,?p,?o) beinhaltet, und das erwartete Ergebnis. Das erwartete Ergebnis wird als String übergeben und hat ein speziell definiertes Format. Dabei können Tupel durch ";" oder eine neue Zeile getrennt werden und Werte innerhalb eines Tupel sind durch ";" separiert. Beginnt und endet der String mit "[" bzw. "]" wird jedem Tupel dessen Index als erster Wert hinzugefügt (siehe Darstellung von Ergebnissen mit Reihenfolge in Abschnitt 2.3). Die Reihenfolge der Tupel ist grundsätzlich nicht relevant da die eigentliche Reihenfolge, wenn relevant, durch den Index in jedem Tupel gegeben ist. Die Funktion assert_sparq1_multi() ignoriert die erste Tupleposition und kann damit verwendet werden, falls die erste Position der Index ist, aber die Reihenfolge egal ist. Wie der Name bereits ausdrückt, wird die Multiplizität jedes Ergebnisses beachtet. Beide Funktionen liefern im Fehlerfall eine möglichst gut formatierte Fehlermeldung, welche fehlende und extra Tupel im Queryergebnis anzeigt.

Die Namen der Testfälle beginnen mit dem Feature-Namen der Übersetzungsfunktion. Beispielsweise gibt es für die Übersetzungsfunktionen für Basic-Graph-Patterns, translate_bgp() und translate_bgp_multi() die Testfunktionen bgp_simple(), bgp() und bgp_multi(). Jede Testfunktion kann mehrere SPARQL-Queries testen und in jeder SPARQL-Query können unter Umständen mehrere Tests stattfinden, z.B. kann in mehreren BIND Zeilen einer Query jeweils ein anderer Test stattfinden. Die Testsuite umfasst 94 Aufrufe der Funktionen assert_sparql() und assert_sparql_multi() in 89 Testfällen und damit 94 zu testende SPARQL-Quieries. Alle Tests laufen in der finalen Implementierung mit der verwendeten Nemoversion erfolgreich. Da Nemo globale Locks für das Timing verwendet, lassen sich die Tests nicht parallelisieren und müssen mit der Umgebungsvariable RUST_TEST_THREADS=1 ausgeführt werden. Dennoch wurden die Tests möglichst effizient gehalten und laufen in ca. 16,7 s vollständig durch. Auch die Korrektheit des Codes, welcher die als String gegebene Erwartung mit dem tatsächlichen Ergebnis vergleicht, wird getestet.

3 Implementierung der SPARQL Features

In diesem Kapitel werden die einzelnen SPARQL Features nacheinander vorgestellt und beschrieben, wie diese in Nemo-Programme (Unterabschnitt 1.5.2) übersetzt werden können. Das vollständige Programm ist auf GitHub einsehbar. [10]

3.1 Umgang mit Unbound-Werten

In SPARQL ist ein einzelnes Ergebnis einer Query ein "solution mapping" (eine partielle Funktion) $\mu:V\to \mathsf{RDF}\text{-}\mathsf{T}$. Dabei ist V die Menge der SPARQL Variablen und RDF-T die Menge der möglichen Werte in RDF (Terms). In Unterabschnitt 1.5.1 wurde bereits vorgestellt, wie diese Darstellung zu einer Darstellung eines Ergebnisses mithilfe eines Tupel und einem Prädikat mit Attributen korrespondiert. Die Domänen ($dom(\mu)$) für unterschiedliche Ergebnisse μ eine SPARQL-Query können sich unterscheiden. Das Ergebnis eines Prädikats in Nemo enthält jedoch nur Tupel gleicher Länge.

Eine Variante unterschiedliche Domains abzubilden wäre ein eigenes Prädikat für jede mögliche Domaine. Dies kann jedoch zu sehr großen Nemo Programmen führen, da die Zahl der möglichen Domains exponentiell von der Anzahl der Variablen in der Query abhängt. Eine bessere Alternative ist die Einführung eines speziellen Wertes, genannt "UNDEF-Marker ". Der Name ergibt sich aus dem UNDEF Schlüsselwort beim VALUES Feature in SPARQL, welcher das Fehlen eines Wertes darstellt. Dies führt jedoch nicht direkt zu korrektem Verhalten bei vielen SPARQL Features. Anpassungen, wie bei diesen der UNDEF-Marker unterstützt werden kann, sind im weiteren Verlauf dieser Arbeit vorgestellt. Der UNDEF-Marker verhält sich bei vielen Features eher wie eine Wildcard als ein konkreter Wert. Innerhalb von Expressions (Abschnitt 3.4) führen nicht definierte Variablen direkt zu einem Fehler. Dies hat zur Folge, dass der UNDEF-Marker innerhalb von Expressions nicht weiter berücksichtigt werden muss, abgesehen von der bound () Expression. (Unterabschnitt 3.4.8).

Es ist nötig, dass der *UNDEF-Marker* nicht in den Eingabedaten der Query oder (Zwischen-) Ergebnissen vorkommt. Dies kann in Nemo sichergestellt werden, indem der *UNDEF-Marker* ein, durch eine existentielle Regel generierter, BNode ist. In der QueryTranslator Klasse gibt es das, im Konstruktor erstellte, undefined_val Prädikat, welches die einelementige Menge mit dem *UNDEF-Marker*, z.B. {(_:0)}, repräsentiert . Da ein sich ändernder BNode die Verständlichkeit beim Betrachten der Ergebnisse verringert, gibt es bei der Übersetzung auch

die Option, dass der *UNDEF-Marker* [→] die einfache Nemo IRI UNDEF ist. Alle Implementierungen können grundsätzlich mit beliebigen Werten als *UNDEF-Marker* → umgehen.

3.2 Umgang mit Fehlern

In Nemo führen Fehler bei Berechnungen, z.B. in Funktionen, zu fehlenden Tupels im Ergebnis. Dies gibt die zu verwendende Repräsentation von Fehlern durch fehlende Tupels vor, da sonst eine umfangreiche Implementierung zum Abfangen von Fehlern nötig wird. Eine Konsequenz dieser Repräsentation ist die Notwendigkeit von Negation zum Prüfen von Fehlern. Da Negation in Datalog ein nicht triviales Feature ist, könnte dies als Nachteil gesehen werden. Stratifizierte Negation bewirkt beispielsweise, dass durch das Testen auf Fehler das Programm nicht stratifiziert wird, wenn der Eingabe-Graph vom Ergebnis der Query abhängt, was zwar kein Problem darstellt, aber dennoch unerwünscht ist (Abschnitt 1.1). Eine Alternative ohne stratifizierte Negation und dafür mit existentiellen Regeln wird exemplarisch in Unterabschnitt 3.7.6 vorgestellt. Diese funktioniert jedoch nicht in allen Fällen.

Es gibt in der Implementierung keine Unterscheidung unterschiedlicher Fehlertypen.

3.3 Umgang mit Variablen

In dieser Arbeit gibt es in unterschiedlichen Zusammenhängen Variablen, die mit? Präfix gekennzeichnet sind:

- SPARQL-Query Variablen (siehe Abschnitt 1.4)
- Nemo Regel Variablen (siehe Unterabschnitt 1.5.2)
- Nemo Template Language Variablen (siehe Unterabschnitt 2.2.1)
- Prädikat-Attribute (siehe Unterabschnitt 1.5.1)

Im Rahmen der Übersetzung kann dieselbe Variable in mehreren dieser Zusammenhänge verwendet werden. Typischerweise verläuft eine Variable folgende Schritte:



Abbildung 3.1: Übergang zwischen verschiedenen Variablen

Eine SPARQL Variable nimmt typischerweise eine Position in einem Basic-Graph-Pattern ein und wird für das entsprechende Prädikat ein Prädikat-Attribut. Dieses Attribut wird dann in weiteren Regeln verwendet, wodurch es nach den Regeln der Nemo Template Language (Abschnitt 2.2) auch ein Attribut der daraus abgeleiteten Prädikate werden kann. Am Schluss werden die Variablen in den Nemo Regeln aus den Prädikat-Attributen abgeleitet. Ein Übergang zwischen Nemo Variable und Variable der Nemo Template Language findet im Prozess der Verallgemeinerung einer Nemo Regel zu einem Regeltemplate statt. Außerdem steht eine Nemo Template Language Variabele in jeder Regelanwendung für ein konkretes Prädikat-Attribut. Eine explizit in Rust erstellte Variable (VarPtr in Unterabschnitt 2.2.3) kann auch in einem Regeltemplate verwendet werden und steht dann direkt für sich selbst als Prädikat-Attribut.

SPARQL Variablen sind durch ihren Namen eindeutig. Prädikat-Attribute müssen jedoch keine SPARQL Variablen sein und sind im Programmcode eindeutig basierend auf ihrer Speicheradresse. Für das Mapping von spargebra SPARQL-Variablen zu Nemo Template Language Prädikat-Attributen hat das QueryTranslator Objekt eine VariableTranslator Instanz¹, welcher Prädikat-Attribute (im Code VarPtr) basierend auf ihrem SPARQL Variablen-Namen zurückgibt. So können neue Variablen als Prädikat-Attribute (VarPtr) jederzeit frei erstellt werden und mit SPARQL Variablen einheitlich zusammen verwendet werden, ohne dass Kollisionen möglich sind. (siehe Kollisionsauflösung in Unterabschnitt 2.2.5)

3.4 Expressions

Expressions sind eine Art von Operationen in der SPARQL-Algebra, die bei gegebener Variablenzuweisung zu einem Literal, BNode oder zu einer IRI evaluiert werden können. Eine Expression-Operation wird, wie alle SPARQL Algebra-Operationen, zu einem Nemo Prädikat übersetzt. Für Expressions hat dieses Prädikat den Typ SolutionExpression, welcher wie folgt, definiert ist (siehe auch Unterabschnitt 2.2.2):

```
nemo_predicate_type!(SolutionExpression = ... result);
```

Der Prädikattyp SolutionExpression umfasst Prädikate, deren letzte Position "result" heißt. Die anderen Stellen werden verwendet, um die möglichen Inputparameterkombinationen zu erfassen. Das heißt für die Expression ?a + ?b ist das resultierende Prädikat dreistellig, wobei z.B. die erste Stelle den Wert für ?a, die zweite Stelle den Wert für ?b und die dritte Stelle das Ergebnis der Berechnung ?a + ?b enthält. Da eine Expression immer auf einer konkreten Menge von Solution Mappings (Unterabschnitt 1.5.1) evaluiert wird, müssen nicht alle theoretisch denkbaren Kombinationen der Inputparameter betrachtet werden, sondern nur solche, die in der konkreten Menge von Solution Mappings vorkommen. Dadurch ist die Größe der Menge, die das Prädikat der Expression repräsentiert Aleiner oder gleich groß der Menge von Solution Mappings, auf denen die Expression berechnet wird.

Nemo erlaubt zusammengesetzte Expressions und es ist sowohl zeitlich als auch aus Sicht des verwendeten Speichers effizienter, diese zu verwenden, als für jede Teilexpression ein neues Prädikat in Nemo zu definieren. Da jedoch viele SPARQL Expressions, z.B. NOT EXISTS sich nicht direkt als Nemo Expression umsätzen lassen, wurde der Ansatz mit einzelnen Prädikaten für jede Teilexpression, aufgrund der Einheitlichkeit, gewählt. In Zukunft ist eine dahingehende Optimierung denkbar (Kapitel 5).

Die einzelnen Expressiontypen der SPARQL-Algebra werden durch Methoden in der QueryTranslator Klasse implementiert und in den folgenden Teilkapiteln näher beschreiben.

Zur allgemeinen Veranschaulichung der Implementierungen der Expressiontypen, wird die Deklaration der Funktion gezeigt, welche eine "oder" Expression übersetzt:

```
fn translate_or(
    &mut self,
    left: &SolutionExpression,
    right: &SolutionExpression,
    binding: &dyn TypedPredicate
) -> Result<SolutionExpression, TranslateError>
```

¹dies ist ein anderer VariableTranslator als in Unterabschnitt 2.2.5

Dabei werden die Parameter der SPARQL Expression als Nemo Prädikate vom Typ SolutionExpression, im Beispiel left und right, und die Menge an Solution Mappings, für welche die Expression berechnet werden soll, als generisches TypedPredicate, im Beispiel binding, übergeben. Der generische Parameter ermöglicht es, die Expression Implementierungen auch im Kontext von Multiset-solutions oder Solution-sequences zu verwenden. Wie dies in der Nemo Template Language funktioniert, wurde bereits in Unterabschnitt 2.2.2 vorgestellt. Häufig werden noch zusätzliche Parameter, spezifisch für die SPARQL Algebra-Expression Operation, übergeben. Die Methoden geben jeweils ein Nemo Prädikat vom Typ SolutionExpression oder einen Fehler zurück.

Alle spezifischen Übersetzungsmethoden für Expressions werden von der übergeordneten translate_expression Methode aufgerufen. Diese führt auch die Rekursion zur Berechnung der Parameter bei verschachtelten Expressions durch. Die korrekte Methode wird in einem großen match expression Statement, wobei expression die übergebene spargebra Expression ist, ausgewählt. Wie auch die spezifischen Expressionmethoden, übernimmt auch die translate_expression Methode den binding Parameter und gibt ein Nemo Prädikat vom Typ SolutionExpression oder einen Fehler zurück.

3.4.1 Variablen

Eine Variablen-Expression evaluiert zu dem Wert, welcher der gegebenen Variable in den gegebenen Bindings zugewiesen ist.

Wie in Abschnitt 3.4 beschrieben, wird eine Variable-Expression in ein Nemo Prädikat übersetzt. Das Prädikat *repräsentiert* ✓ Tupel, die jeweils aus Input-Parametern und dem Ergebnis, bestehen.

Wird z.B. die Expression ?b auf folgenden Solution Mappings evaluiert:

?a	?b	?c
"a" "b" "c"	1 1 2	a b c

repräsentiert [↑] das resultierende Prädikat, die Tupel:

?b	result
1	1
2	2

Als Sonderfall muss betrachtet werden, dass die Variable in einigen Solution Mappings nicht definiert sein kann. Dies kann der Fall sein, wenn die Position, welcher der Variable zugeordnet ist, in einem Tupel der UNDEF-Marker ist oder der Variable keine Tupelposition zugeordnet ist. Variablen sind in diesem Zusammenhang, wie in Abschnitt 3.3 beschrieben, SPARQL Variablen, die als Prädikat-Attribute verwendet werden. Die Verwendung einer nicht definierten Variable ist ein Error in SPARQL. Es wird sichergestellt, dass es kein Tupel für die Inputs, welche zu einem Error führen, im Ergebnis des Prädikats gibt (siehe Abschnitt 3.2 für den Umgang mit Fehlern).

Da dies die erste vorgestellte konkrete SPARQL zu Nemo Übersetzung ist, wird hier beispielhaft gezeigt, wie eine vollständige Implementierung aussieht:

```
fn translate_expression_variable(
    &mut self, var: &Variable, binding: &dyn TypedPredicate
) -> Result<SolutionExpression, TranslateError>
    let var_binding = self.sparql_vars.get(var);
    if get_vars(binding).contains(&var_binding)
       let undef = self.undefined_val.clone();
       nemo_def!(
           var(var_binding; @result: var_binding)
            :- binding(??set_contains_var), ~undef(var_binding)
            ; SolutionExpression
        );
       0k(var)
   else
       let always_error = SolutionExpression::create(
            "always_error", vec![var_binding.clone()]
        Ok(always_error)
}
```

Die Funktion könnte, für das Beispiel auf der vorhergehenden Seite, den folgenden Nemo-Code erzeugen:

```
var(?b, ?b) := p(?a, ?b, ?c), \sim undef(?b).
```

In diesem Code ist der var Parameter die SPARQL-Variable ?b, und der binding Parameter das Prädikat p, dessen Stellen für die Variablen ?a, ?b und ?c stehen. ?a, ?b und ?c sind also, nach Definition in Unterabschnitt 1.5.1, die Prädikat-Attribute.

Die Funktion erhält, wie alle Übersetzungsfunktionen, das QueryTranslator Objekt self und, wie die meisten Expression-Übersetzungen, das Nemo Prädikat mit den Variablen-Bindings, binding. Zusätzlich wird die SPARQL Expression Variable var vom Typ Variable, welcher in der spargebra Bibliothek definiert ist, übergeben.

Durch sparql_vars.get() wird die SPARQL-Variable in eine entsprechende Nemo Template Language Variable übersetzt (siehe Abschnitt 3.3).

Das nemo_def Makro definiert das resultierende Nemo Prädikat, var. Dieses zweistellige Prädikat hat wie alle Expressions den Typ SolutionExpression, bei dem die letzte Position das Ergebnis ("result") enthält. Da beide Positionen an var_binding gebunden werden, haben sie immer den gleichen Wert. Der Wert wird im Regel-Körper im binding Prädikat gebunden. Dies macht die Regel "safe" (siehe Abschnitt 1.5). Das ??set_contains_var Variablenset umfasst alle Variablen des Binding Prädikats und damit auch die Variable var_binding (siehe Unterabschnitt 2.2.1).

Durch ~undef(var_binding) wird sichergestellt, dass nicht definierte Variablen zu einem Error (fehlendes Tupel) führen. Trotz der Negation führt diese Regel, selbst wenn das Input-Graph-Prädikat vom Ergebnis der SPARQL-Query zyklisch abhängt, nicht zu einem nicht stratifizierten Programm, da das undef Prädikat nicht vom Eingabe-Graph abhängt. (siehe Abschnitt 1.1 und Unterabschnitt 1.5.2 weshalb dies relevant ist).

Im Falle, dass die SPARQL Variable nicht in den Variablen des binding Prädikats vorkommt, ist das Ergebnis der Übersetzung ein always_error Prädikat, welches in keinem Regel-Kopf ✓ vorkommt. Dieses Prädikat repräsentiert ✓ die leere Menge und somit einen Fehler für alle Eingaben. Das always_error Prädikat ist einstellig, da es nur eine Position für das Ergebnis hat.

3.4.2 NamedNode und Literal

Die NamedNode Expression in SPARQL evaluiert zu einer konstanten IRI. Dies lässt sich zu einem einstelligen Nemo Prädikat übersetzen, für welches ein Fakt generiert wird. Eine kurze Implementierung ist dafür ausreichend:

Außer self wird nur die IRI als NamedNode (Typ aus spargebra) übergeben.

Das resultierende Prädikat named_node vom Typ SolutionExpression wird erstellt und mittels nemo_add Makro aus der Nemo Template Language um einen Fakt erweitert.

Zusätzlich zur abgebildeten Funktion wurde der Trait From<&NamedNode> für Binding implementiert. Binding ist der Typ für Bindings von Prädikatpositionen in der Nemo Template Language und bietet einen Erweiterungspunkt durch Implementierung des From Traits. Dadurch kann ein Objekt vom Typ NamedNode direkt im Nemo Template verwendet werden. (siehe Unterabschnitt 2.2.3)

Literal-Expressions evaluieren zu einem konstanten RDF Literal anstatt einer IRI und werden sehr ähnlich wie NamedNode Expressions übersetzt.

3.4.3 Effective Boolean Value

Operationen in SPARQL, die einen Wert vom Typ Boolean als Eingabe nehmen, konvertieren nicht boolesche Werte zu einem Boolean mithilfe der "Effective Boolean Value" Berechnung. Die Übersetzung unterstützt die Effective Boolean Value Berechnung für die Typen bool, str und numeric. Da der Typ zum Zeitpunkt der Übersetzung nicht bekannt ist, werden alle Regeln für die drei Fälle für jede Effective Boolean Value Berechnung generiert. Ein Boolean hat Effective Boolean Value true, wenn er der Wert true ist. Ein String hat den Effective Boolean Value true, wenn er länger als der leere String ist. Eine Zahl hat den Effective

Boolean Value true, wenn sie nicht Null ist. Ein Beispiel für die Effective Boolean Value Übersetzung bei dem SPARQL-Query Fragment FILTER(?b) ist hier dargestellt (xsd Präfix und Kommentare manuell eingeführt):

```
@prefix xsd: <http://www.w3.org/2001/XMLSchema#> .
% bools
effective_boolean_value(?b, "false"^^xsd:boolean)
   :- var(?b, ?RESULT), ?RESULT = "false"^^xsd:boolean .
effective_boolean_value(?b, "true"^^xsd:boolean)
   :- var(?b, ?RESULT), ?RESULT = "true"^^xsd:boolean .
% str
effective_boolean_value(?b, "false"^^xsd:boolean)
   :- var(?b, ?RESULT), STRLEN(?RESULT) = 0 .
effective_boolean_value(?b, "true"^^xsd:boolean)
   :- var(?b, ?RESULT), STRLEN(?RESULT) > 0.
% numbers
effective_boolean_value(?b, "false"^^xsd:boolean)
   :- var(?b, ?RESULT), ?RESULT >= 0, ?RESULT <= 0.
effective_boolean_value(?b, "true"^^xsd:boolean)
   :- var(?b, ?RESULT), ?RESULT > 0 .
effective_boolean_value(?b, "true"^^xsd:boolean)
   :- var(?b, ?RESULT), ?RESULT < 0 .
```

Es gibt jeweils eine eigene Regel für true bzw. false. Für Zahlen besteht der Fall für true aus zwei Regeln, da ein direkter Test auf Gleichheit bzw. Ungleichheit den Typ mit berücksichtigen würde. Es muss sichergestellt sein, dass kein Wert beide Fälle triggert.

Die drei Typen entsprächen den im SPARQL Standard vorgeschriebenen Typen für die Effective Boolean Value Berechnung. Damit kann die Berechnung unter der Annahme, dass Nemo alle vorgeschriebenen Zahlen korrekt unterstützt, als standardkonform bezeichnet werden. Für NaN Werte oder falsche Literals wie äbc"^^xsd:integer würde der Effective Boolean Value false. Jedoch kann Nemo diese Werte ohnehin nicht darstellen. Alle bisher nicht berücksichtigten Werte ergeben einen Fehler, was korrekt abgebildet wird, da in diesem Fall keine der Regeln zum Tragen / kommt.

Für Subexpressions, von denen bekannt ist, dass sie bereits einen booleschen Wert liefern, muss keine Effective Boolean Value Berechnung durchgeführt werden. Dazu gibt es die Funktion expression_known_to_be_bool(), welche mithilfe einer match Expression true zurückgibt, falls die äußerste Operation den Ergebnistyp Boolean hat oder die Subexpression der konstante Wert true oder false ist. Die Methode translate_bool_expression() verwendet die Funktion translate_expression(), expression_known_to_be_bool() und translate_effective_boolean_value(), um eine Subexpression für eine Operation mit boolescher Eingabe zu übersetzen.

3.4.4 And und Or

Nemo hat eine OR und eine AND Funktion, welche jedoch nicht direkt verwendet werden können, da sie sich im Fehlerfall nicht korrekt verhalten. SPARQL hat Short-circuit boolesche Operatoren. Beispielsweise ergibt ?a && 0, wobei ?a nicht definiert, also ein Error ist, in SPARQL den booleschen Wert false. Wenn Fehler als fehlende Tupel dargestellt werden, ist diese Verhalten in Datalog generell schwierig in einer einzigen Funktion umsetzbar. Die Implementierung verwendet stattdessen Standard Datalog Regeln ohne Funktionen.

Es folgt die Übersetzungsfunktion von OR:

```
fn translate_or(
   &mut self,
    left: &SolutionExpression,
    right: &SolutionExpression,
    binding: &dyn TypedPredicate
) -> Result<SolutionExpression, TranslateError>
    let or = SolutionExpression::create(
        "or",
        nemo_terms![
            left.depend_vars(),
            right.depend_vars(),
            VarPtr::new("result")
        ].vars()
    );
    nemo_add!(
        or(??left, ??right; @result: true)
        :- left(??left; @result: true), binding(??left, ??right, ??other)
    );
    nemo_add!(
        or(??left, ??right; @result: true)
        :- right(??right; @result: true), binding(??left, ??right, ??other)
    );
    nemo_add!(
        or(??both, ??left, ??right; @result: false)
        left(??both, ??left; @result: false),
        right(??both, ??right; @result: false),
        binding(??both, ??left, ??right, ??other)
    );
   0k(or)
}
```

Hier ist ein beispielhaftes resultierendes Nemo-Program. true und false dienen nur zur Veranschaulichung und werden in Wirklichkeit von der Nemo Template Language korrekt in xsd:boolean übersetzt:

```
or(?a, ?b, true) :- left(?a, true), p(?a, ?b, ?c) .
or(?a, ?b, true) :- right(?a, ?b, true), p(?a, ?b, ?c) .
or(?a, ?b, false) :- left(?a, false), right(?a, ?b, false), p(?a, ?b, ?c) .
```

Dabei sind or, left und right Prädikate mit demselben Namen wie im Rust-Code und p das binding Prädikat. left und right stehen für die linke und rechte Expression, welche mit Or verknüpft sind.

Die Implementierung folgt folgender Aussage: "a oder b" ist genau dann wahr, wenn "a" wahr ist oder "b" wahr ist und genau dann falsch, wenn "a" und "b" beide falsch sind. Ist z.B. "a" falsch und "b" ein Fehler, ist "a oder b" weder wahr noch falsch - also ein Fehler.

Die Übersetzungsfunktion erstellt zunächst ein neues Prädikat or, welchem dann drei Regeln hinzugefügt werden.

Das or-Prädikat hat Positionen für Abhängigkeiten von linker und rechter Subexpression und, wie alle SolutionExpression Prädikate, das Ergebnis als letztes Prädikat-Attribut. Diese Positionen werden mit dem nemo_terms! Makro gemerged. Dieses entfernt Duplikate, ohne die Reihenfolge zu ändern. Die depend_vars() Methode gibt für SolutionExpression alle Variablen bis auf die letzte, welche für das Ergebnis ist, zurück.

Die drei Regeln werden mit dem nemo_add! Makro der Nemo Template Language zum or Prädikat hinzugefügt. Die ersten beiden Regeln stehen für: "a oder b" ist genau dann wahr, wenn "a" wahr ist oder "b" wahr ist. Die dritte Regel steht für "a oder b" ist genau dann falsch, wenn "a" und "b" beide falsch sind.

Das Binding Prädikat in jeder Regel schränkt die möglichen Inputkombinationen ein. Dies ist wichtig, falls die linke und rechte Teilexpression nicht von den gleichen Variablen abhängen. Dies würde in den ersten beiden Regeln zum Verstoß gegen die Safety Bedingung (Abschnitt 1.5) und in der letzten Regel, unter Umständen, zu einem großen *Ergebnis* führen, da zwei Variablen, die nur auf einer Seite jeweils vorkommen, im Ergebnis alle möglichen Kombinationen liefern würden. Es ist darauf geachtet worden, alle möglichen Kombinationen, mit denen Variablen in Prädikaten auftauchen können, mit Variablen Sets (beginnend mit ??, siehe Unterabschnitt 2.2.1) zu berücksichtigen.

Die zugrundeliegende Aussage ist durch die De-morganschen Gesetze inspiriert und kann auch mit diesen in eine Aussage für AND überführt werden: "a und b" ist genau dann falsch, wenn "a" falsch ist oder "b" falsch ist und genau dann wahr, wenn "a" und "b" beide wahr sind. Diese Aussage kann für einer Übersetzung von AND ganz ähnlich zu OR verwendet werden. Eine formale Herleitung wäre nur möglich, nachdem einige Gesetze der in SPARQL verwendeten Logik mit "Wahr", "Falsch" und "Error" eingeführt würden. Die Korrektheit der Aussagen und Übersetzungsimplementierung kann durch Testen aller neun im SPARQL Standard festgelegten Möglichkeiten² gezeigt werden.

Es ist die korrekte Implementierung der Effective Boolean Value Berechnung (Unterabschnitt 3.4.3) der linken und rechten Teilexpression zu beachten.

3.4.5 Not

Nemo hat eine NOT Funktion, die boolesche Negation berechnet. Diese wird zur Übersetzung der Not Expression aus SPARQL verwendet. Allerdings ist zu beachten, die Effective Boolean Value Berechnung (Unterabschnitt 3.4.3) korrekt durchzuführen.

Beispiel Nemo-Code:

```
boolean_not(?a, ?b, NOT(?result)) :- inner(?a, ?b, ?result) .
```

²https://www.w3.org/TR/sparql11-query/#truthTable

Jede, auch zusammengesetzte, (Sub-) Expression wird, der Einfachheit halber, zu einem einzigen Prädikat übersetzt. Deswegen kann Not nicht durch ein simples zweistelliges Prädikat, welches die Warheitstabelle für Not ({(true, false), (false, true)}) repräsentiert ↗, dargestellt werden und die Abhängigkeiten der inneren Expression müssen "durchgereicht" werden.

Falls die innere Expression für eine Kombination von Eingaben einen Error ergibt, gibt es kein Tupel im *Ergebnis* ✓ des Prädikats und somit auch kein Tupel im *Ergebnis* ✓ des boolean_not Prädikats. Der Fehler wird somit korrekt propagiert.

3.4.6 In

Eine In Expression in SPARQL testet, ob das Ergebnis einer Expression gleich einem Ergebnis einer Expression aus einer gegebenen Liste von Expressions ist. Beispielsweise lässt FILTER(1+1 in (1, ?a, 3)) nur Ergebnisse mit ?a gleich 2 zu.

Eine In Expression ergibt genau dann Wahr (Wahr-Fall), wenn einer der Expressions aus der Liste das gleiche Ergebnis (kein Error) wie die separat gegebene Expression hat. Eine In Expression ist genau dann Falsch (Falsch-Fall), wenn alle Expressions aus der Liste ein anderes Ergebnis als die separat gegebene Expression und keinen Error liefern. Fehler können also ignoriert werden, wenn der Wahr-Fall dennoch zutrifft. Da nur mit Ergebnissen von Expressions gerechnet wird, welche immer definiert sind, muss der Fall undefinierter Variablen nicht berücksichtigt werden. Dies ist ein sehr ähnliches Verhalten wie bei And und Or (Unterabschnitt 3.4.4) und die Übersetzung findet ähnlich statt. Einziger Unterschied ist das And und Or in der SPARQL-Algebra nur eine linke und rechte Teilexpression haben, während In eine beliebige Anzahl an Teil-Expressions erlaubt. Dies stellt jedoch kein Problem dar, da die Nemo Template Language es erlaubt, Regeln innerhalb einer Rust-Schleife zu erzeugen (für Wahr-Fall) und auch mittels nemo_atoms! Makro (Unterabschnitt 2.2.4) Teile einer Regel in einer Rust-Schleife zu erzeugen. Konkret ist eine In Expression laut Standard äquivalent zur oder Verknüpfung von Tests, wobei jeder Test das Ergebnis der separat gegebenen Expression mit dem Ergebnis einer Expression aus der Liste vergleicht.

Im Folgenden ist eine komplette Übersetzung einer ASK-Query mit In Expression dargestellt.

```
Query:
ASK {
    FILTER(2 in (1, ?a, 3))
}
```

Nemo-Programm: (xsd Datentypen zur Lesbarkeit entfernt, int und boolean sind in Realität typisiert)

```
dummy(arity_zero) .
bgp(arity_zero) :- dummy(arity_zero) .
literal(2) .
literal_1(1).
literal_2(3).
in_expression(false)
:- bgp(arity_zero),
  literal(?RESULT),
  literal_1(?RESULT_1),
  always_error(?RESULT_2),
   literal_2(?RESULT_3),
   ?RESULT_1 != ?RESULT, ?RESULT_2 != ?RESULT, ?RESULT_3 != ?RESULT.
in_expression(true)
:- bgp(arity_zero), literal(?RESULT), literal_1(?RESULT) .
in_expression(true)
:- bgp(arity_zero), literal(?RESULT), always_error(?RESULT) .
in_expression(true)
:- bgp(arity_zero), literal(?RESULT), literal_2(?RESULT) .
filter(arity_zero) :- bgp(arity_zero), in_expression(true) .
dummy_1(0).
ask(true) :- filter(arity_zero) .
ask(false) :- dummy_1(0), \sim filter(arity_zero).
@output ask .
```

Zum Verständnis des Nemo Beispiel-Programms zunächst eine Wiederholung relevanter Informationen aus anderen Kapiteln: Im Code wird die Konstante arity_zero verwendet. Dieses wird von der Nemo Template Language generiert, wenn ein Parameter Template für einen konkreten Fall zu keinen Parametern führt. Führt ein Template zu keinem Regel-Körper Z, wird ein dummy Prädikat verwendet. (siehe Unterabschnitt 2.2.5 für weitere Informationen) "bgp" steht für Basic-Graph-Pattern und wird in Unterabschnitt 3.7.2 näher erläutert. Die Beispielquery enthält ein implizites leeres Basic-Graph-Pattern.

Die erste und dritte Regel von in_expression kommen nicht zum Tragen \(^{\alpha}\), da das always_error Prädikat in keinem Regel-Kopf \(^{\alpha}\) vorkommt, ebenfalls nicht die zweite und vierte Regel, weil 2 nicht gleich 1 bzw. 3 ist. Damit repräsentiert \(^{\alpha}\) in_expression und somit auch filter die leere Menge und die letzte Regel mit ask(false) kommt zum Tragen \(^{\alpha}\), was zum korrekten Ergebnis der Query führt: false.

Vor dem Hintergrund dieses Beispiels sind einige von SPARQL geforderten Eigenschaften zu erkennen:

- Eine In Expression mit leerer Liste ist gültig: Im Beispiel würde der Falsch-Fall bei leerer Liste zu in_expression(false) :- bgp(arity_zero), literal(?RESULT). Die in Expression evaluiert also zu false. Dies ist korrekt. Im Standard ist explizit das Beispiel 2 IN () ist false gegeben. Jedoch sollte die In Expression auch zu false evaluieren, wenn die Liste leer und die Expression selbst ein Error ist, was mit der derzeitigen Übersetzung nicht korrekt funktioniert.
- Zur Implementierung der Vergleiche ist eine strengere Form von Gleichheit in Nemo verwendet als im SPARQL Standard vorgesehen. Ein Beispiel aus dem Standard besagt 2 IN ("str", 2.0">http://example/iri>"str", 2.0) ist true. 2 matcht jedoch nicht 2.0 mit der verwendeten Form von Gleichheit in Nemo. (Näheres dazu in Unterabschnitt 3.4.10)

Außer der In Expression gibt es auch die Not In Expression. Diese ist äquivalent zu einer In Expression mit Negation. Eine Not In Expression wird bereits in spargebra zu einer In und Not Expression konvertiert und muss nicht separat berücksichtigt werden.

3.4.7 If

Eine If Expression hat drei Subexpressions:

- eine Condition-Expression, die auswählt, welche der anderen zwei Subexpressions zur Berechnung des Ergebnisses verwendet wird;
- eine Wahr-Expression, welche das Ergebnis liefert falls die Condition-Expression zutrifft;
- eine Falsch-Expression, welche das Ergebnis liefert falls die Condition-Expression nicht zutrifft.

eine

Die If Expression kann durch zwei Regeln in Nemo umgesetzt werden, eine Regel erzeugt die Ergebnisse für den Wahr-Fall und eine für den Falsch-Fall.

So sieht das Fragment der If-Expression für die Expression IF(?c, ?t, ?f) z.B. aus (xsd Präfix nachträglich eingeführt):

```
@prefix xsd: <http://www.w3.org/2001/XMLSchema#> .

if_expression(?c, ?t, ?f, ?RESULT)
:- bgp(?a, ?c, ?t, ?f),
   effective_boolean_value(?c, "true"^^xsd:boolean),
   var_1(?t, ?RESULT) .

if_expression(?c, ?t, ?f, ?RESULT)
:- bgp(?a, ?c, ?t, ?f),
   effective_boolean_value(?c, "false"^^xsd:boolean),
   var_2(?f, ?RESULT) .
```

Wie bei anderen Expressions *repräsentiert* [→] das bgp Prädikat die Variablen-Bindings und stellt sicher, dass die Regeln safe (Abschnitt 1.5) sind. Die If-Expression hängt nicht von der Variable ?a ab. Diese ist im konkreten Beispiel, dennoch Teil des Basic-Graph-Patterns. var_1 und var_2 sind die Prädikate der Subexpressions, im konkreten Beispiel ist der erste und zweite Parameter für sie immer identisch (siehe Unterabschnitt 3.4.1).

SPARQL gibt vor, dass die If-Expression einen Error ergibt, wenn die Condition-Expression einen Fehler verursacht. Eine Parameterkombination, welche einen Fehler bewirkt, ist nicht

im Ergebnis von effective_boolean_value (siehe Unterabschnitt 3.4.3) und somit kommt keine der beiden Regeln zum Tragen und das Ergebnis ist korrekterweise ein Error. Weiterhin gibt SPARQL vor, dass die Sub-Expression, die nicht für das Ergebnis benötigt wird, nicht berechnet wird. Die Übersetzung berechnet jedoch beide Expressions. Dies führt zu einem identischen Ergebnis, da die Berechnung keine Sideffects hat, vorausgesetzt ein Fehler in der nicht zu evaluierenden Sub-Expression, verursacht keinen Error im Ergebnis. Dies ist gegeben, da die entsprechende Regel ohnehin nicht zum Tragen keinen kommt.

3.4.8 Bound

Bound ist eine SPARQL Expression, die testet, ob eine Variable in einem Solution Mapping definiert ist, z.B. bound(?a) ist wahr, wenn ?a einen Wert hat. Nach dem in Abschnitt 3.1 beschriebenen Umgang mit Unbound-Werten muss zur Implementierung der Bound expression geprüft werden, ob der entsprechende Wert der UNDEF-Marker ist. In Nemo Template Language kann dies wie folgt aussehen:

```
nemo_def!(
    bound(nemo_var; @result: true) :- binding(??vars), ~unbound(nemo_var)
    ; SolutionExpression
);
nemo_add!(
    bound(nemo_var; @result: false) :- binding(??vars), unbound(nemo_var)
);
```

Das nemo_def! Makro erstellt ein neues Prädikat bound mit Regel für den Wahr-Fall und mit nemo_add! wird eine weitere Regel für den Falsch-Fall hinzugefügt (Makros werden in Unterabschnitt 2.2.4 beschrieben). binding stellt den Wert der Variable zur Verfügung. nemo_var ist die Nemo Template Language Variable zur SPARQL-Variable von welcher geprüft werden soll, ob sie an einen Wert gebunden ist. Das Ergebnis des unbound Prädikats enthält nur den UNDEF-Marker. Das unbound Prädikat repräsentiert den UNDEF-Marker. Der Wahr-Fall ergibt true für alle Werte, die nicht der UNDEF-Marker sind. Der Falsch-Fall ergibt falsch für den UNDEF-Marker. falls dieser für die Variable vorkommt.

Die zweite Regel wird mittels einer if-Bedinung in Rust nur generiert, falls die Variable nicht bereits als "immer gebunden" markiert ist (siehe Abschnitt 2.2 für automatisches Tracking von Eigenschaften). Ein weiterer Sonderfall stellt dar, wenn die Variable für die Bound getestet werden soll, nicht in den Stellen des binding Prädikats auftaucht. In diesem Fall wäre die erste Regel nicht safe (Abschnitt 1.5). Die Expression wird zu einem extra Prädikat never_bound, welches false *repräsentiert* ✓, übersetzt⁴. Bei Variablen-Expression in Unterabschnitt 3.4.1 gab es bereits ein ähnliches Vorgehen.

³Formal korrekt *repräsentiert* ✓ das Prädikat eine einelementige Menge mit einem ein-Tupel: {(x)} mit dem *UNDEF-Marker* ✓ x

⁴Formal korrekt repräsentiert / das Prädikat eine einelementige Menge mit einem ein-Tupel: {(false)}

3.4.9 Exists

Neben MINUS (Unterabschnitt 3.7.7) ist eine wesentliche Form von Negation in SPARQL FILTER NOT EXISTS. Beispielsweise findet folgende Query alle Dinge, die ein ex:a aber kein ex:b für die Eigenschaft ex:p haben:

```
prefix ex: <https://example.com/>
SELECT DISTINCT ?a {
    ?a ex:p ex:a
    FILTER NOT EXISTS {
        ?a ex:p ex:b
    }
}
```

Ähnlich wie bei "In" (Unterabschnitt 3.4.6) und "Not In" ist laut SPARQL Standard NOT EXISTS äquivalent zu EXISTS mit angeschlossener Negation. Die spargebra Bibliothek führt diese Substitution automatisch aus und kennt keine separate Algebra-Operation für NOT EXISTS, sondern nur eine für EXISTS. Es ist jedoch bekannt, dass allgemeine Negation in Datalog zu Problemen führen kann, weshalb Nemo stattdessen stratifizierte Negation unterstützt (Unterabschnitt 1.5.2). Die Schwierigkeit liegt jedoch nicht in der Not-Operation, welche durch einen einfachen Aufruf der NOT Funktion in Nemo übersetzt wird (Unterabschnitt 3.4.5), sondern im Fall, dass die EXISTS Expression das Ergebnis false liefert. Dieser Fall spielt jedoch in vielen Fällen, in denen EXISTS ohne NOT verwendet wird, keine Rolle. Bei einem Nemo-Programm, in dem eine SPAROL Query vorkommt, deren Eingabegraph zyklisch vom Ergebnis der Query abhängt (siehe Abschnitt 1.1) ist bei FILTER NOT EXISTS in der Query ein nicht stratifiziertes Programm, jedoch bei nur FILTER EXISTS nicht zwangsläufig ein nicht stratifiziertes Programm zu erwarten. Deswegen ist die Übersetzung von EXISTS, unterteilt in eine Funktion für den positiven Spezialfall translate_positive_exists() und eine allgemeine Funktion translate_exists() welche die translate_positive_exists() Funktion und stratifizierte Negation verwendet, um das Ergebnis für den Falsch-Fall zu vervollständigen. Die translate_exists() Funktion ist sehr einfach und kann hier komplett abgebildet werden:

```
fn translate_exists(
   &mut self, pattern_solution: &SolutionSet, binding: &dyn TypedPredicate
) -> Result<SolutionExpression, TranslateError>
    let partial_exists = self.translate_positive_exists(
        pattern_solution, binding
    )?;
    nemo_def!(
        exists(??vars; @result: true)
        :- partial_exists(??vars; @result: true)
        ; SolutionExpression
    );
    nemo_add!(
        exists(??vars; @result: false)
        :- binding(??vars, ??other), ~partial_exists(??vars; @result: true)
   Ok(exists)
}
```

Die Funktion nimmt neben dem üblichen self und binding Parameter die pattern_solution als Eingabe. Die pattern_solution ist ein Nemo Prädikat, welches das *Query-Ergebnis* des Exists-Pattern *repräsentiert* . Reihenfolge und Multiplizität ist jedoch für den Exists-Pattern nicht relevant. Deswegen ist die pattern_solution vom einfachen Typ SolutionSet, welcher keine besonderen Prädikatpositionen definiert (Abschnitt 2.3).

Die Funktion verwendet das partial_exists Prädikat, welches durch die Methode translate_positive_exists() erstellt wird und bereits das korrekte *Ergebnis repräsentiert*, wenn man sich auf Tupel mit true in als Ergebnis beschränkt. Alle Ergebnisse in partial_exists sind true. Die korrekten Wahr-Fall-Ergebnisse werden durch die erste Regel, im nemo_def Makro, einfach kopiert. Für den Falsch-Fall werden, unter Verwendung von stratifizierter Negation (Unterabschnitt 1.5.2), in der zweiten Regel im nemo_add! Makro, alle Eingaben mit dem Ergebnis false hinzugefügt, die nicht bereits durch die erste Regel mit true hinzugefügt wurden. Das VarSet ??other wird benötigt, um alle Variablen, die im binding vorkommen, von denen jedoch die EXISTS Expression nicht abhängt abzudecken. (siehe Unterabschnitt 2.2.1)

Die eigentliche Übersetzung in translate_positive_exists() gehört zu einer Kategorie von Funktionen, die ähnlich zu einem Join funktionieren. Sie wird in Unterabschnitt 3.7.3 vorgestellt und verglichen. Die Funktion ist durch das Behandeln von nicht gebundenen Variablen komplex. Die eigentliche Funktionsweise kann bereits hier an einem Beispiel ohne nicht gebundene Variablen nachvollzogen werden. Das Beispiel ist das Nemo-Programm von der Übersetzung der oben vorgestellten FILTER NOT EXISTS Query. Zur besseren Lesbarkeit wurde die Formatierung manuell angepasst und die Präfixe ex: und xsd: eingeführt und für true und false der xsd:boolean Type entfernt:

```
@prefix ex: <https://example.com/> .

bgp(?a) :- input_graph(?a, ex:p, ex:a) .
bgp_1(?a) :- input_graph(?a, ex:p, ex:b) .

partial_exists(?a, true) :- bgp(?a), bgp_1(?a) .

exists(?a, true) :- partial_exists(?a, true) .
exists(?a, false) :- bgp(?a), ~partial_exists(?a, true) .
boolean_not(?a, NOT(?b)) :- exists(?a, ?b) .

filter(?a) :- bgp(?a), boolean_not(?a, true) .
projection(?a) :- filter(?a) .
@output projection .
```

Man kann beobachten, dass EXISTS in diesem Beispiel im Wesentlichen durch den einfachen Join bgp(?a), bgp_1(?a) implementiert wurde. Es sei auf einige Punkte verwiesen, die beim Betrachten des Nemo-Programmbeispiels nicht offensichtlich sind: bgp steht für Basic-Graph-Pattern, was in Unterabschnitt 3.7.2 beschrieben wird. Der Ursprung des Variablen-Namen ?b scheint überraschend, dieser stammt explizit aus dem Nemo Template Language Template, da die Nemo Template Language keine implizit benannten Variablen in Funktionsaufrufen unterstützt (Unterabschnitt 2.2.4).

Die Unterscheidung, wann die translate_positive_exists() Funktion direkt genutzt wird, passiert in der translate_pattern() Funktion (Abschnitt 3.7). Dort gibt es einen Sonderfall für FILTER EXISTS, in allen anderen Fällen wird die generische translate_exists() Funktion verwendet.

Im SPARQL Standard wird das Verwenden von Variablen aus dem umgebenden Scope in der EXISTS Expression vollständig unterstützt. Dies ist eine wesentliche Abweichung vom SPARQL Standard bei der Übersetzung. Durch den grundlegenden Ansatz, dass die Operationen bottom-up nach der SPARQL-Algebra Darstellung bearbeitet werden, erfolgt die Übersetzung der EXISTS Expression und des umgebenden Scopes unabhängig. So führt beispielsweise ein Test Bound(?x) innerhalb eines EXISTS Filters zum nicht konformen Ergebnis false, wenn ?x nur im umgebenden Scope gebunden wird. Dieses Problem wird in Kapitel 5 aufgegriffen.

3.4.10 Vergleichsoperatoren

SPARQL erlaubt es, Werte mit Vergleichsoperatoren wie Größer-Als, ">", oder Ungleich, "!=", zu vergleichen. Nemo behandelt unterschiedliche Typen auf unterschiedliche Weise, was einer kurzen Übersetzung entgegenwirkt. Die Übersetzung der Vergleichsoperatoren umfasst über 150 Zeilen. Die Implementierung lässt sich in drei Teile untergliedern:

- eine Hilfsfunktion translate_comparison(), die, mittels Nemo Template Language, Nemo Code generiert, in den als Parameter gegebene Nemo Template Language Fragmente eingearbeitet werden;
- eine spezielle Funktion translate_equal(), die einen = Vergleich aus SPARQL übersetzt:
- ein Match-Statement in Rust, welches für die jeweiligen Elemente der Expression-Enumeration aus spargebra mittels der Hilfsfunktionen die korrekte Operation durchführt

Die grundlegende Herangehensweise ist es, für jeden Typen eine Regel für den Falsch-Fall und eine für den Wahr-Fall zu generieren. Die finale Übersetzung muss dann immer alle Regeln beinhalten, da mögliche Einschränkungen des Typs zur Übersetzungszeit nicht bekannt sind.

Die translate_comparison() Funktion unterstützt die Typen Numeric, Boolean, String und keine Vergleiche für zwei unterschiedliche dieser drei Typen. Damit ist die Funktion fast standardkonform, da der Standard nur zusätzlich mindestens Unterstützung für Date-Time fordert. Da jedoch Nemo diesen Typ nicht unterstützt, wurde auf dessen Implementierung hier verzichtet. Eine Implementierung sehr ähnlich zu der in Unterunterabschnitt 3.4.13.3 vorgestellten ist jedoch denkbar.

Numerische Vergleiche werden direkt zu Vergleichsoperatoren in Nemo übersetzt. Boolean Werte werden zunächst mit der in Nemo verfügbaren INT Funktion zu integer konvertiert und dann mit denselben Vergleichsoperatoren wie numerische Werte verglichen. Die Funktion nimmt dafür die Parameter true_op und false_op. Strings werden mit der COMPARE Funktion in Nemo verglichen und das Ergebnis mit einem gegebenen Wert str_compare verglichen. Bei Gleichheit ist das Ergebnis des Vergleiches insgesamt str_compare_for (also true bzw. false), bei Ungleichheit das Gegenteil von str_compare_for. Folgende Tabelle zeigt alle 4 Parameter für die jeweiligen SPARQL Operatoren:

SPARQL op	true_op	false_op	str_compare	str_compare_for
Greater	>	<=	1	true
GreaterOrEqual	>=	<	-1	false
Less	<	>=	-1	true
LessOrEqual	<=	>	1	false

Hier folgt ein Beispiel, zu welchen Operationen ein Größer-Als-Vergleich (Greater) von ?x und ?y aus SPARQL übersetzt wird:

Nemo Expression	Expression für
?x > ?y	true
?x <= ?y	false
INT(?x) > INT(?y) and datatypes are xsd:boolean	true
<pre>INT(?x) <= INT(?y) and datatypes are xsd:boolean</pre>	false
COMPARE(?x, ?y) = 1	true, da str_compare_for true ist
COMPARE(?x, ?y) != 1	<pre>false (= not str_compare_for)</pre>

Es ist wichtig, dass die Regeln für Boolean-Werte den Typ prüfen, da sonst Fälle eintreten können, in denen der Vergleich sowohl true als auch false ergibt. Beispielsweise führt COMPARE("3", "12") = 1 zu true, aber INT("3") <= INT("12") zu false. Die anderen Regeln ergeben ohnehin einen Fehler bei falschem Typ.

Die Gleichheitsoperation "=" aus SPARQL, wird für alle nicht numerischen Typen direkt zur Gleichheitsoperation "=", bzw. "! =" im Falsch-Fall, in Nemo übersetzt. Diese Operation beachtet jedoch in Nemo keine Typkonvertierungen, wie dies bei den anderen Vergleichsoperatoren der Fall ist. Deswegen wird Gleichheit von ?x und ?y für numerische Typen wie folgt übersetzt:

- Wahr-Fall: Eine Regel, die sowohl ?x >= ?y als auch ?x <= ?y prüft
- Falsch-Fall: Zwei Regeln, entweder ?x < ?y oder ?x > ?y

SameTerm in SPARQL ist eine weitere Gleichheitsoperation. Diese wird mit fullStr(?x) = fullStr(?y) für den Wahr-Fall bzw.fullStr(?x) != fullStr(?y) für den Falsch-Fall übersetzt.

Der Ungleich-Operator wird bereits von spargebra zu einem Gleichheitsoperator und Negation transformiert und hat keine eigene Implementierung.

Es ist anzumerken, dass die hier vorgestellte Übersetzung dennoch keine SPARQL konforme Implementierung ergibt, z.B. werden in Nemo Werte normalisiert, was dazu führt, dass unterschiedliche Werte als gleich befunden werden. Auch beachtet die Typkonvertierung von numerischen Werten in Nemo nicht die im SPARQL Standard vorgeschriebenen "numeric type promotion" und "subtype substitution" Regeln, sondern vergleicht unterschiedliche Typen, indem beide Werte zunächst zu Double konvertiert werden. Das schwerwiegendste Problem stellt jedoch dar, dass Nemo in der verwendeten Version keine Werte vom Typ xsd:decimal vergleichen kann und dies der Standardtyp ist, wenn in SPARQL eine Zahl mit Komma, wie z.B. 0.9, ohne expliziten Typ verwendet wird. Zwar wäre eine automatische Konvertierung von decimal-Werten in der Literal-Implementierung (Unterabschnitt 3.4.2) möglich, jedoch ist es sicher nicht komplex, den decimal-Typ in Nemo zu unterstützen.

3.4.11 Coalesce

Die COALESCE-Expression in SPARQL ergibt das erste Ergebnis aus einer Liste von Expressions, welches kein Error ist. COALESCE(1/0, 2, 3) ergibt beispielsweise 2. Dieses Beispiel wird hier ergänzt um Prädikate für bereits übersetzte Subexpressions. Jede der drei Subexpressions wird im Beispiel in ein einstelliges Prädikat übersetzt. 1/0 wird zum Prädikat

op übersetzt (siehe Unterabschnitt 3.4.12). Da die Division einen Fehler ergibt, *repräsentiert* ✓ op die leere Menge (siehe Abschnitt 3.2 für den Umgang mit Fehlern). literal_2 und literal_3 *repräsentieren* ✓ jeweils 2 bzw. 3⁵. Folgendes ist eine initiale Implementierung, welche die drei Ergebnisse zusammenführt:

```
coalesce(?RESULT) :- op(?RESULT) .
coalesce(?RESULT) :- literal_2(?RESULT) .
coalesce(?RESULT) :- literal_3(?RESULT) .
```

Da die Reihenfolge der Parameter nicht egal ist, lässt sich COALESCE nicht durch gleichförmige Regeln für jeden Parameter, wie in dieser initialen Implementierung, übersetzen. Die tatsächliche Implementierung fügt jeder Regel noch eine Bedingung hinzu, dass keine der vorherigen Expressions bereits ein Nicht-Error-Ergebnis geliefert hat:

Damit hat nur die Regel, welche als erstes keinen Error verursacht (im Beispiel die zweite), einen Effekt auf das Ergebnis. Alle vorherigen Regeln (im Beispiel die erste) evaluieren definitionsgemäß zu einem Error und beeinflussen somit nicht das Ergebnis. Alle späteren Regeln enthalten das Prädikat der relevanten Regel in negierter Form und haben somit keinen Einfluss auf das Ergebnis. Wenn alle Expressions einen Error verursachen, kommt keine Regel zum Tragen und das Ergebnis ist ein Error.

Wie bei vorherigen Expression-Übersetzungen werden die Variablen-Bindings, das Prädikat bgp im Beispiel, benötigt, damit alle Regeln safe (Abschnitt 1.5) sind, auch wenn Subsexpressions von unterschiedlichen Variablen abhängen.

Die Implementierung generiert die Regeln mittels eines for-Loops in Rust. Die negierten Atome werden mittels des nemo_atoms! Makro (Unterabschnitt 2.2.4) in jeder Iteration akkumuliert.

Es ist anzumerken, dass eine so übersetzte COALESCE-Expression ein nicht stratifiziertes Nemo-Programm bewirkt, wenn der Eingabegraph vom Ergebnis der Query abhängt. Es gelten die allgemeinen Überlegungen zum Darstellen von Fehlern durch fehlende Tupel (Abschnitt 3.2).

3.4.12 Arithmetische Operatoren

Arithmetische Operatoren in SPARQL (Add, Subtract, Multiply und Divide) werden direkt zu den jeweiligen Operatoren in Nemo übersetzt. Unäre Operatoren (UnaryMinus und UnaryPlus) werden übersetzt wie Subtraktion von bzw. Addition zu 0.

⁵Formal die einelementige Menge aus dem ein-Tupel der Zahl, z.B. {(2)}.

Die Implementierung ist sehr einfach und kann deswegen, hier als weiteres Beispiel, wie eine SPARQL-Feature-Implementierung aussieht, abgebildet werden:

```
fn translate_binary_operator(
    &mut self,
    1: Binding,
    r: Binding,
    result: Binding,
    left_solution: &SolutionExpression,
    right_solution: &SolutionExpression,
    binding: &dyn TypedPredicate
) -> Result<SolutionExpression, TranslateError>
   nemo_def!(
        op(??vars, ??left, ??right; @result: result) :-
            binding(??vars, ??left, ??right, ??other),
            left_solution(??vars, ??left; @result: 1),
            right_solution(??vars, ??right; @result: r)
            ; SolutionExpression
    );
   0k(op)
}
```

Die Funktion translate_binary_operator() übersetzt einen beliebigen binären Operator. Der eigentliche Operator wird, wie unten gezeigt, als result Parameter in Form eines Nemo Template Language Fragmentes der Funktion übergeben. Die beiden Werte für die Berechnung kommen vom Ergebnis der linken bzw. rechten Subexpression (left_solution bzw. right_solution Prädikat). Die tatsächlichen Variablen dafür werden als Parameter übergeben, damit diese sowohl bei der Operation als auch im result Parameter verwendet werden. (siehe Unterabschnitt 2.2.1 für mehr Information zu den mit ?? beginnenden Variablen Sets im Code-Beispiel). Wie die Funktion aufgerufen wird, wird hier am Beispiel von Addition gezeigt:

Das Code-Fragment ist ein Ausschnitt aus der Rust Match-Expression, welches sich in der translate_expression() Funktion (siehe Abschnitt 3.4) befindet. Zunächst werden die Subexpressions übersetzt. Dann werden neue Variablen für linkes und rechtes Ergebnis erzeugt. Schließlich wird die translate_binary_operator() Funktion aufgerufen. Die eigentliche Operation wird durch 1 + r definiert. Die Nemo Template Language beinhaltet Überladungen für arithmetische Operatoren. (siehe Unterabschnitt 2.2.3)

Ein Fehler in einer Subexpression bewirkt das Fehlen der Parameterkombination im jeweiligen *Ergebnis* [→] des Prädikats, zu welchem die Subexpression übersetzt wird. Dadurch gibt es

auch diese Parameterkombination nicht im Ergebnis der Operation, was gleichbedeutend mit einem Error ist. Das bedeutet Errors propagieren korrekt.

Es ist anzumerken, dass es Unterschiede beim Umgang mit unterschiedlichen Typen bei den Operatoren in Nemo gegenüber SPARQL gibt (siehe Unterabschnitt 3.4.10). Damit sind die Operatoren nicht standardkonform. Besonders gravierend sind:

- limitierte Unterstützung für xsd:decimal (dieser ist der Standardtyp in SPARQL; die FLOAT Funktion in Nemo unterstützt diesen Typ bereits und es gibt in der verwendeten Version automatische Konvertierung für Integer vom Typ xsd:decimal)
- nicht standardkonformer Rückgabetyp. Insbesondere 9 / 10 ergibt 0, obwohl explizit im SPARQL Standard über den Rückgabetyp der Division gesagt wird "xsd:decimal if both operands are xsd:integer"

3.4.13 Funktionen

Das Ziel von Nemo ist es, die SPARQL Funktionen direkt zu unterstützen. In der verwendeten Nemo Version ist dies jedoch noch nicht vollständig der Fall. Einige nicht in Nemo unterstützte Funktionen können mithilfe anderer Funktionen implementiert werden, für einige wurde dies im Rahmen dieser Arbeit umgesetzt. Insbesondere hat Nemo in der verwendeten Version keine Unterstützung für Datum und Uhrzeit, es konnten jedoch einige derartige Funktionen durch String Manipulationsfunktionen übersetzt werden.

3.4.13.1 Direkt unterstützte Funktionen

Die meisten Funktionen in SPARQL werden direkt mit einer Funktion in Nemo übersetzt. Die eigentliche Übersetzung erfolgt dabei mithilfe der function() Methode des QueryTranslator Objektes:

```
fn function(
   &mut self,
    expressions: & Vec < Solution Expression > ,
   binding: &dyn TypedPredicate,
    func: &str
) -> Result<SolutionExpression, TranslateError>
    let call = Call::new(
        func,
        nemo_terms!(expressions => SolutionExpression::result_var).bindings()
    );
    nemo_def!(
        solution(
            nemo_terms!(expressions => SolutionExpression::depend_vars, call)
        ) :- {expressions}, {binding}
        ; SolutionExpression
        ; &func.to_lowercase()
   Ok(solution)
}
```

Die Funktion nimmt als Eingabe neben den bisher bekannten Parametern self und binding, die Nemo Funktion als &str und die Parameter, mit denen diese aufgerufen werden soll, als Liste von SolutionExpression Prädikaten, welche das Ergebnis der Übersetzung der Subexpresions sind.

Die function() Funktion erstellt zunächst einen neuen Funktionsaufruf, welcher als Parameter die Ergebnisvariablen der übergebenen Parameter Expressions bekommt. Diese werden unter Verwendung der Mappingsyntax des nemo_terms! Makros (Unterabschnitt 2.2.4) extrahiert. Diese Syntax wird auch innerhalb der Nemo Template Language Regel verwendet.

Es ist anzumerken, dass das nemo_terms! Makro Duplikate Variablen automatisch entfernt, jedoch die Reihenfolge beibehält, wodurch der einzige Funktionsaufruf call in der letzten result Position des SolutionExpression Prädikats bleibt.

Die depend_vars() Funktion der SolutionExpression-Klasse gibt bei gegebenem Prädikat alle Variablen, die nicht die result_var sind, zurück. Somit hat ein Funktionsaufruf alle Abhängigkeiten, die in einer der Subexpressions vorkommen. Wie bereits in anderen Expression-Übersetzungen besteht der *Regel-Körper* aus den Prädikaten für die Parameter und den Variablen-Bindings, welche die Parameter limitieren, für welche die Funktion berechnet wird.

Die Nemo Template Language Syntax erlaubt es optional, nach dem zweiten Semikolon dem erzeugen Prädikat einen dynamischen Default-Namen zu geben. Dadurch hat das zurückgegebene Prädikat nicht den Namen "solution", sondern den Namen der Nemo Funktion.

Die korrekte Anzahl der Parameter muss nicht getestet werden, da dies bereits von spargebra validiert wird.

Der Funktionsaufruf CONCAT(?a, ?x) in SPARQL kann beispielsweise wie folgt übersetzt werden:

```
concat(?a, ?x, CONCAT(?RESULT, ?RESULT_1))
:- var(?a, ?RESULT), var_1(?x, ?RESULT_1), bgp(?a, ?x) .
```

Dabei sind var und var_1 die Resultate der Übersetzung der Subexpressions für die Variablen ?a bzw. ?x und bgp *repräsentiert* ✓ die aktuellen Variablen-Bindings, wie dies bereits in Abschnitt 3.4 erläutert ist.

Im Folgenden ist die Liste der direkt übersetzten Funktionen dargestellt:

Categorie	Namen
General-puropse	DATATYPE, STR
Strings	STRLEN, UCASE, LCASE, CONCAT, LANG, REGEX
String tests	STRSTARTS, STRENDS, CONTAINS, STRBEFORE, STRAFTER
numbers	ABS, ROUND, CEIL, FLOOR
tests	islri, isNumeric, isBlank

Folgende Kommentare sind zu diesen Funktionen in der Liste erwähnenswert:

- Der SPARQL 1.1 Standard hat konkrete Regeln für die Verwendung von Plain-String, xsd:string und Language-Taged-String in einer konkreten Situation. Diese werden in Nemo grundsätzlich nicht berücksichtigt. Dies stellt keine größere Nicht-Konformität dar, da das Verhalten in SPARQL 1.2 bereits stark vereinfacht wurde. Ein größere Nicht-Konformität stellt jedoch mangelnde Implementierung für Funktionen auf Languagetagged-Strings dar. So ergibt beispielsweise CONCAT("a"@de, "b"@de) einen Error in Nemo.
- Die REGEX Funktion in Nemo verwendet eine Rust-Bibliothek, welche sich auf Effizienz konzentriert und deutlich weniger Features unterstützt als der in SPARQL verwendete Regex-Syntax. Außerdem werden keine Regex-Flags unterstützt.
- Die Ergebnisse einiger String-Funktionen hängen von der Definition eines characters ab. Die Länge des "technologist emoji" hat beispielsweise die Länge 1 in Nemo, in Blazegraph⁶ die Länge 5 und in Virtuoso⁷ die Länge 3. Der anzuwendende Standard ist dabei ISO/IEC 10646⁸ (laut dem in SPARQL referenzierten xpath-Standard⁹) und die korrekte Antwort 3: ein Person-Emoji, ein Zero-Width-Joiner und ein Laptop-Emoji.
- Die Funktionen UCASE und LCASE sind vertauscht in der verwendeten Version von Nemo.
- LANG() ergibt keinen leeren String für Plain-Strings.
- ROUND() rundet in die falsche Richtung für negative Werte, welche auf ".5" enden.
- isBlank() ist die isNull() Funktion in Nemo.

3.4.13.2 Abgeleitete Funktionen

Einige SPARQL Funktionen werden unterstützt, obwohl sie nicht direkt in Nemo zur Verfügung stehen:

- Die BNode () Funktion Variante ohne Parameter erzeugt einen neuen BNode. Diese wird mittels einer existentiellen Regel ohne Regel-Körper

 übersetzt. Dies ist unterschiedlich von einem Fakt und wird von der Nemo Template Language unterstützt. Fakten in Nemo können keine existentiell quantifizierten Variablen enthalten. Im SPARQL Standard wird nicht offensichtlich definiert, wie oft diese Funktion evaluiert wird. Eine einmalige Evaluierung ist konsistent mit anderen SPARQL Implementierungen, z.B. Blazegraph.
- Die SUBSTR() Funktion wird mittels der SUBSTR() und SUBSTRING() Funktionen, je nachdem, ob zwei bzw. drei Parameter übergeben wurden, übersetzt. Beide Funktionen sind in Nemo für die die Edge-Cases nicht Standardkonform. Zur Implementierung wird die function() Methode (Unterunterabschnitt 3.4.13.1) mit dem jeweils korrekten func Parameter aufgerufen.
- Die Funktion isLiteral() wird durch NOT(OR(isIri(?x), isNull(?x))) für gegebenen Parameter ?x implementiert. Jeder Funktionsaufruf wird dabei einzeln mit der function() Methode (Unterunterabschnitt 3.4.13.1) übersetzt.
- Einige Datumsfunktionen werden mittels anderer Nemo Funktionen übersetzt. (siehe Unterunterabschnitt 3.4.13.3)

⁶In dieser Arbeit wurde Blazegraph 2.1.6 verwendet.

⁷In dieser Arbeit wurde Virtuoso 07.20 verwendet.

⁸https://www.iso.org/standard/76835.html

⁹https://www.w3.org/TR/xpath-functions/#func-string-length

3.4.13.3 Datums Funktionen

Einige Date-Time-Expressions in SPARQL dienen dazu, eine Komponente eines Date-Time-Literals zu extrahieren. Keine dieser Funktionen werden in der verwendeten Version von Nemo direkt unterstützt. Da jedoch der xsd:dateTime Type ein recht festen lexical space hat, sind einige davon ohne große Probleme mithilfe anderer Nemo Funktionen zu übersetzen.

Der lexical space von xsd:dateTime ist im Standard definiert als:

Danach kann man einen Date-Time-Wert als ein T in der Mitte sehen, wobei Zahlen vor dem T mittels - getrennt und nach dem T mittels : getrennt sind. Außerdem gibt es zusätzlich die Zeitzone, deren Format separat beschrieben ist: (('+' | '-') hh ':' mm) | 'Z'. Es ist zu erkennen, dass die Zeitzone immer mit +, - oder Z beginnt.

Folgende Date-Time-Funktionen werden bei der Übersetzung unterstützt:

is_time	offset
false	2
false	1
false	0
true	0
true	1
true	2
	false false false true true

Dabei gibt is_time an, ob sich der Wert vor oder hinter dem T befindet und offset ist der Index beginnend bei O neben T.

Basierend auf is_time kann mittels STRBEFORE() oder STRAFTER() der korrekte Teil extrahiert werden. Um das n-te Element im String zu finden, wird n – 1 mal die STRAFTER() Funktion mit dem korrekten Separator angewendet und danach die STRBEFORE() Funktion mit dem gleichen Separator, um den restlichen String zu entfernen. Die STRBEFORE() Funktion wird nur angewendet, wenn es sich nicht um das letzte Element (offset = 2) handelt. Da für is_time = false der Index, um negative Daten zu unterstützen, von hinten beginnt, wird vor und nach dem Finden des n-ten Elements die STRREV() Funktion angewandt, um den String zu drehen. Zum Schluss wird der Zahl-String mit der INT() Funktion zu einem Integer konvertiert. Eine Ausnahme stellt die SECONDS() Funktion dar. Hier wird das Ergebnis zu DOUBLE() konvertiert und die Zeitzone entfernt, in dem alles nach +, - oder Z entfernt wird. Um alles nach einem bestimmten Symbol zu entfernen, kann mittels CONCAT() das entsprechende Symbol angehängt werden und sich anschließend mittels STRBEFORE() auf den String bis zum ersten Auftauchen des entsprechenden Symbols beschränkt werden.

Die tatsächliche Übersetzung findet in der date_function() Funktion statt, diese umfasst 40 Zeilen inklusive einem Match-Statement, welches aus der übergebenen spargebra Funktion die is_time und offset Parameter bestimmt. Die Implementierung verwendet das nemo_call! Makro (Unterabschnitt 2.2.4) umfangreich.

Im Folgenden als Beispiel eine Übersetzung der Month Funktion:

var ist das Prädikat der Subexpression. Es ist hier nicht nötig, die Variablen-Bindings extra im *Regel-Körper* [▶] zu haben, da die Datefunktionen nur von einer Subexpression, dem Datum, abhängen. Es ist nötig, den Datentyp zu prüfen, da sonst die Funktion auch auf einigen speziell formatierten String funktionieren würde.

Einzig bekannter Unterschied der Implementierung zum SPARQL Standard ist der Rückgabetyp der SECONDS() Funktion, welcher im Standard xsd:decimal ist, jedoch bei der Implementierung absichtlich xsd:double, da Nemo xsd:decimal nicht umfangreich unterstützt.

3.4.13.4 Nicht unterstützte Funktionen

Einige Funktionen, die der SPARQL Standard fordert, werden nicht von der Übersetzung unterstützt:

Kategorie	Funktionen	Kommentar
String	LangMatches, Replace	wären unter Umständen nichttrivial in Nemo zu implementieren
Erzeugung	Iri, StrLang, StrDt, BNode mit Argumenten	sind fundamental unmöglich, mit bestehenden Funktionen zu implementieren
Random	Rand, Uuid, StrUuid	innerhalb einer Query Übersetzung ist globales State-Management für Rand theoretisch mit bestehenden Mitteln möglich
Datum	Timezone, Tz, Now	für Tz ist Implementierung mit bestehenden Funktionen möglich
Hashing	Md5, Sha1, Sha256, Sha384, Sha512	ist vermutlich leicht in Nemo zu implementieren
Sonstiges	EncodeForUri	ist leicht in Nemo zu implementieren

Bist auf LangMatches() und Replace() sind alle Funktionen sicherlich sehr einfach in Nemo zu implementieren und auch Replace ist kein Problem, wenn man sich mit dem reduzierten Regex-Feature-Set wie bei der bestehenden Implementierung der REGEX() Funktion zufrieden gibt.

Mit den Funktionen aus der Kategorie "Erzeugung" lässt sich theoretisch der komplette SPARQL Standard in Nemo abbilden, da Nemo Turing-Complete ist und jede Operation auf Strings durchführen kann. Ohne diese Funktionen ist es jedoch bei dem vorgegebenen Ausgabeformat eines Nemo Prädikats, welches das SPARQL *Query-Ergebnis* ** repräsentiert **, unmöglich, den kompletten SPARQL Standard in Nemo zu übersetzen.

3.4.13.5 SPARQL Erweiterung für weitere von Nemo unterstützte Funktionen

Nemo unterstützt einige Funktionen, die nicht direkt Teil des SPARQL Standards sind. Diese müssten nicht in dieser Arbeit berücksichtigt werden. Es ist dennoch in der Praxis hilfreich, einige davon zu unterstützen und eine entsprechende Implementierung ist mit der bestehenden function() Methode aus Unterunterabschnitt 3.4.13.1 möglich. SPARQL erlaubt dafür Extensions durch Custom-Funktionen, welche durch eine IRI gegeben werden. Folgende Custom-Funktionen werden bei der Übersetzung unterstützt:

Funktion	Nemo Funktion
math:sqrt() math:sin() math:cos() math:tan() math:pow() fn:sum() fn:min() fn:max()	SQRT SIN COS TAN POW SUM MIN MAX

Präfix math: http://www.w3.org/2005/xpath-functions/math# Präfix fn: https://www.w3.org/2005/xpath-functions#

Für die restlichen Funktionen wurde keine offensichtliche IRI gefunden. Insbesondere ist math:log(), welche den natürlichen Logarithmus berechnet, nicht äquivalent zur 'LOG()' Funktion in Nemo.

3.5 Property Paths

In SPARQL kann eine Einschränkung von einem "Start-Knoten" und einem "End-Knoten" (Knoten eines Graphs definiert in Abschnitt 1.3) durch eine Property Path Expression gegeben werden. Für jedes Ergebnis der Query muss der Pfad zwischen Start- und End-Knoten die Property Path Expression erfüllen. Ein Pfad ist eine Sequenz von Kanten, wobei die Objekt-Position der vorhergehenden Kante mit der Subjekt-Position der darauffolgenden Kante übereinstimmen muss. Die Property Path Expression definiert eine Einschränkung der Prädikate entlang der Sequenz durch einen regulären Ausdruck. Das Alphabet der regulären Sprache sind im Graph mögliche Prädikate und deren inverse Relation. Dadurch werden spezielle Features für Pfade in einem Graphen unterstützt, wie beispielsweise das

"Überqueren" einer Kante von Object zu Subject Position statt wie sonst von Subject zu Object Position.

In Datalog lässt sich das Ergebnis einer Property Path (Teil-)Expression durch ein Prädikat darstellen, welches die Menge aller Knotenpaare aus Start- und End-Knoten repräsentiert /, welche die Property Path Expression erfüllen. Da die resultierenden Prädikate immer zweistellig sind, kann auf die Definition von eigenem Prädikattypen der Nemo Template Language verzichtet werden. Es werden einfache Prädikate vom Typ SolutionSet verwendet, wobei die erste Position der Start-Knoten und die zweite Position der End-Knoten ist.

Die Implementierung geschieht in der translate_path Methode der QueryTranslator Klasse:

```
fn translate_path(
    &mut self, start: Binding, path: &PropertyPathExpression, end: Binding
) -> Result<SolutionSet, TranslateError>
```

Dabei ist start und end der Start bzw. Endpunkt des Pfades vom in der Nemo Template Language definierten Typ Binding, welcher sowohl Konstanten als auch Variablen darstellen kann. path ist die zu übersetzende PropertyPathExpression aus der Transformation zu SPARQL-Algebra mittels der spargebra Bibliothek. Das Ergebnis ist ein zweistelliges Prädikat vom Typ SolutionSet. Die Implementierung besteht aus einer Fallunterscheidung nach dem Typ der PropertyPathExpression. Hat dieser Subexpressions, werden diese zunächst rekursiv mit der translate_path Funktion übersetzt.

3.5.1 OneOrMore

Ein Feature in Property Path Expressions ist der OneOrMore Pfad, dargestellt durch ein Suffix +. Beispielsweise kann folgende Query genutzt werden, um alle Subklassen der Klasse ex:cat anzufragen inklusive Subklassen von Subklassen:

```
SELECT ?type
WHERE {
    ex:cat ex:has_subclass+ ?type .
}
```

Die Klasse ex:cat selbst ist dabei nicht im Ergebnis, was den Unterschied zu einem ZeroOrMore Pfad ausmacht.

In Nemo lässt sich das Verhalten durch eine rekursive Regel übersetzen. Das Prädikat inner repräsentiert ✓ im Beispiel das, wie in Abschnitt 3.5 definierte, Ergebnis der inneren Property Path Expression:

```
recursive(ex:cat, ?next) :- inner(ex:cat, ?next) .
recursive(ex:cat, ?next) :- recursive(ex:cat, ?mid), inner(?mid, ?next) .
```

Da der Anfang des Pfades im Beispiel eine bekannte Konstante ist, ist der erste Parameter die konstante ex: cat. Dennoch muss der innere Pfad auch für andere Startknoten berechnet werden.

Der Start- und End-Knoten können jeweils eine Variable oder Konstante sein. Diese vier Möglichkeiten werden einzeln im SPARQL Standard betrachtet. Die Implementierung im Beispiel funktioniert ähnlich, wenn statt der Konstanten ex:cat der Anfang des Pfades eine

Variable ist. Damit die Implementierung auch für zwei Konstanten funktioniert, wird in der tatsächlichen Implementierung noch eine weitere Regel verwendet:

```
nemo_def!(
    one_or_more_path(start, end) :- recursive(start, end)
    ; SolutionSet
);
```

Dabei ist start und end die Start- bzw. End-Konstante. Für den Fall, dass der End-Knoten eine Konstante und der Startknoten keine Konstante ist, gibt es eine zweite, symmetrische Implementierung, bei der in allen Regeln die erste und zweite Position der Prädikate vertauscht sind.

3.5.2 Pfade der Länge null

Ein Pfad der Länge null bedeutet, dass der Pfad im selben Knoten endet, wie er anfängt. Im SPARQL Standard werden unterschiedliche Fälle betrachtet, je nachdem, ob Anfang und Ende Konstanten oder Variablen sind. Die Implementierung findet in der zero_path_extend Methode statt. Diese nimmt den Start, das Ende und das Prädikat path, welches bisher das Ergebnis der Übersetzung der Property Path Expression ist, als Parameter und fügt Regeln hinzu, damit das Prädikat auch Pfade der Länge null berücksichtigt.

Der Einsatz von Berechnung mit Optional in Rust ermöglicht es in der Implementierung, die beiden Fälle, in denen genau eins der beiden Pfadenden eine Konstante ist, gleichzeitig abzudecken. Es wird ein einfacher Fakt nemo_add!(path(c, c)); hinzugefügt, wobei c die Konstante am Ende des Pfades ist.

Im Falle, dass der Pfad in einer Variablen beginnt und endet, kann zu jedem Knoten ein Pfad der Länge null, welcher bei diesem beginnt und endet, gesehen werden. Im SPARQL Standard wird dafür die Funktion nodes $(G) = \{ n \mid n \text{ is an RDF term that is used as a subject or object of a triple of G} definiert. Bemerkenswerte ist dabei, dass nur Knoten, die als Subjekt oder Objekt vorkommen, beachtet werden. In der Nemo Template Language lässt sich dies wie folgt abbilden:$

```
nemo_add!(path(?s, ?s) :- input_graph(?s, ?p, ?o));
nemo_add!(path(?o, ?o) :- input_graph(?s, ?p, ?o));
```

Der letzte Fall tritt ein, wenn Start und Ende beide Konstanten sind. Dieser Fall kann wie folgt implementiert werden, wobei start und ende die entsprechenden Konstanten sind:

```
nemo_def!(start_c(start));
nemo_def!(end_c(end));
nemo_add!(path(?c, ?c) :- start_c(?c), end_c(?c));
```

Diese Implementierung führt den Vergleich auf Gleichheit durch Verwendung gleicher Variablen in Nemo durch. Dies schafft Konsistenz, da die gleiche Form von Gleichheit auch in der Übersetzung von Basic Graph Patterns verwendet wird. Dies ist besonders relevant da in SPARQL manche Property Path expressions equivalent zu einem Basic Graph Pattern sind und diese Transformation von der spargebra Bibliothek automatisch vorgenommen wird.

Hierzu ein kleiner Ausblick in die Edge-Cases von SPARQL. Es ist im SPARQL Standard unklar, welche Form von Gleichheit in diesem Spezialfall zu verwenden ist. Es wird ohne weiteren Kommentar der mathematische Ausdruck "X = Y" verwendet. In der Praxis ist interessant, in welchen Fällen ein literal überhaupt der Anfang und Ende eines Pfades sein kann, denn

Literale sind sind in RDF nicht in Subjektposition erlaubt. Ein Beispiel, indem die Query auf einem leeren Graph ausgeführt wird:

```
SELECT DISTINCT (1 as ?out)
{1.0 (^<https://example.com/backward> / <https://example.com/forward>)? 1}
```

Empirisch ergibt die Query in Virtuoso einen Fehler, und in rdflib und Blazegraph sind 1.0 und 1 als unterschiedlich angesehen. Allerdings sind "01"^^xsd:integer und "1"^^xsd:integer unterschiedlich in rdflib und gleich in Blazegraph. Das bedeutet, die Implementierung in Nemo ist in dieser Hinsicht Blazegraph ähnlich. Weiter untersuchen lassen sich BNodes. Der gleiche BNode _ : 1 wird bei der Implementierung in Nemo als gleich angesehen, nicht aber für diesen speziellen Fall in rdflib und Blazegraph. Virtuoso wirft einen Fehler "BNode not allowed in subject of transitive path". Noch interessanter wird es, wenn ein BNode mit gleicher ID in einem Basic-Graph-Pattern und einer Property-Path-Expression vorkommt. An sich ist der Scope der BNodes durch die Join Operation der SPARQL-Algebra, in diesem Fall für Property Path Expression und Basic Graph Pattern unterschiedlich, jedoch nicht bei Property Path Expressions, welche äquivalent zu einem Basic Graph Pattern sind. Die spargebra Bibliothek fängt diesen Sonderfall ab und wirft einen hilfreichen Fehler. Diesen Fehler kann man jedoch umgehen, in dem man einen anonymen BNode verwendet: s:a s:b [s:x* s:y]. Dieser Pattern enthält in der SPARQL-Algebra zwei unterschiedliche anonyme BNodes - einen für den Basic Graph Pattern und einen für die Property Path Expression.

Pfade der Länge null werden in der Implementierung der Zero0rMore Expression und der Zero0r0ne Expression verwendet. Bei der Zero0r0ne Expression wird die innere Subexpression übersetzt und das Ergebnis um die Pfade der Länge null erweitert. Bei der Zero0rMore Expression wird zunächst der innere Pfad mit Variablen als Start und Ende übersetzt, danach die Rekursion mittels der in Unterabschnitt 3.5.1 beschriebenen Methode durchgeführt und zuletzt die Pfade der Länge null hinzugefügt.

3.5.3 Negated Property Set

Negated Property Set ist eine Property Path Expression, welche einen Pfad aus einer Kante matcht. Dabei ist die Property dieser Kante keine aus einer gegebenen Liste von nicht erlauben Properties.

Die Übersetzung geschieht in der translate_negated_property_set() Methode. Diese Methode enthält folgende wesentliche Nemo Template Language Definition:

```
nemo_def!(
    negated_property_set(start, end)
    :- input_graph(start, ?property, end), {filters}
    ; SolutionSet
);
```

Dabei wurde start und end als Parameter übergeben und kann sowohl eine Variable als auch eine Konstante sein. Alle Einschränkungen für die ?property Variable sind in den filters enthalten. Für jedes Element der gegebenen Liste an nicht erlauben Properties gibt es eine ungleich, !=, Bedingung in Nemo. Diese Bedingungen werden in einem For-Loop in Rust mit dem nemo_atoms! Makro (Unterabschnitt 2.2.4) aggregiert.

Bemerkenswerte ist, dass in diesem Fall keine Diskussion über die korrekte Variante von Ungleichheit durchzuführen ist, da in Prädikate-Position keine Literale erlaubt sind in RDF.

SPARQL erlaubt Syntax, bei dem manche Properties in einem Negated Property Set invertiert sind. Diese sind laut Standard äquivalent zu einer Kombination aus anderen Property Path Features und die entsprechende Transformation wird bereits beim Übersetzen in SPARQL Algebra von der spargebra Bibliothek durchgeführt, sodass sie nicht weiter berücksichtigt werden müssen.

3.5.4 Weitere Property Paths

Die bisher noch nicht vorgestellten Property Path Expression Features sind leicht implementierbar und werden direkt in der translate_path Methode implementiert. start und end werden als Parameter übergeben und können jeweils eine Variable oder konstante sein. Folgende Übersicht zeigt die Verbleibenden Property Path Expression Operationen:

NamedNode Ein Pfad über eine einfache Property.

path_property(start, end) :- input_graph(start, property, end)

Reverse Der innere Property Path von Ende zu Start.

reverse(start, end) :- inner(end, start)

Start und Ende müssen auch beim Übersetzen des inneren Property Paths

vertauscht werden.

Sequence sequence(start, end) :- first(start, middle), second(middle, end)

middle ist eine neue Variable.

Alternative first Pfad oder second Pfad.

alternative(start, end) :- first(start, end)
alternative(start, end) :- second(start, end)

Falls Start oder Ende eine Konstante sind, wird diese Information, wenn möglich, zu den Subexpressions propagiert. Dadurch wird das *Ergebnis* → der Prädikate kleiner und die Ausführung effizienter. Außerdem vereinfacht die spargebra Bibliothek einige Property Path Expressions, die sich zu einem Basic Graph Pattern umwandeln lassen. Dies führt zu einer deutlichen Effizienzsteigerung, da keine extra Prädikate für die Subexpressions verwendet werden und stattdessen Nemos Multiway-Join-Algorithmus zusätzliche Bedingungen aus einem zugehörigen Basic Graph Pattern mit beachten kann.

3.6 Ergebnis-Typ-Transformationen

Es ist möglich, die Ereignistypen SolutionSet, SolutionMultiSet und SolutionSequence (siehe Abschnitt 2.3) ineinander zu transformieren. Dies ermöglicht es in vielen Fällen, Features nicht für alle Ergebnistypen zu implementieren und die verbleibenden Typen durch Konvertierung zu unterstützen. Es können die Typen verwendet werden, welche eine Natürliche Nemo Implementierung erlauben. Zwar muss in einigen Fällen Information "frei erfunden" werden, beispielsweise muss bei der Konvertierung von SolutionMultiSet nach SolutionSequence eine Reihenfolge hinzugefügt werden, jedoch werden die entsprechenden Funktionen nur eingesetzt, wenn die Konvertierung passend ist, z.B. die Reihenfolge ohnehin keine Rolle spielt.

3.6.1 Sequenz aus einem Set

Die Transformation ist in der get_sequence() Methode implementiert:

```
fn get_sequence(&mut self, inner: &SolutionSet) -> SolutionSequence
```

Für die Konvertierung zu einer Sequenz muss für jedes Tupel ein beliebiger Index neu generiert werden. Dabei müssen die Indizes eine lückenlose Abfolge von natürlichen Zahlen sein, welche bei null beginnt. Außerdem ist die Effizienz mitunter relevant, da fast jede Query ohne DISTINCT einen Basic Graph Pattern, bei dem die Reihenfolge keine Rolle spielt, in eine Sequenz umwandeln muss. Die Konvertierung von Multiset zu Sequenz verwendet auch die get_sequence() Funktion zur Implementierung.

Es besteht ein Zusammenhang zwischen der Konvertierung zu einer Sequenz, bei der eine beliebige Reihenfolge vergeben werden muss, und der Sortierung, bei der eine bestimmte Reihenfolge vergeben werden muss. Es könnte beispielsweise mittels einer existentiellen Regel für jedes Tupel ein BNode generiert werden und dann nach den BNodes sortiert werden. Dennoch kann nicht ein beliebiger Sortieralgorithmus verwendet werden. Beispielsweise benötigt die im Unterabschnitt 3.7.12 vorgestellte Bitonic-Sort Implementierung bereits eine Reihenfolge der Eingabe. Das ebenfalls dort vorgestellte Radix-Sortierverfahren hingegen funktioniert. Allerdings beeinflusst, aufgrund der bereits oben erwähnten häufigen Verwendung der Implementierung, eine lange Implementierung die Länge von vielen Query-Übersetzungen, was ein Arbeiten erschwert. Deswegen wurde sich für das ebenfalls in Unterabschnitt 3.7.12 vorgestellte "Hacker-Mans-Sort" Verfahren entschieden. Der größte Nachteil, dass dieses Sortierverfahren keine SPARQL konforme Sortierreihenfolge erzeugt, spielt hier keine Rolle und die Vorteile der kurzen Implementierung und Ausführungszeit sind erwünscht. Allerdings ist es abhängig von der spezifischen derzeitigen Nemo-Rule-Engine Implementierung, insbesondere davon, dass BNodes einer existentiellen Regel durch eine fortlaufende ID benannt werden. Im Folgenden ist eine Beispielübersetzung dargestellt. Da die Query fast keine anderen Features beinhaltet, kann die komplette Übersetzung gezeigt werden.

```
SPARQL-Query:
prefix ex: <https://example.com/>

SELECT ?a WHERE {
    SELECT DISTINCT ?a
    WHERE {?a ex:p ex:o}
}

Nemo-Programm: (Kommentare manuell eingefügt)

% Innere Query
bgp(?a) :- input_graph(?a, <https://example.com/p>, <https://example.com/o>) .
projection_1(?a) :- bgp(?a) .

% Für jedes Tuple im Ergebnis ein neuer BNode
sequence_proto(?a, !bnode_for_id) :- projection_1(?a) .

% Extrahieren der Zahl aus dem BNode Namen
sequence_shifted(?a, INT(STR(?bnode_var))) :- sequence_proto(?a, ?bnode_var) .

% Beginn der Indizes auf 0 setzen
```

```
sequence_start(#min(?RESULT)) :- sequence_shifted(?a, ?RESULT) .
sequence(?id - ?min, ?a) :- sequence_shifted(?a, ?id), sequence_start(?min) .
% SELECT ?a Implementierung
projection(?INDEX, ?a) :- sequence(?INDEX, ?a) .
@output projection .
```

Die verwendete Min-Aggregation hat den Nebeneffekt, dass an dieser Stelle ein neues Stratum des Programms beginnt. In der Praxis stellt dies sicher, dass z.B. nicht das input_graph Prädikat vom projection Prädikat abhängen kann und die existentielle Regel nur einmal bearbeitet wird. Stellt sich beim Testen in Zukunft heraus, dass die Regel mehrfach aufgerufen wird und Lücken in der Index Sequenz auftreten, muss künstlich auch ein neues Stratum vor der existentiellen Regel eingeführt werden. Es gibt aber derzeit keine bekannte Query bei der dies auftritt.

3.6.2 Sequenz aus einem Multiset

Die Transformation ist in der get_sequence_from_multi() Methode implementiert:

```
fn get_sequence_from_multi(
     &mut self, inner: &SolutionMultiSet
) -> SolutionSequence
```

Die Konvertierung von einem Multiset zu einer Sequenz verwendet im Wesentlichen die get_sequence() Methode, die zur Konvertierung von einem Set zu einer Sequenz dient (Unterabschnitt 3.6.1). Zuvor werden zu jedem Tupel, je nach Multiplizität, weitere Tupel generiert. Diese Tupel unterscheiden sich durch eine zusätzliche Zahl. Diese ist zunächst die Multiplizität des Tupel verringert um 1. Für jede zusätzliche Zahl größer als 0 wird auch das Tupel mit der nächst kleineren erzeugt:

```
let remaining = nemo_var!(remaining);
nemo_def!(
    pre_index(??vars, remaining.clone() - 1)
    :- inner(@count: remaining.clone(); ??vars)
    ; SolutionSet
);
nemo_add!(
    pre_index(??vars, remaining.clone() - 1)
    :- pre_index(??vars, remaining.clone()),
    {nemo_filter!("", remaining.clone(), " > 0")}
)
```

Nach dem get_sequence() Aufruf wird die zusätzliche Zahl wieder entfernt.

Wie in Unterabschnitt 3.7.12 gezeigt, sind solche zählenden Regeln in der Verwendeten Nemo Version quadratisch in ihrer Laufzeit. Besteht also die Multimenge aus einem einzigen Ergebnis der Multiplizität 100.000, ist diese Implementierung langsam¹⁰. In der Praxis ist dieser Fall zwar möglich, jedoch nicht häufig. Eine effizientere Implementierung könnte anstatt die nächst kleinere zusätzliche Zahl auch direkt noch weitere Zahlen erzeugen. Eine

¹⁰etliche Minuten wie in Unterabschnitt 3.7.12 gezeigt wird

balancierte Baumstruktur ist jedoch nicht trivial und in den bisherigen Tests traten so hohe Multiplizitäten nicht auf.

3.6.3 Weitere Ergebnis-Typ-Transformationen

Weitere Ergebnistransformationen sind einfach. Die Transformation einer Sequenz zu einem Multiset kann durch Zählen (Aggregation) der jeweils relevanten Indizes erfolgen¹¹:

```
nemo_def!(
    as_multi(@count: %count(?i); ??vars)
    :- inner(@index: ?i; ??vars)
    ; SolutionMultiSet
);
```

Ein Multiset kann aus einem Set gebildet werden, indem die Multiplizität auf 1 gesetzt wird (get_multi() Methode):

```
nemo_def!(
    multi(@count: 1; ??vars) :- inner(??vars); SolutionMultiSet
);
```

Ein Set kann durch Weglassen des count oder index geschehen. Für dies gibt es keine separate Funktion. Die Operation wird direkt an den Stellen, wo dies nötig ist, durchgeführt.

3.7 Graph Patterns

Graph-Patterns ist ein Typ von Operation in SPARQL-Algebra, der alle Operationen abdeckt, welche nicht Expressions, Property-Path-Expressions oder Query Forms sind. In der spargebra Bibliothek gibt es dazu den Enum-Typ GraphPattern. Die Übersetzung eines Graph-Patterns erfolgt durch ein match Statement in Rust und individuellen Implementierungen für die einzelnen Operationen. Außer einzelne Operationen werden auch Sonderfälle für Kombinationen aus Operationen, wie eine Implementierung ohne Negation für FILTER EXISTS (siehe Unterabschnitt 3.7.4), betrachtet.

Unterschiedliche Operationen können unterschiedliche Typen als Ergebnis haben. So ist beispielsweise bei einer OrderBy Operation die Reihenfolge der Ergebnisse relevant und bei einer Query ohne DISTINCT spielt die Häufigkeit eines Ergebnisses eine Rolle. Um dies abzubilden, gibt es drei Methoden in der QueryTranslator Klasse, die jeweils einen anderen Ergebnistyp haben:

```
fn translate_pattern(&mut self, pattern: &GraphPattern)
   -> Result<SolutionSet, TranslateError>
fn translate_pattern_multi(&mut self, pattern: &GraphPattern)
   -> Result<SolutionMultiSet, TranslateError>
fn translate_pattern_seq(&mut self, pattern: &GraphPattern)
   -> Result<SolutionSequence, TranslateError>
```

¹¹get_multi_from_sequence() Methode entspricht der ToMultiSet Funktion im SPARQL Standard

Die Funktionen rufen sich gegenseitig rekursiv in den entsprechenden Fällen auf. Alle Informationen über die zu übersetzende Operation werden durch den pattern Parameter übergeben. Die Ergebnistypen SolutionSet¹², SolutionMultiSet¹³ und SolutionSequence¹⁴ sind in Abschnitt 2.3 vorgestellt. Konvertierungen zwischen den Typen, unabhängig von einer Algebraoperationen, sind in Abschnitt 3.6 vorgestellt.

3.7.1 Distinct und Reduced

Die DISTINCT Operation der SPARQL-Algebra entfernt alle Duplikate aus dem Ergebnis. Die REDUCED Operation stellt es der Implementierung frei, einige Duplikate zu entfernen. Da die Darstellung von und vor allem der Umgang mit SolutionMultiSet und SolutionSequence Overhead bedeutet, ist eine Query ohne Duplikate im Allgemeinen effizienter, weshalb REDUCED genau wie DISTINCT übersetzt wird.

Die Verwendung von DISTINCT entscheidet außerdem darüber, welchen Ergebnistyp die übersetzte Query am Ende produziert. Die Unterscheidung ist nur für SELECT Queries relevant und findet in der translate_query Funktion (Abschnitt 3.8) statt. Ist die äußerste Operation DISTINCT oder ein Slice (LIMIT und OFFSET) von DISTINCT (Slice wird nach DISTINCT evaluiert), ist das Ergebnis ein SolutionSet. In allen anderen Fällen ist das Ergebnis eine SolutionSequence. Insbesondere resultieren Queries mit REDUCED in einer SolutionSequence. Der Typ SolutionMultiSet wird nur für interne Zwischenergebnisse verwendet.

Die Implementierung von REDUCED bzw. DISTINCT führt zu keinen eigenen Regeln in Nemo. Stattdessen wird die innere Query durch die Funktion translate_pattern() übersetzt, welche ein SolutionSet und damit keine Duplikate produziert. Für die Funktionen translate_pattern_multi() und translate_pattern_seq() wird das Ergebnis danach in den richtigen Typ konvertiert (Abschnitt 3.6).

Der SPARQL Standard schreibt vor, dass DISTINCT und REDUCED eine durch ORDER BY gegebene Ordnung erhalten müssen. Dies ist bei der Übersetzung nicht gegeben.

3.7.2 Basic Graph Patterns

Basic-Graph-Pattern, BGP in SPARQL-Algebra, ist ein grundlegendes SPARQL Feature zum Matchen von Teilen eines Graphen. Im Folgenden ist ein Beispiel dargestellt:

```
prefix ex: <https://example.com/>
SELECT DISTINCT ?a {
    ?a ex:p ex:o .
    ?a ex:q ?x.
}
```

Die Query fragt alle Knoten, welche den Wert ex: o für die Property ex: p und einen beliebigen Wert für die property ex: q haben, an.

¹²Ohne Zusatzinformation für jedes Ergebnis

¹³Mit count für jedes Ergebnis

¹⁴Mit index für jedes Ergebnis

Die Übersetzung der gezeigten Query in Nemo ist mit wenigen Regeln möglich und kann deswegen hier komplett abgebildet werden. Das Präfix "ex" wurde nachträglich eingefügt:

```
@prefix ex: <http://example.org/> .
bgp(?a, ?x) :- input_graph(?a, ex:p, ex:o), input_graph(?a, ex:q, ?x) .
projection(?a) :- bgp(?a, ?x) .
@output projection .
```

Das Prädikat input_graph ist separat mit den Tripeln des Eingabe-Graphen zu definieren. Es ist zu beobachten, dass jedes Triple im Basic-Graph-Pattern zu einem input_graph Prädikat im *Regel-Körper* des bgp Prädikats übersetzt wird. Indem der gesamte Basic-Graph-Pattern zu einer einzigen Regel übersetzt wird, kann Nemos effiziente Multiway-Join-Implementierung gut ausgenutzt werden. Außerdem wird der potenziell große Eingabe-Graph auf diese Weise im ersten Schritt zu einem häufig signifikant kleineren Zwischenergebnis reduziert.

BNodes werden zunächst zu Nemo-Variablen übersetzt¹⁵ und dann für SolutionSet ignoriert oder für SolutionMultiSet mit #count Aggregation als Multiplizität gezählt. Da die #count Aggregation in Nemo mindestens eine Variable als Parameter benötigt, gibt es einen extra betrachteten Sonderfall, falls der Basic Graph Pattern keine BNodes enthält, welcher die Multiplizität für alle Ergebnisse auf 1 setzt. Der SPARQL Standard definiert keine Reihenfolge für die Ergebnisse eines Basic-Graph-Patterns. Deswegen wird für SolutionSequence die SolutionMultiSet Implementierung verwendet und das Ergebnis konvertiert (Abschnitt 3.6).

Die Implementierung der Übersetzung umfasst folgende Methoden in der QueryTranslator Klasse:

translate_term() Transformation der IRIs, Literals, BNodes und Variablen aus der spar-

gebra Repräsentation in Nemo Template Language sowie Verwaltung

von Listen der Variablen und BNode-Variablen

translate_triple() Transformation eines spargebra Tripels in ein Nemo Template Lan-

guage input_graph Prädikat und weitere Verwaltung der BNodes und Variablen. Die Funktion verwendet für Subjekt- und Objekt-Position die translate_term() Funktion, die Prädikat-Position hat

einen eigenen Typ in spargebra

translate_bgp() BGP ohne Multiplizität translate_bgp_multi() BGP mit Multiplizität

Im SPARQL Standard wird die Semantik eines Basic Graph Patterns durch ein "pattern instance mapping" P definiert, welches direkt zu einer Mapping der Variablen im Regel-K"orper", unter Berücksichtigung der Tripel im Graph, der durch das Prädikat input_graph repr"asentiert" wird, korrespondiert. P entspricht also einer Variablenersetzung θ aus der Datalogdefinition in Abschnitt 1.5. Ein Ergebnis des Basic Graph Patterns μ ist dann "the restriction of P to the query variables", was direkt mit dem bgp Prädikat im Regel-Kopf f korrespondiert f Die Multiplizität, gegeben f ist definiert durch "number of distinct RDF instance mappings, f0, such that f1 = f2 (für ein valides f2). Es ist möglich, die #count Aggregation in Nemo durch einen ähnlichen Ausdruck zu definieren.

Es ist zu beobachten, dass durch diese Definition der Scope eines BNodes auf innerhalb eines Basic-Graph-Patterns beschränkt ist. Folgende Query enthält zwei unterschiedliche

¹⁵In Abschnitt 3.3 beschriebenes Vorgehen ermöglicht es aus BNode IDs nicht-kollidierende Variablen zu bilden ¹⁶Korrenspondenz von Tupel und Mapping aus Unterabschnitt 1.5.1 ist hier so anwendbar, da alle Ergebnisse für die gleichen Variablen definiert sind.

BNodes mit gleicher ID (das BIND stellt sicher, dass die beiden BGPs nicht als ein BGP betrachtet werden können):

```
SELECT ?c WHERE \{\{\_:1 \text{ a ?c}\}\{\_:1 \text{ a ?d . BIND}(?d \text{ as ?c})\}\}
```

In rdflib wird der Scope dennoch ausgedehnt. In der verwendeten spargebra Bibliothek wird davon ausgegangen, dass dies ungewollt ist und ein entsprechender Parsing Error erzeugt.

3.7.3 Join Patterns

Die Graph-Patterns Join und LeftJoin, die SPARQL-Algebra-Operation zu OPTIONAL sowie die Exists Expression (Unterabschnitt 3.4.9) haben, trotz unterschiedlicher Details, ähnliches Verhalten und sind dadurch sinnvoll zusammen zu betrachten.

Grundsätzlich lässt sich ein Join leicht in Datalog umsetzen, da der *Regel-Körper* [→] in Datalog einen Join beschreibt. Das Beispiel implementiert einen Join anhand der jeweils ersten Position von zwei Tupel Mengen *repräsentiert* [→] durch die Prädikate x und y:

```
z(?a, ?b, ?c) :- x(?a, ?b), y(?a, ?c).
```

Diese Join-Übersetzung liefert jedoch keine korrekten Ergebnisse, falls eine Tupel in der ersten Position den *UNDEF-Marker* enthält. Nach der obigen Implementierung würde ein *UNDEF-Marker* in x nur mit einem *UNDEF-Marker* in y matchen. Das korrekte Verhalten ist jedoch, dass ein nicht definierter Wert in x mit jedem beliebigen Wert in y matcht. Damit ein Wert zu mehreren Werten matchen kann, kann ein Mapping Prädikat eingeführt werden, welches die Werte, die zueinander matchen, in Relation setzt. Da so ein Prädikat weniger effizient ist, wird getrackt, welche Variable überhaupt den *UNDEF-Marker* annehmen kann (siehe Abschnitt 2.2). Nur für solche Variablen wird ein Mapping Prädikat generiert. Hier ist ein Beispiel für einen Join wobei die erste Position von y den *UNDEF-Marker* annehmen kann:

```
map(?a, ?a, ?a) :- x(?a, ?b), y(?a, ?c) . map(?a, ?a, UNDEF) :- x(?a, ?b) . z(?a, ?b, ?c) :- map(?a, ?left, ?right), x(?left, ?b), y(?right, ?c) .
```

Die zweite und dritte Position des map Prädikats bilden zwei Werte, die auf der linken bzw. rechten Seite des Joins matchen können. Die erste Position ist der Wert, welcher das Ergebnis des Joins ist. Die erste Regel stellt sicher, dass zwei gleiche Werte matchen, wobei das Ergebnis der matchende Wert ist. Die zweite Regel stellt sicher, dass der *UNDEF-Marker* → in der ersten Position von y mit jedem Wert in der ersten Position von x matcht, wobei das Ergebnis der Wert aus x ist.

Im allgemeineren Fall, wo auch die erste Position von x den *UNDEF-Marker* annehmen kann, käme eine dritte Regel ähnlich der 2. Regel hinzu, welche bewirkt, dass der *UNDEF-Marker* in x mit jedem Wert der ersten Position aus y matcht. Weiterhin benötigt man ein Prädikat ähnlich dem map Prädikat aus dem Beispiel für jede Position, die in beiden zu joinenden Teilergebnissen vorkommt und welche nicht definiert sein kann.

Betrachtet man die Speichernutzung durch ein map-Prädikat, ist feststellbar, dass die erste Regel höchstens so viele Tupel wie das kleinste *Ergebnis* → der zu joinenende Prädikate erzeugt. Die andern beiden Regeln erzeugen höchstens so viele Tupel wie das *Ergebnis* → der zu joinendenden Prädikate zusammen. Somit *repräsentiert* → das map Prädikat höchstens

doppelt so viele Tupel wie die zu joinenden Prädikate zusammen. Auf diese Weise kann gezeigt werden, dass durch das map-Prädikat keine massiv größeren Zwischenergebnisse, wie beispielsweise ein Zwischenergebnis, welches quadratisch größer als die Eingabe des Joins ist, entstehen kann.

Die Multiplizität $card(\mu)$ eines Solution-Mapping μ (Unterabschnitt 1.5.1) im Join Ergebnis ist in SPARQL wie folgt definiert (vereinfachte Darstellung):

```
card(\mu) = \sum card(\mu_1) * card(\mu_2) for (\mu_1, \mu_2) such that \mu = merge(\mu_1, \mu_2)
```

Dabei ist μ_1 und μ_2 im jeweils linken bzw. rechten zu joinenden Prädikat und $merge()^{17}$ kombiniert zwei Solution-Mappings, wenn dies möglich ist¹⁸. Die Summe wird benötigt, da unterschiedliche Kombinationen zum selben Ergebnis führen können, z.B. führen die Tupel (1, 2) und (1, UNDEF) auf der linken Seite mit dem Tupel (1, 2) auf der rechten Seite beide zum Tupel (1, 2) im Ergebnis des Joins. Die Formel aus dem SPARQL Standard kann direkt in Nemo übersetzt werden. Dafür hier das relevante Fragment in Nemo Template Language:

```
nemo_def!(
    join(
        @?count: %sum(cl.clone() * cr.clone(), extra_vars)
        ; result_terms
) :-
        {maps},
        left(@?count: cl; left_bindings),
        right(@?count: cr; right_bindings)
; T
);
```

Im Folgenden ist die Erklärung der verwendeten Variablen dargestellt:

- extra_vars: alle Hilfsvariablen, im Beispiel oben ?left und ?right
- result_terms:
 Die Variablen im Ergebnisprädikat des Joins.
- maps:

 Die map Prädikate, bereits an die korrekten Variablen gebunden
- left / right: repräsentieren → die zu joinenden Zwischenergebnisse
- left_bindings / right_bindings:
 Die korrekten Variablen für die jeweiligen Positionen der left und right Prädikate
- c1 / cr:
 Neue Variablen (Variablen in Expressions müssen vorher erstellt werden)
- T: generischer Rust-Typ Parameter vom Typ TypedPredicate (Unterabschnitt 2.2.2)

Durch @?-Syntax wird der count Parameter nur gesetzt, wenn der verwendete Prädikat-Typ diesen unterstützt (Unterabschnitt 2.2.2). Dadurch ist die Implementierung generisch für SolutionSet und SolutionMultiSet einsetzbar. Siehe auch Unterabschnitt 2.2.4 für weitere Erklärungen von Features der Nemo Template Language.

¹⁷könnte auch "instance-level Join" genannt werden

¹⁸https://www.w3.org/TR/sparql11-query/#defn_algCompatibleMapping

Die Implementierung der Operatoren Exists, Join und LeftJoin umfasst in der Praxis fast 200 Zeilen und wird kurz vorgestellt. Alle Implementierungen verwenden die gemeinsame Funktion unbound_join_map() welche, bei gegebenem linken und rechten Prädikat und einer konkreten SPARQL Variable, ein einzelnes map Prädikat mit den dazugehörigen Nemo Regeln konstruiert. Die Funktion stellt fest, welche der Variablen am Join für Regel 1 teilnehmen können und ob für eine der Seiten keine Regel nach der Form 2 bzw. 3 generiert werden muss. Die Funktion unbound_join_map() wird von zwei unterschiedlichen Funktionen verwendet, welche die Berechnung der korrekten Variablen-Bindings, zur Verwendung für die Prädikate in der finalen Regel bei der Berechnung des Joins, durchführen. Dabei bindet die Funktion unbound_combinations() die eigentliche SPARQL-Variable an erster Stelle des map Prädikats und die Funktion unbound_combinations_left_focus() an zweiter Stelle, sodass bei Verwendung dieser Variante immer das linke Prädikat das Ergebnis bestimmt. Außerdem hat die unbound_combinations_left_focus() eine einfachere Logik beim Generieren der Bindings für das linke Prädikat, da hier, weil das Ergebnis direkt vom linken Prädikat kommt, die SPARQL-Variablen, welche den Positionen ohnehin zugeordnet sind, direkt übernommen werden können.

Es folgt ein Vergleich der Implementierungen mit Join translate_positive_exists(), translate_minus_g() und translate_join_multi_g():

- · Funktion welche die Übersetzung durchführt:
 - Join: translate_join_multi_g()
 - Minus: translate_minus_g()
 - Exists: translate_positive_exists()
- · Verwendete Funktion zum generieren der Bindings:
 - Join: unbound_combinations()
 - Minus: unbound_combinations_left_focus()
 - Exists: unbound_combinations_left_focus()
- · Linker Join Input:
 - Join: linke Eingabe
 - Minus: linke Eingabe
 - Exists: Variablen-Bindings zum evaluieren der Expression (siehe Abschnitt 3.4)
- · Rechter Join Input:
 - Join: rechte Eingabe
 - Minus: rechte Eingabe
 - Exists: exists-Pattern Prädikat
- Egebnis Prädikat Typ:
 - **Join:** SolutionSet / SolutionMultiSet (Unterstützt beide Typen durch generischen Parameter, deswegen auch das _g Suffix im Funktionsnamen)
 - Minus: SolutionSet / SolutionMultiSet (Ebenfalls generisch)
 - Exists: SolutionExpression
- · Zusätzliche Bindings:
 - Join: @count wie oben beschreiben
 - Minus: @count von linker Eingabe
 - Exists: @result: true

Die Implementierungen für Exists und Minus beinhalten noch weitere Schritte außer einem Join, diese sind beschrieben in Unterabschnitt 3.4.9 für Exists und in Unterabschnitt 3.7.7 für Minus.

Die Implementierung für LeftJoin (SPARQL-Algebra-Operation zu OPTIONAL) ist etwas komplexer und daher nicht direkt in der vorherigen Übersicht aufgenommen. Es gibt zwei grundsätzlich unterschiedliche Implementierungen. Die erste Implementierung wird verwendet für Ergebnisse mit Multiplizität in der Funktion translate_left_join_multi(). Sie führt die LeftJoin Operation auf die Operationen Join, Filter, Union und Exists zurück. Im SPARQL Standard ist LeftJoin als

$$LeftJoin(\Omega_1, \Omega_2, expr) = Filter(expr, Join(\Omega_1, \Omega_2)) \cup Diff(\Omega_1, \Omega_2, expr)$$

definiert. Ω_1 ist das Testergebnis des eigentlichen Patterns, Ω_2 ist dies Teilergebnis im OPTIONAL-Block und expr ist eine zusätzliche Filter-Expression. Diff ist wiederum definiert als Ω_1 ohne Ω_2 und ohne die Ergebnisse für die expr den Effective-Boolean-Value von false hat. Dabei können in expr sowohl Variablen aus Ω_1 als auch aus Ω_2 verwendet werden. Die Multiplizität bei Diff die Multiplizität aus Ω_1 . Diff lässt sich durch eine Kombination aus Filter und Exists implementieren. Hier ist die Struktur der Operationen für LeftJoin(Ω_1 , Ω_2 , expr):




Abbildung 3.2: Datenfluss der Übersetzung von LeftJoin(Ω 1, Ω 2, expr)

Entscheidend ist, dass das Ergebnis von Filter2 nur Variablen aus Ω_1 enthält, während das Ergebnis von Filter1 Variablen aus Ω_1 und Ω_2 bindet. Damit produziert die Union Operation *UNDEF-Marker* \nearrow für alle Variablen aus Ω_2 für Tupel aus Ω_1 für die Filter1 kein passendes Ergebnis liefert.

Die Korrektheit der Diff Implementierung folgt aus doppelter Negation der im Standard definierten Bedingung und Propagierung der inneren Negation nach den erweiterten De Morganschen Gesetzen. Aus der Defintion im SPARQL Standard dafür das ein Ergebnis μ aus Ω_1 auch ein Ergebnis von Diff ist

```
\forall \mu' \in \Omega_2: either \mu and \mu' are not compatible or \mu and \mu' are compatible and expr(merge(\mu, \mu')) has an effective boolean value of false
```

wird dadurch

```
not \exists \mu' \in \Omega_2 : \mu \text{ and } \mu' \text{ are compatible} and \exp(merge(\mu,\mu')) has an effective boolean value of true
```

Wobei das "not ∃" zu einem FILTER NOT EXISTS, die *expr*, welche true sein muss, zu einem Filter und das *merge* der kompatiblen solution-mappings direkt zu einem Join Korrespondiert¹⁹.

Die Multiplizität ist korrekt, da Filter und Diff diese direkt aus Ω_1 übernehmen.

Der FILTER NOT EXISTS Teil der Implementierung beinhaltet stratifizierte Negation, was die Frage aufwirft, ob auch eine Implementierung ohne stratifizierte Negation und damit ein stratifiziertes Nemo-Programm bei welchem der Eingabe-Graph vom Ergebnis der SPARQL-Query abhängt, möglich wäre (Abschnitt 1.1). Grundsätzlich kann dies zu Widersprüchen führen, wenn beispielsweise der *UNDEF-Marker* aus dem Optional dazu führt, dass nun ein Wert für das entscheidende Prädikat existiert, was ursprünglich zum *UNDEF-Marker* geführt hat. Hier eine Implementierung ohne stratifizierter Negation, sie führt Negation durch Regeln mit existentiell quantifizierten Variablen (Unterabschnitt 1.5.2) durch:

Query:

```
prefix ex: <https://example.com/>
SELECT DISTINCT ?a ?b {
    ?a ex:p ex:o .
    OPTIONAL { ?a ex:q ?b . }
}
```

Übersetzung: (manuell mit Kommentaren versehen und Formatiert)

```
% computation before left join
bgp(?a)
   :- input_graph(?a, <https://example.com/p>, <https://example.com/o>) .
bgp_1(?a, ?b)
   :- input_graph(?a, <https://example.com/q>, ?b) .
```

¹⁹Das Gegenteil von false in der Diff-Definition ist in diesem Fall tatsächlich true und nicht wie logisch korrekt wäre "true oder ein Error". In einer Korrektur in SPARQL 1.2 ist die Definition "not true" wodurch das Gegenteil dann auch logisch korrekt true ist.

```
% regular join
join(?a, ?b) :- bgp(?a), bgp_1(?a, ?b).
% create dummy dependency
dummy_dependency(arity_zero) .
dummy_dependency(arity_zero) :- join(?a, ?b) .
% add bnodes to fill missing values
left_join_proto(?a, ?b, defined)
    :- join(?a, ?b), dummy_dependency(arity_zero) .
left_join_proto(?a, !b, !CONST)
    :- bgp(?a), dummy_dependency(arity_zero) .
% translate bnodes to unbound
dummy(arity_zero) .
undefined_val(UNDEF) :- dummy(arity_zero) .
left_join(?a, ?b) :- left_join_proto(?a, ?b, defined) .
left_join(?a, ?unbound)
    :- undefined_val(?unbound),
        left_join_proto(?a, ?b, ?CONST),
        ?CONST != defined .
% computation after left join
projection(?a, ?b) :- left_join(?a, ?b) .
@output projection .
```

Der reguläre Join muss dabei auch mit dem *UNDEF-Marker* umgehen. Außerdem wird der Fall eines LeftJoin mit Filterexpression berücksichtigt. Beides ist jedoch im vorliegenden Beispiel nicht vorhanden. Die dummy_dependency bewirkt, dass beide left_join_proto Regeln in jeder Query Durchlauf Iteration in der richtigen Reihenfolge "ausgeführt" werden. Ohne dummy_dependency versagt die existential Regelevaluierungsheuristik bei größeren Queries. Wie oben bereits erwähnt, kann diese Übersetzung ohne stratifizierter Negation nicht für alle Fälle korrekte Ergebnisse liefern. In der Praxis ist jedoch ein korrektes Verhalten, insbesondere im Standard-Fall ohne Abhängigkeit des Eingabe-Graph vom Ergebnis der Query, zu beobachten. (siehe auch Unterabschnitt 3.7.6)

3.7.4 Filter

Die Filter Operation in SPARQL behält nur Solution-Mappings (Unterabschnitt 1.5.1) für die eine gegebene Expression zu einem Ergebnis mit Effective-Boolean-Value true evaluiert. Sie ist durch eine einzige Nemo-Template-Language-Regel realisierbar:

```
nemo_def!(
    filter(@?count: ?c; ??expr_vars, ??other_vars)
    :- inner(@?count: ?c; ??expr_vars, ??other_vars),
        expression(??expr_vars; @result: true)
    ; T
);
```

Dabei repräsentiert ✓ inner das zu filternde Zwischenergebnis und expression ist ein Prädikat vom Typ SolutionExpression, wobei das Ergebnis vom Typ Boolean sein muss. Das ??expr_vars VarSet (VarSets beschrieben in Unterabschnitt 2.2.1) steht für alle Variablen, von denen die Expression abhängt.

Wie im gezeigten Nemo Template Language Fragment zu sehen, wird die Multiplizität, falls benötigt, direkt vom inneren Zwischenergebnis übernommen. Die Implementierung wird in vier Fällen eingesetzt:

Algebra- Operationen	Typ des Ergebnisprädikats	Übersetzung der Expression durch
Filter Exists Filter Filter Exists Filter	SolutionSet SolutionSet SolutionMultiSet SolutionMultiSet	<pre>translate_positive_exists() translate_bool_expression() translate_positive_exists() translate_bool_expression()</pre>

Der Sonderfall für Exists ist in Unterabschnitt 3.4.9 näher beschrieben. Falls die Expression nicht ohnehin ein Ergebnis vom Typ Boolean garantiert (siehe Unterabschnitt 3.4.3), berechnet die translate_bool_expression() Funktion den Effective-Boolean-Value. Ergebnisse vom Typ SolutionSequence müssen erst als SolutionMultiSet gefiltert und dann konvertiert werden (siehe Abschnitt 3.6) da ein bloßes Filtern keinen fortlaufenden Index garantiert.

3.7.5 Union

Im Kern ist eine Union Operation ein "oder". Ein Tupel ist im *Ergebnis* [→], wenn es entweder im linken *oder* im rechten Teilergebnis ist. Dies kann durch zwei Regeln abgebildet werden:

Query:

```
prefix ex: <https://example.com/>
SELECT DISTINCT ?a {
     {?a ex:p ex:o1}
     UNION
     {?a ex:p ex:o2}
}
```

Übersetzung: (Predikate ohne effect manuell entfernt, und Umformatiert)

Die tatsächliche Implementierung umfasst trotz einfacher Grundlage 60 Zeilen, was durch den Umgang mit Variablen, welche für ein Ergebnis nur auf einer der beiden Seiten gebunden sind, und drei eigene Implementierungen für SolutionSet, SolutionMultiSet und SolutionSequence zustande kommt.

Variablen, die nur auf einer Seite gebunden werden, müssen im Ergebnis zum UNDEF-Marker gemappt werden. Dafür gibt es die map_unbound() Funktion. Diese berechnet Bindings für ein target Prädikat, sodass alle SPARQL-Variablen, die nicht in einem source Prädikat vorkommen zum UNDEF-Marker . Da dieser erst zur Laufzeit bekannt sein kann, werden die entsprechenden Positionen zu einer Variable gemappt, welche dann durch das einstellige unbound Prädikat, welches nur den UNDEF-Marker im Ergebnis hat²0, gebunden wird. Außer mehrfacher Verwendung der map_unbound() Funktion in allen Union Implementierungen (jeweils für linke und rechte Teillösung) wird diese auch bei der Übersetzung von left_join und project (konkret beim Zusammenführen von Solution-Mappings, die durch das Project gleich werden) verwendet.

Grundlegend erweitern alle Implementierungen die linke und rechte Seite durch *UNDEF-Marker* um sie aneinander anzupassen und führen dann beide Ergebnisse durch zwei Regeln, wie im initialen Beispiel oben, zusammen. Abhängig vom Ergebnistyp gibt es extra Logik. Die SolutionMultiSet Implementierung könnte dabei aus der SolutionSequence Implementierung abgeleitet werden, da sie jedoch in der left_join_multi() Implementierung (Unterabschnitt 3.7.3) verwendet wird, ist eine eigene effizientere Implementierung nützlich.

Funktion	Ergebnistyp	Extra Logik
<pre>translate_union() translate_union_multi()</pre>	SolutionSet SolutionMultiSet	Keine Multiplizität wird addiert für Ergebnisse in beiden Seiten; insgesamt drei Regeln für Ergebnis links, rechts und in beiden
<pre>translate_union_seq()</pre>	SolutionSequence	Länge des linken Ergebnisses wird auf den Index des rechten Ergebnis addiert; extra Nemo Regel zur Berechnung der Größe

Nur die SolutionSet Implementierung kommt ohne nichtmonotone Features, wie stratifizierte Negation oder Aggregation, aus. Die SolutionMultiSet Implementierung benötigt stratifizierte Negation, um festzustellen, dass ein Ergebnis in einer Seite, aber nicht der anderen Seite vorkommt und die SolutionSequence Implementierung verwendet Aggregation, um die Größe des linken Teilergebnisses zu bestimmen.

²⁰Formal korrekt ein ein-Tupel aus dem *UNDEF-Marker* /

3.7.6 Extend

In SPARQL kann das Ergebnis einer Expression mittels BIND einer Variablen zugewiesen werden. In SPARQL-Algebra ist dafür die Extend Operation verantwortlich. Der SPARQL Standard lässt das Verhalten absichtlich undefiniert, wenn die Variable bereits an einen anderen Wert gebunden ist. In der Praxis gibt es keine einheitlich verwendete Lösung. Virtuoso ignoriert z.B. das zusätzliche Binding, Blazegraph matcht die bestehende Variable mit dem Binding und rdflib überschreibt das bestehende Binding. Spargebra und somit auch die SPARQL zu Nemo Übersetzung werfen Fehler in diesem Fall.

Eine Übersetzung von Extend könnte prinzipiell wie folgendes Beispiel funktionieren:

```
extend(?a, ?b, ?c, ?d) :- input(?a, ?b, ?c), expr(?b, ?c, ?d) .
```

Dabei repräsentiert input das erweiterte Ergebnis, expr das Ergebnis der Expression, wobei die Expression von den Variablen ?b und ?c abhängt, und extend das Ergebnis der Extend Operation. Das Ergebnis der Expression ?d wird im Ergebnis der Extend Operation mit aufgenommen.

Falls die Expression in einem Fehler resultiert, ist die neue Variable nicht definiert, also im Kontext der Übersetzung der *UNDEF-Marker*. Da ein Error durch fehlendes Tupel für diese Expression-Inputs dargestellt wird, liese sich dies durch stratifizierte Negation implementieren. Da jedoch existentielle Regeln in Nemo ein ähnliches Feature unterstützen, bei dem nur neue BNodes erzeugt werden, wenn nicht bereits ein Ergebnis existiert, stellt sich die Frage, ob eine Implementierung ohne stratifizierte Negation mittels existentieller Regeln möglich ist. Dies ist im Allgemeinen nicht möglich, da bei zyklischer Abhängigkeit des Eingabe-Graph vom Query-Ergebnis ein *UNDEF-Marker* im Ergebnis zu einem neuen Wert führen kann, welcher den Fehler verhindert und damit den *UNDEF-Marker* im Nachhinein inkorrekt macht. Dieser Fall ist jedoch unmöglich mit monotoner Logik lösbar. Da jedoch der SPARQL Standard nicht für solche zyklischen Abhängigkeiten definiert ist, kann in solchen Fällen, die über den SPARQL Standard hinaus gehen, ein zusätzlicher *UNDEF-Marker* im Ergebnis trotzdem zu praktisch nützlichen Ergebnissen führen.

Hier ist die Übersetzung einer Query mit BIND:

Query:

Übersetzung: (Kommentare nachträglich zur Erklärung der Implementierung eingeführt und Formatierung angepasst)

```
% variable-expression
var(?x, ?x) := bgp(?a, ?x), \sim undefined_val(?x).
% create dummy dependency
dummy_dependency(arity_zero) .
dummy_dependency(arity_zero) :- var(?x, ?RESULT) .
% add bnodes to fill missing values
proto_extend(?x, ?a, ?y, no_error)
:- bgp(?a, ?x), var(?x, ?y), dummy_dependency(arity_zero) .
proto_extend(?x, ?a, !no_result, !error)
:- bgp(?a, ?x), dummy_dependency(arity_zero).
% translate bnodes to unbound
extend(?x, ?a, ?y) := proto_extend(?x, ?a, ?y, no_error).
extend(?x, ?a, ?RESULT)
:- proto_extend(?x, ?a, ?y, ?CONST),
   undefined_val(?RESULT),
   ?CONST != no_error .
% computation after left join
projection(?a, ?y) := extend(?x, ?a, ?y).
@output projection .
```

Es ist anzumerken, dass die Negation von undefined_val keinen Einfluss auf die Stratifizierbarkeit des Programms hat, da das undefined_val Prädikat nicht vom Eingabegraphen abhängt und immer zuerst berechnet werden kann. Empirisch kann festgestellt werden, dass das dummy_dependency Prädikat die Korrektheit bei Queries bewirkt, bei denen der Eingabe-Graph nicht vom Ergebnis abhängt. Als Beispiel wurde explizit eine Query ausgewählt für die das dummy_dependency Prädikat eine Rolle spielt. Fügt man dem Beispiel den Fakt input_graph(1, https://example.com/p, 2) hinzu und entfernt das dummy_dependency Prädikat aus dem Regel-Körper der zwei proto_extend Regeln²¹, ergibt das Programm ein zusätzliches falsches Tupel mit dem UNDEF-Marker der. Siehe auch Unterabschnitt 3.7.3 für eine ähnliche Ersetzung von stratifizierter Negation durch existentielle Regeln.

3.7.7 Minus

MINUS ist neben FILTER NOT EXISTS das andere Modell, Negation in SPARQL-Queries zu formulieren. Der SPARQL Standard definiert das Ergebnis der *Minus*(*A*, *B*) Operation als alle Solution-Mappings in *A*, für die kein Solution Mapping in *B* existiert, was kompatibel ist und mindestens eine Variable gemeinsam hat. Kompatibel ist dabei eine häufig im SPARQL Standard verwendete Form von Gleichheit²² von Solution Mappings (siehe Unterabschnitt 1.5.1), bei der nicht definierte Variablen mit allen Werte matchen. Die Extrabedingung, dass gemeinsame Variablen nötig sind, ist einer der Unterschiede, wenn Negation mit MINUS anstatt mit FILTER NOT EXISTS ausgedrückt wird. Der andere Unterschied wäre, dass bei FILTER

²¹alternativ kann auch die Regel mit dummy_dependency im *Regel-Kopf* ⁷ auskommentiert werden

²²nicht immer transitiv

NOT EXISTS Variablen aus dem zu filterenden Zwischenergebnis im Scope sind, was jedoch in dieser Arbeit nicht standardkonform umgesetzt wurde (siehe Unterabschnitt 3.4.9).

Die Übersetzung berechnet die Operation in zwei Schritten. Zunächst werden die zu entfernenden Tupels durch ein Prädikat to_remove berechnet und dann werden diese Tupels mittels stratifizierter Negation entfernt und daraus das minus Prädikat berechnet. Der erste Schritt ergibt alle Tupels aus A für die es ein kompatibles Tupel aus B gibt und erfolgt grundsätzlich ähnlich zur Exists Implementierung (Unterabschnitt 3.7.3). Es wird zunächst für alle Variablen, die nicht definiert sein können, ein Mapping Prädikat gebildet, welches jeden relevanten Wert aus dem anderen Prädikat mit dem UNDEF-Marker in Relation setzt und jeden anderen Wert mit sich selbst in Relation setzt. Dafür wird die bereits in Unterabschnitt 3.7.3 beschriebene Funktion unbound_combinations_left_focus() wieder verwendet. Die Minus Implementierung unterscheidet sich zur Exists Implementierung durch das Prüfen der Extrabedinung, dass Tupel nur matchen, wenn sie mindestens eine gemeinsame Variable haben. Die jeweiligen Fälle sind durch folgende Auflistung gegeben:

- Die gegebenen Prädikate haben keine gemeinsame Variable
 - Detection: Einfacher Test während der Übersetzung
 - Vorgehen: Minus hat keinen Effekt, zurückgeben der linken Eingabe
- Für eine Variable ist Definiertheit in beiden Prädikaten bekannt
 - Detection: Information wird gesammelt w\u00e4hrend Konstruktion der Mappingpr\u00e4dikate
 - Vorgehen: Extrabedingung wird aus Nemo-Programm entfernt (ist immer erfüllt, muss nicht geprüft werden)
- Es gibt eine Variable für die beide Prädikate keinen UNDEF-Marker / haben
 - Detection: Evaluierung zur Laufzeit in Nemo (siehe unten), Extrabedingung ist erfüllt
 - Vorgehen: Tupel ist im *Ergebnis* → des to_remove Prädikats
- Für alle Variablen hat eines der Prädikate einen UNDEF-Marker
 - Detection: Evaluierung zur Laufzeit in Nemo (siehe unten), Extrabedingung ist nicht erfüllt
 - Vorgehen: Tupel nicht im *Ergebnis* [→] des to_remove Prädikats

Die Extrabedingung ist eine oder-Verknüpfung über alle Variablen und für jede Variable wird geprüft, ob diese für das eine Prädikat und für das andere Prädikat definiert ist. Der UNDEF-Marker [→] kann theoretisch jeder Wert sein. Ein Vergleich zum UNDEF-Marker [→] mittels = in Nemo wäre möglich, liefert jedoch keinen Boolean, welchen man für die AND() bzw. OR() Funktion in Nemo nutzen kann. Eine Umsetzung mit mehreren Regeln wäre denkbar, wenn auch weniger effizient. Es ist jedoch auch eine Implementierung als ein Constraint (siehe Unterabschnitt 1.5.2) in einer Regel möglich. Der Vergleich kann dabei mit ABS(COMPARE(fullStr(?val), fullStr(?undef))) durchgeführt werden, was 0 ergibt, wenn beide unterschiedlich, also der Wert definiert, und 1, wenn der Wert nicht definiert ist. 1 und 0 lassen sich nicht so leicht in einen Boolean Wert für die Verwendung von AND bzw. OR konvertieren. Stattdessen kann in diesem Zusammenhang * für AND und + für OR genutzt werden. So wird das Ergebnis des Vergleiches für eine Variable für beide Prädikate multipliziert und die Ergebnisse für alle Variablen werden wiederum addiert. Sind alle Variablen in mindestens einem Prädikat nicht definiert, ist das Ergebnis 0. Ist das Ergebnis größer als 0 ist mindestens eine Variable in beiden Prädikaten definiert, was die gesuchte Extrabedingung darstellt. Genau genommen muss der Vergleich nur für Positionen, von denen

nicht bereits durch Tracken bekannt ist, dass sie definiert sind, durchgeführt werden. Kann also eine Variable nur für ein Prädikat den *UNDEF-Marker* → annehmen, kann der Vergleich direkt addiert werden und es muss für diese Variable keine Multiplikation erfolgen. (siehe Abschnitt 2.2 für das Tracken von Eigenschaften)

Das to_remove Prädikat ist vom Typ SolutionSet und das minus Prädikat hat einen generischen Typ (entweder SolutionSet oder SolutionMultiSet) für SolutionMutliSet wird mittels @?-Syntax (Unterabschnitt 2.2.2) die Multiplizität vom ersten Operand übernommen. SolutionSequence wird nicht direkt unterstützt und muss aus dem SolutionMultiSet konvertiert werden

3.7.8 Values

Bei Values wird das Ergebnis der SPARQL Operation direkt als Eingabe vom Autor der Query angegeben. Bei der Übersetzung wird ein gegebener Wert zunächst von spargebra in eine spargebra spezifisch Repräsentation transformiert und dann mittels der translate_ground_term() Funktion in Nemo Template Language Repräsentation übersetzt. Das eigentliche values Prädikat wird mit einer Regel für jedes Tupel erzeugt. Eine Regel ist statt einem Fakt notwendig, da der UNDEF-Marker → zur Übersetzungszeit nicht bekannt sein muss und als Prädikat gegeben ist. Im Folgenden ist die Übersetzungsfunktion dargestellt (Formatierung und Kommentare zur Erklärung der Implementierung nachträglich bearbeitet):

```
fn translate_values_seq(
   &mut self.
    variables: &Vec<Variable>,
    bindings: &Vec<Vec<Option<GroundTerm>>>
) -> SolutionSequence {
    // create new predicate with correct position variables
    let values = SolutionSequence::create(
        "values",
        nemo_terms!(
            nemo_var!(index),
            variables => self.translate_var_func()
        ).vars()
    );
    let undef = nemo_var!(undef);
    let undef_pred = self.undefined_val.clone();
    for (i, binding) in bindings.iter().enumerate() {
        // convert the values to Nemo Template Language
        let terms: Vec<Binding> = binding.iter().map(
            |b| self.translate_ground_term(b, &undef)
        ).collect();
        // add the tuple
        nemo_add!(values(@index: i; terms) :- undef_pred(undef));
    }
   values
}
```

Die Inputtypen Variable und GroundTerm sind in spargebra definiert. Die Funktion erzeugt ein Nemo Template Language Prädikat values vom Typ SolutionSequence. SolutionMultiSet-Ergebnisse müssen durch Konvertierung erzeugt werden. Für SolutionSet gibt es eine eigene sehr ähnliche Funktion. Das values Prädikat hat an erster Stelle den Index und an den anderen Stellen die vom SPARQL-Query-Autor gegebenen Variablen. Diese werden mittels des Mapping-Syntax (siehe Unterabschnitt 2.2.4) des nemo_terms! Makros in Variablen der Nemo Template Language übersetzt. Die eigentliche Übersetzung erfolgt mittels der translate_var_func() Funktion, diese gibt eine Funktion zurück, welche die korrekte Variable in einem VariableTranslator Objekt des QueryTranslator (self Parameter) anfragt. Es kann keine neue Variable erzeugt werden, da unterschiedliche Variablen automatisch umbenannt werden, um Namenskollisionen zu verhindern (siehe Unterabschnitt 2.2.5).

Im Folgenden ein weiteres Beispiel:

Query:

```
SELECT ?a {
    VALUES (?a ?b) {(1 UNDEF) (2 3)}
}
```

Übersetzung: (explizite xsd:integer Datentypen aus Literalen nachträglich entfernt und Kommentare hinzugefügt)

```
% setup UNDEF Marker
dummy(arity_zero) .
undefined_val(UNDEF) :- dummy(arity_zero) .

% values pattern
values(0, 1, ?undef) :- undefined_val(?undef) .
values(1, 2, 3) :- undefined_val(?undef) .

% final projection
projection(?INDEX, ?a) :- values(?INDEX, ?a, ?b) .
@output projection .
```

3.7.9 Project

Für Values (siehe Unterabschnitt 3.7.8) gibt es eine separate Übersetzung für mit bzw. ohne Multiplizität, da die @?-Syntax nicht für die generische Implementierung ausreicht, denn es ist ein explizites Prädikat erstellt worden und es muss bei den unterschiedlichen Typen unterschieden werden, wie viele Variablen bei der Erstellung angegeben werden. Die Project Implementierung ist leicht komplexer und unterstützt alle drei Typen SolutionSet, SolutionMultiSet und SolutionSequence. Dadurch lohnt sich eine generische Implementierung, obwohl auch hier das projection Prädikat manuell erstellt wird. Die Unterscheidung, ob eine zusätzliche initiale Variable bei der Erstellung übergeben wird, erfolgt, indem die Länge aller Variablen mit der Länge der inneren Variablen verglichen wird. Die Funktion inner_vars() ist für jeden der drei Typen definiert und gibt alle Variablen eines Prädikats, abgesehen von den extra Variablen für Multiplizität oder Index, zurück. Die eigentliche Übergabe passiert mittels des nemo_terms! Makros (siehe Unterabschnitt 2.2.4), wobei auch, wie bei Values, die übergebenen zu projizierenden Variablen mittels der translate_var_func() Funktion gemappt werden.

An sich kann eine Projektion sehr einfach in einer Nemo Regel stattfinden, indem das projection Prädikat im *Regel-Kopf* nur die zu projizierenden, während das zu projizierende inner Prädikat im *Regel-Körper* alle Variablen gebunden hat. Es sind jedoch in SPARQL zwei Sonderfälle zu beachten. Zum einen sind dies projizierte Variablen, die nicht im zu projizierenden Zwischenergebnis vorkommen, und zum anderen sind dies Tupel, welche vor der Projektion unterschiedlich und nach der Projektion gleich sind.

Im SPARQL Standard ist die Projektion die Einschränkung der Variablen, für die jedes einzelne Solution Mapping (Unterabschnitt 1.5.1) definiert ist. Ist ein Solution Mapping bereits vorher für eine Variable nicht definiert, ist dieses Mapping nach der Projektion für diese Variable immer noch nicht definiert. Existiert eine Variable nicht im inner Prädikat, bedeutet dies, dass sie für keins der Solution Mappings definiert ist. Da sie auch nach der Projektion für kein Solution Mapping definiert ist, ist ein valide Ansicht jede Variable, die nicht im inner Prädikat vorkommt zu ignorieren. Jedoch ist aus Sicht eines Anwenders der SPARQL zu Nemo Übersetzung wünschenswert, dass man leicht die Arität des resultierenden Nemo Prädikats anhand des Project (SELECT) Pattern der SPARQL Query ablesen kann. Deswegen wird die nirgends definierte Variable konstant auf den UNDEF-Marker → gesetzt. Gibt es eine solche Variable wird diese, in einem Zwischenschritt, welcher ein proto_projection Prädikat ergibt, hinzugefügt.

Tupel, die durch Projektion gleich werden, sind nur bei SolutionMultiSet relevant. Bei SolutionSequence unterscheiden sich ohnehin alle Tupel im Index und bei SolutionSet werden die gleichen Tupel automatisch zusammengefasst. Bei SolutionMultiSet können sich Tupel hingegen allein durch die Multiplizität unterscheiden. Diese Multiplizitäten müssen durch sum Aggregation zusammengefasst werden.

Die wichtigste Zeile der Übersetzung kann hier gezeigt werden:

```
nemo_add!(
    projection(@?count: %sum(?c, ??other), @?index: ?i; ??projected)
    :- extended_inner(@?count: ?c, @?index: ?i; ??projected, ??other)
);
```

Es wird das nemo_add! Makro statt nemo_def! (Unterabschnitt 2.2.4) verwendet, da das projection Prädikat bereits zuvor mit den korrekten Variablen erstellt wurde, somit wird das VarSet ??projected automatisch an die korrekten zu projizierenden Variablen gebunden und ??other steht für die verbleibenden Variablen (Unterabschnitt 2.2.1). Das extended_inner Prädikat ist das zu projizierende Teilergebnis, welches, falls nötig, bereits um nicht im Teilergebnis vorkommende Variablen erweitert wurde. Es ist ersichtlich, dass mittels des @?-Syntax (Unterabschnitt 2.2.2) sowohl Multiplizität mit count als auch Sortierung mittels index generisch unterstützt wird.

3.7.10 Slice

Slice ist die SPARQL-Algebra-Operation zu LIMIT und OFFSET. Dies lässt sich für Zwischenergebnisse welche durch ein Prädikat vom Typ SolutionSequence *repräsentiert* ✓ werden durch eine Condition (Unterabschnitt 1.5.2) der Index-Variable in einer Nemo-Regel und eine Verschiebung der Indizes im Ergebnis durch Subtraktion implementieren:

```
fn translate_slice_seq(
    &mut self,
    inner: &SolutionSequence,
    start: usize,
    length: Option<usize>
) -> SolutionSequence {
    let index = nemo_var!(index);
    let mut condition = nemo_condition!(index, " >= ", start);
    if let Some(1) = length {
        condition = nemo_atoms![
            condition,
            nemo_condition!(index, " < ", start + 1)</pre>
    }
    nemo_def!(
        slice(@index: index.clone() - start; ??vars)
        :- inner(@index: index; ??vars), {condition}
        ; SolutionSequence
    );
    slice
}
```

Die anderen Typen können dadurch durch Konvertierung von bzw. nach SolutionSequence unterstützt werden (Abschnitt 3.6).

Es ist anzumerken, dass LIMIT in SPARQL häufig verwendet wird, um eine Query ohne Anspruch auf Vollständigkeit, effizienter zu machen, da die Evaluierung abbrechen kann, wenn bereits genügend Ergebnisse gefunden sind. Dieses Prinzip wird hier nicht berücksichtigt, da grundsätzlich alle Zwischenergebnisse komplett berechnet werden. Dennoch kann das Feature verwendet werden, z.B. wenn eine Subquery limitiert wird, sodass eine äußere Query auf weniger Ergebnissen ausgeführt wird.

3.7.11 Aggregation

Aggregation ist in SPARQL recht komplex, mittels der Operationen Group, ListEval, Aggregation, AggregateJoin und Flatten sowie extra Operationen für die jeweiligen Aggregationsfunktionen Count, Sum, Avg, Min, Max, GroupConcat und Sample, definiert. Spargebra hat bereits ein vereinfachtes Model und übersetzt Aggregation zu einem Graph Pattern Group, welcher Aggregates vom Typ AggregateExpression haben kann. Zusätzlich bettet spargebra die Group Operation in eine Extend Operation (Unterabschnitt 3.7.6). Dadurch werden äußere Expressions, in denen das Ergebnis der Aggregation modifiziert wird, wie bei #sum(...) + 1, bereits inklusive Fehlerbehandlung ohne zusätzlichen Aufwand abgedeckt. Bei der Übersetzung wird eine SPARQL Aggregatione im Wesentlichen zu einer

Nemo Aggregation übersetzt und die Details aus dem SPARQL Standard somit nicht einzeln adressiert.

Dennoch werden die grundlegenden Features, welche in SPARQL relevant sind, aber nicht direkt in Nemo unterstützt werden, wie folgt adressiert:

- Unterstützung für mehrere Aggregationen (Nemo unterstützt nur eine Aggregation pro Regel)
- Unterstützung von Aggregation mit und ohne DISTINCT Keyword (Nemo verwendet, Set-Semantik nach der es grundsätzlich keine Duplikate geben kann)
- Unterstützung von komplexen Expressions (Bei der Übersetzung werden auch manche Expressions unterstützt, die nicht direkt in Nemo zulässig sind, z.B COALESCE aber auch viele andere aus Abschnitt 3.4)

In der Funktion translate_aggregation() findet die Übersetzung einer einzelenn Aggregation statt:

```
fn translate_aggregation(
    // QueryTranslator
    &mut self.
    // repräsentiert zu aggregierendes Teilergebnis
    inner: &dyn TypedPredicate,
    // SPARQL Variable für Ergebnis der Aggregation
   variable: VarPtr,
    // zu aggregierende Expression
    expression: &Expression,
    // name der aggregationsfunktion in Nemo
    aggregation: &str,
    // Variablen nach denen grupiert werden soll
    group_vars: &Vec<VarPtr>,
    // ob aggregation in Nemo "distinct variables" nicht unterstützt
    idempotent: bool
) -> Result<SolutionSet, TranslateError>
```

Zunächst wird die spargebra expression, wie bereits in Abschnitt 3.4 beschrieben mit der translate_expression() Methode zum expr_solution Prädikat übersetzt. Danach wird der Aufruf der Aggregationsfunktion mit korrekten Parametern aggregation_call (für nicht idempotente Funktionen werden alle nicht grupierten Variablen als "distinct variables"²³ in Nemo angegeben) und das aggregate Prädikat mit allen group_vars und der variable für das Ergebnis der Aggregation generiert. Schließlich wird die eigentliche Regel erzeugt:

```
nemo_add!(
    aggregate(??group_vars, aggregation_call)
    :- inner(??group_vars, ??other), {&expr_solution}
);
```

Für count(*) gibt es eine eigene Funktion translate_count_all() welche, statt einer zu aggregierenden Expression, alle nicht gruppierten Variablen mittels einer #count Aggregation in Nemo aggregiert. Der Spezialfall, dass bei allen Variablen gruppiert wird, wird nicht extra beachtet und führt zu einem Fehler in Nemo, da eine Aggregation ohne Parameter in Nemo nicht erlaubt ist. Korrekt sollte das Ergebnis in diesem Fall 1 sein.

²³https://github.com/knowsys/nemo/wiki/Rule-language#distrinct-variables

Alle Aggregationen werden in der Funktion translate_group_by() zusammengeführt:

```
collect_aggregations(?b, ?var_26, ?e0)
:- bgp(?a, ?b), sum_aggregate(?b, ?var_26), count_aggregate(?b, ?e0) .
```

Dies ist ein Ausschnitt der Übersetzung von folgender Query:

```
SELECT DISTINCT (SUM(DISTINCT ?a) as ?s) (COUNT(DISTINCT ?a) as ?c) ?b WHERE { ?a ex:p ?b . } GROUP BY ?b
```

Die Variablen für die Ergebnisse der Aggregationen sind von spargebra generierte Hilfsvariablen und werden in der nachfolgenden extend Operation verwendet. Die Namen wurden im Beispiel manuell gekürzt. Außerdem ist zu beobachten wie so eine Variable im Beispiel mit 2 beginnt und damit nicht valide in Nemo ist und mit einem Präfix var_ valide gemacht wurde.

Г.	1 1 4	۸ ، ۱	1 .		Illunterscheidung	
1 110	vorravtan i	UGGRAGATIANAN	Mardan Ir	n dinar La	III INTARCCHAIMLING	arzaliat.
DIC	NOLLENIELL /	7221 62011011611	WEIGELLII		1110116613616100118	CIZCUEL.

Distinct	spargebra Expression	Nemo Aggregation	Übersetzungsfunktion	idempotent
Ja	Count mit expr = None	-	translate_count_all()	-
Ja	Count sonst	#count	<pre>translate_aggregation()</pre>	Nein
Ja	Sum	#sum	<pre>translate_aggregation()</pre>	Nein
Ja	Min	#min	<pre>translate_aggregation()</pre>	Ja
Ja	Max	#max	<pre>translate_aggregation()</pre>	Ja
Nein	Count mit expr = None	-	translate_count_all()	-
Nein	Count sonst	#count	<pre>translate_aggregation()</pre>	Nein
Nein	Sum	#sum	<pre>translate_aggregation()</pre>	Nein
Nein	Min	#min	<pre>translate_aggregation()</pre>	Ja
Nein	Max	#max	<pre>translate_aggregation()</pre>	Ja

Die Fälle mit DISTINCT verwenden dabei das inner Prädikat, welches mit der translate_pattern() Funktion erstellt wurde, als relevantes Zwischenergebnis und die Fälle ohne DISTINCT verwenden das inner_multi Prädikat, welches mit der translate_pattern_multi() Funktion erstellt wurde (siehe Abschnitt 3.7). In der Tabelle gibt es keine Angabe der Nemo Aggregation oder Idempotentheit für die translate_count_all() Funktion, da diese keine solchen Parameter erfordert.

Die im SPARQL Standard vorgesehenen Aggregationen Avg, GroupConcat und Sample werden nicht unterstützt, wobei zumindest Avg leicht aus Sum und Count implementierbar wäre.

Andere Ergebnisprädikat-Typen außer SolutionSet werden durch Konvertierung unterstützt. (Abschnitt 3.6)

3.7.12 Order By

Andere SPARQL zu Datalog Übersetzungen [2] greifen zur Implementierung der Order By Operation auf Features der Datalog Engine zurück. Dies wäre in einer anderen Version von Nemo ähnlich denkbar. In dieser Arbeit wird untersucht, welche SPARQL Features sich mit der Verwendeten Nemo Version umsetzen lassen. In diesem Fall ist Order By eine der komplexesten Operationen. Grundsätzlich stellt sich die Frage, wie überhaupt eine Reihenfolge in der Mengen-Semantik von Nemo dargestellt werden kann. Der verwendete Ansatz, wobei die erste Stelle eines Prädikats der Index des Ergebnisses angibt, wurde bereits in der gesamten Arbeit verwendet und insbesondere in Abschnitt 2.3 vorgestellt. Als Alternative wurde auch eine separate Nachfolgerrelation in Betracht gezogen. Diese lässt sich jedoch leicht aus der Index Repräsentation erstellen, da der Nachfolger Index einfach durch Addition von eins berechnet werden kann. Umgekehrt ließe sich der Index aus einer Nachfolgerelation zwar auch berechnen, ist jedoch in der Praxis erheblich langsamer, weswegen der andere Ansatz gewählt wurde.

Dieser Performanceunterschied ist durch folgendes Programm demonstriert:

```
n(0) . n(?i+1) :- n(?i), ?i + 1 < 100000 . m(?i+1) :- n(?i), ?i + 1 < 100000 .
```

Die erste Regel benötigt dabei auf einem Testsystem²⁴ ca. 13 min, während die zweite nur ca. 14 s benötigt, obwohl beide grundsätzlich sehr ähnlich sind. Die erste Regel ist jedoch signifikant langsamer, da sie durch die Rekursion für jeden neuen Wert neu aufgerufen werden muss. Führt man eine quadratische Regression auf gemessenen Zeiten in Abhängigkeit vom Maximalwert für ?i bei der ersten Regel durch, kann eine sehr gut passende quadratische Funktion gefunden werden, obwohl die Regel auf den ersten Blick linear aussieht. Wenn man den Eingabewerten einen fortlaufenden Index zuordnet, z.B. beim Sortieren, muss darauf geachtet werden, dies nicht wie in der ersten Regel zu tun. Zwar ist der Reasoningprozess in Nemo sequentiell, allerdings zeigt der Test, dass eine Regel, die einmal evaluiert wird und viele Ergebnisse produziert, erheblich effizienter ist als eine Regel, die häufig evaluiert wird und immer nur wenige neue Ergebnisse liefert²⁵. Schwer parallelisierbare Algorithmen neigen dazu, Regeln zu beinhalten, die häufig aufgerufen werden müssen. Viele klassische Sortierverfahren sind nicht gut parallelisierbar, was einer effizienten Implementierung in Nemo entgegenwirkt. Außerdem basieren viele Sortierverfahren darauf, dass ein beliebiger Wert, wie z.B. der erste Wert in der Liste als Pivotelement, "genommen" wird. Gibt es jedoch grundsätzlich keine Reihenfolge, ist dies nicht umsetzbar. Nemo bietet keine Möglichkeit, ein beliebiges Tupel eines Prädikats auszuwählen. Zwar kann mittels Aggregation z.B. der kleinste Wert "genommen" werden. Dies verhindert jedoch die Rekursion einer Regel, da sonst ein nicht stratifiziertes Programm entsteht und innerhalb eines Sortiervorgangs muss prinzipiell beliebig oft ein Wert "genommen" werden, was Rekursion unvermeidbar macht.

Es wurden einige Algorithmen prototypisch implementiert. Einige Kandidaten werden hier vorgestellt. Die Tests wurden auf einer Permutation der Zahlen 0 bis n, bzw. deren Dezimaldarstellung, durchgeführt. Die gemessenen Zeiten verändern sich in mehreren Messversuchen nur wenig und stellen die Zeit ohne Generieren und Laden der Eingabedaten dar. Bei den Nemo-Programm Auszügen bildet das Prädikat "num" die zu sortierenden Zahlen bzw. das Prädikat "s" die zu sortierenden Strings.

²⁴Alle Test in diesem Kapitel wurden auf einem System mit AMD Ryzen 9 3900X CPU und 32 GiB RAM (Dual-Channel DDR4, 2133 MT/s) durchgeführt

²⁵Die Eliminierung von Duplikaten ist teilweise verantwortlich für dieses Verhallten sie wird jedoch nur mit etwa 50% der Ausführungszeit in Nemos Report aufgeführt.

3.7.12.1 Hacker Mans Sort

Hacker-Mans-Sort sortiert die Eingabe nicht selbst, sondern verschafft sich Zugang zu der bereits sortierten Eingabe. In Nemo ist dies prinzipiell möglich, da die Prädikate in Nemo bereits sortiert gespeichert werden. Es ist möglich diese Sortierung sichtbar zu machen, da BNode Namen in der Reihenfolge in der die Werte gespeichert sind sequentiell generiert werden, z.B. _:5, _:6, _:7 ...

```
\begin{array}{l} \text{dummy(d)} \ . \\ \text{bnode(!x):- dummy(d)} \ . \\ \text{proto\_sort(!x, ?i, ?oi):- num(?i, ?oi)} \ . \\ \text{shifted(INT(STR(?x)), ?i, ?oi):- proto\_sort(?x, ?i, ?oi)} \ . \\ \text{min\_id(\#min(?id)):- shifted(?id, ?i, ?oi)} \ . \\ \text{sorted(?id - ?m, ?oi, ?i):- min\_id(?m), shifted(?id, ?i, ?oi)} \ . \end{array}
```

Auf 5 Mio. Zahlen dauerte das Sortieren nur 13 Sekunden. Das Sortierverfahren ist jedoch schwer, mit unterschiedlichen Typen standardkonform umzusetzen und funktioniert beispielsweise nicht mit Strings, welche nach Nemos internen Indizes und nicht alphabetisch sortiert werden.

3.7.12.2 Sort by Counting

Dies ist der einfachste Sortieralgorithmus in Nemo. Der Index eines Elements ergibt sich aus der Anzahl der Elemente, die kleiner sind.

```
sorted(\#count(?other), ?s) := s(?s), s(?other), COMPARE(?other, ?s) < 0.
```

Das Verfahren lässt sich grundsätzlich auf allen Datentypen, für die eine Vergleichsoperation möglich ist, anwenden. Theoretisch ist es sogar möglich, für Nemo die #count Aggregation in konstanter Zeit durchzuführen, wenn die Werte bereits korrekt sortiert gespeichert sind. In der Praxis hat das Verfahren jedoch eine quadratische Laufzeit und ist dadurch sehr langsam für große Eingaben. 10.000 Strings lassen sich in 30 s sortieren, bei 100.000 Strigs waren nach etwa einer Stunde die 32 GB Arbeisspeicher erschöpft.

3.7.12.3 Bitonic Sort

Wie bereits erwähnt, bieten sich parallelisierbare Algorithmen für die Implementierung in Nemo an. Bitonic-merge-sort ist ein paralleler Sortieralgorithmus. Die hier vorgestellte Variante wurde in mehreren Iterationen optimiert. Die Kommentare erklären die grobe Funktionsweise:

```
% Look-Up-Table-Ergebnis ist 1 wenn Eingabe negativ
lut(-3, 1) .
lut(-2, 1) .
lut(-1, 1) .
lut(0, 0) .
lut(1, 0) .
lut(2, 0) .
lut(3, 0) .
```

```
% erste Position von s ist der fortlaufende initiale Index
len(\#max(?i) + 1) :- s(?i, ?v).
% shape(?t, ?w, ?s) mit
% ?t Zeitschritt,
% ?w Weite der blauen äußeren Box,
% ?s Größe der braunen bzw. roten Subbox
shape(0, 1, 1).
shape(?t + 1, ?w * 2, ?w * 2)
:- shape(?t, ?w, 1), len(?l), ?w * 2 < ?l.
shape(?t + 1, ?w, ?s / 2)
:- shape(?t, ?w, ?s), ?s >= 2.
% compare(?t, ?i1, ?i2)
% Vergleichen der Werte am Index ?i1 und ?i2 zum Zeitschritt ?t
compare(?t, ?i, ?i + 2*?w - 1 - 2*REM(<math>?i, 2*?w))
:- shape(?t, ?w, ?w), s(?i, ?v), REM(?i, 2 * ?w) < ?w.
compare(?t, ?i, ?i + ?s)
:- shape(?t, ?w, ?s), s(?i, ?v), REM(?i, 2 * ?s) < ?s, ?s < ?w .
% sorting(?t, ?p_original, ?p) zum Zeitschritt ?t ist der wert,
% welcher anfangs am Index ?p_original war, nun am Index ?p
sorting(0, ?p, ?p) := s(?p, ?v).
comparison(
    ?t, ?p1, ?p2, ?op1, ?op2,
    2*COMPARE(?v1, ?v2) - COMPARE(STR(?op2 - ?op1), ".")
:- compare(?t, ?p1, ?p2), sorting(?t, ?p1, ?op1),
   sorting(?t, ?p2, ?op2), s(?op1, ?v1), s(?op2, ?v2).
sorting(?t+1, ?p1, ?op1 * ?r + ?op2 * (1-?r)),
sorting(?t+1, ?p2, ?op2 * ?r + ?op1 * (1-?r))
:- comparison(?t, ?p1, ?p2, ?op1, ?op2, ?rp), lut(?rp, ?r) .
sorting(?t+1, ?p, ?op)
:- sorting(?t, ?p, ?op), compare(?t, ?p, ?p2), len(?1), ?p2 >= ?1.
% extrahieren der Sortierung aus dem letzten Zeitschritt
end(\#max(?t) + 1) :- shape(?t, ?w, ?s).
sorted(?p, ?op, ?v) := end(?t), sorting(?t, ?p, ?op), s(?op, ?v).
```

Bitonic-merge-sort hat jedoch eine etwas schlechtere Laufzeit als n*log(n), außerdem wird Zeit aufgewendet in den Prädikaten shape und compare um das Sorting-Network aufzubauen, bevor der eigentliche Sortiervorgang beginnt. Dennoch ist es das schnellste bekannte vergleichsbasierte Sortierverfahren in Nemo. Es benötigte 61 Sekunden auf 100.000 Eingabewerten. Ein weiterer Nachteil ist, dass eine initiale Reihenfolge gegeben sein muss, zwar lässt sich eine solche in Nemo mit dem oben vorgestellten Hacker-Mans-Sort für belie-

bige Eingabetypen generieren, jedoch kommt eine saubere Lösung, wie das als nächstes vorgestellte Radix-sort, ohne initiale Reihenfolge aus.




Abbildung 3.3: Visualisierung des Bitonic Sort Netzwerks https://en.wikipedia.org/wiki/Bitonic_sorter#Alternative_representation

3.7.12.4 Radix Sort

Radix-sort stellt jeden zu sortierenden Wert in einer gemeinsamen Baumstruktur dar, wobei Werte mit gemeinsamen Präfix sich den entsprechenden Anfang des Pfades von der Wurzel zum Blatt, welches für den Wert steht, teilen. Die vorgestellte Implementierung wurde umfangreich optimiert. Es wird nicht für jeden Character ein neuer Knoten in der Baumstruktur erzeugt. Stattdessen wird für den gesamten Wert zunächst nur ein Knoten erzeugt und Werte werden, nur wenn erforderlich, rekursiv in Präfix und Suffix halbiert. Ein Split ist erforderlich, wenn ein Knoten mehrere Kindknoten hat. Dies wirkt zunächst schwierig ohne Aggregation, welche rekursiven Aufbau der Baumstruktur wegen nicht stratifiziertem Programm verhindern würde, zum Zählen der Kindknoten. Folgendes Pattern in Nemo ist jedoch erstaunlich effizient in der verwendeten Nemo Version (nicht quadratisch in Laufzeit):

```
multiple_values(yes) :- values(?a), values(?b), ?a != ?b .
```

Auf der nächsten Doppelseite ist der Radix-Sort Algorithmus in Nemo abgebildet. Es wurden wieder erklärende Kommentare eingefügt.

```
% Die maximale Länge definiert gemeinsame Split Punkte
% der Strings; Aufrunden auf Zweierpotenz wäre ineffizienter
1(\#\max(STRLEN(?s))) :- s(?s).
% === BAUEN DES RADIX BAUMES ===
% Zu Beginn ist jeder Eingabestring ein Kind der Wurzel ("")
% und geht von 0 bis zur maximalen Länge ?1
child("", 0, ?1, ?s) :- s(?s), 1(?1).
% Gibt es zu einem ?parent betrachtet von ?start bis
% ?end mehrere children?
multiple_children(?parent, ?start, ?end)
:- child(?parent, ?start, ?end, ?a),
   child(?parent, ?start, ?end, ?b),
   ?a != ?b .
% Ein ?parent von ?start bis ?end ist in die Knoten von
% ?start bis mid und von mid bis ?end zu teilen, wenn er
% mehrere Kinder hat
split(?parent, ?start, ?start + (?end - ?start) / 2, ?end)
:- multiple_children(?parent, ?start, ?end),
   ?end - ?start >= 2 .
% Ein zu splittender String wird gesplittet
child(?parent, ?start, ?mid, ?mid_str),
child(?mid_str, ?mid, ?end, ?child)
:- child(?parent, ?start, ?end, ?child),
   split(?parent, ?start, ?mid, ?end),
   ?mid_str = SUBSTRING(?child, 1, MIN(?mid, STRLEN(?child))) .
% Welche Strings wurden später nicht mehr gesplittet?
min_end(?parent, ?start, #min(?end))
:- child(?parent, ?start, ?end, ?child) .
true_child(?parent, ?child)
:- min_end(?parent, ?start, ?end),
   child(?parent, ?start, ?end, ?child),
   ?parent != ?child .
% === ZÄHLEN UND SORTIEREN DER KINDER ===
% jeder Eingabe-String wird zu seinem Knoten gezählt
at(?s, ?s) :- s(?s).
% Jeder Eingabe-String wird zusätzlich zu seinem Parent gezählt
at(?parent, ?s) :- at(?child, ?s), true_child(?parent, ?child) .
```

```
% Zählen der Strings an einem Knoten
% dies ermöglicht später das Generieren des Indexes mit
% deutlich weniger Regelaufrufen (in "parallel")
count(?node, #count(?s)) :- at(?node, ?s) .
% sortieren der Kinder durch "sort by counting"
child_index(?parent, ?child, #count(?other))
:- true_child(?parent, ?child),
   true_child(?parent, ?other),
   COMPARE(?other, ?child) <= 0 .</pre>
% === GENERIEREN DES INDEX ===
% Der erste String unter der Wurzel hat den Index 0
index(0, "").
% Das erste Child hat den Index wie das Parent
% wenn das Parent keiner der Eingabe Strings ist
index(?i, ?child)
:- index(?i, ?parent),
   child_index(?parent, ?child, 1),
   ~s(?parent) .
% Das erste Child hat den nächsten Index nach dem Parent
% wenn das Parent einer der Eingabe-Strings ist
index(?i + 1, ?child)
:- index(?i, ?parent),
   child_index(?parent, ?child, 1),
   s(?parent) .
% Das nächste Kind hat den Index, der um die Anzahl der
% Strings unter dem vorhergehenden Kind größer ist.
% Dadurch, dass die Anzahl der Strings unter dem vorhergehenden Kind
% bereits bekannt ist, kann die Indexberechnung unter dem
% nächsten Kind direkt beginnen, was den Vorgang erheblich
% effizienter macht.
index(?i + ?c, ?next)
:- index(?i, ?before),
   count(?before, ?c),
   child_index(?parent, ?before, ?child_i),
   child_index(?parent, ?next, ?child_i+1) .
% filtern aller Indizes nach solchen, die für das Ergebnis
% relevant sind
sorted(?i, ?s) := index(?i, ?s), s(?s).
```

Dieser Algorithmus benötigt nur 26 Sekunden für 1 Mio. Strings. Für 100.000 Strings benötigt er 2,4 s und für 10.000 String 0,21 s. Es besteht eine signifikante Abhängigkeit der Laufzeit von der Länge der Strings. Haben alle Strings die Länge 100, werden 100.000 Strings in 10 Sekunden sortiert. Gleiche Präfixe bzw. Suffixe haben in dieser Form des Algorithmus keinen großen Einfluss auf die Laufzeit.

3.7.12.5 SPARQL compliant Sort

Der Radix-sort Algorithmus kann als Grundlage genutzt werden, einen Sortieralgorithmus, welcher alle Datentypen korrekt sortiert, zu entwickeln. Dieser ist jedoch in seiner Rohfassung über 100 Zeilen lang. Zum Vergleich dazu ist der Radix-sort Algorithmus ist in seiner nicht für die Arbeit angepassten Formatierung 21 Zeilen lang. Deswegen wird der SPARQL compliant Sort Algorithmus hier nicht vollständig abgebildet.

Zentraler Punkt im Algorithmus ist eine "Sortiertabelle", diese hat zwei Zeilen für jede zu sortierende Variable und eine Zeile für jedes zu sortierende Tupel. Beispielsweise bei ORDER BY ?a ?b hat sie 5 Zeilen. Dabei wird für jede Variable die erste Spalte für einen Zahl basierend auf dem Datentyp und die zweite Spalte für eine Zahl zum Sortieren innerhalb des Datentyps verwendet. Die Sortierung der Eingabe basiert auf Sortierung der "Sortiertabelle" nach der ersten Spalte, wobei bei Gleichheit einer Zeile bis zur n-ten Spalte die nächste Spalte zum Sortieren verwendet wird. Die letzte Spalte der Sortiertabelle ist der ursprüngliche Index, was das Sortierverfahren stable macht und dafür sorgt, dass keine Spalten am Ende denselben Index zugewiesen bekommen, statt dem Index kann auch ein beliebiges anderes Unterscheidungsmerkmal, wie der Name eines neu generierten BNodes, verwendet werden.

Hier die Schritte des Algorithmus:

- Aufteilen der Eingabewerte in numerisch und nicht-numerisch, alle nichtnumerischen Werte werden zunächst als String konvertiert
- Sortieren aller nicht-numerischen Werte mittels Radix-sort
- · Bilden der "Sortiertabelle"
- Konvertieren der Zahlen zu Strings und korrektes Einrücken (Alignment der dezimalen einer-Position)
- bilden eines Strings für jede Zeile der "Sortiertabelle"
- · Sortieren der Strings aus der "Sortiertabelle" mittels Radix-sort
- Transformieren der Indizes im zu sortierenden Prädikat mittels der sortierten Strings aus der "Sortiertabelle"

Alle nicht numerischen Strings werden gemeinsam sortiert, der resultierende Index bildet die Zahl nach der Werte des gleichen Typs untereinander verglichen werden in der "Sortiertabelle". Zum Einrücken der Zahlen wird zunächst die Maximallänge aller Zahlen als String in einer Spalte bestimmt. Die Länge einer Zahl wird dabei nur bis zum Komma gemessen, was mit dem Ausdruck STRLEN(STRBEFORE(CONCAT(?s, "."), ".")) für eine als String konvertierte Zahl ?s berechnet werden kann. Positive Zahlen werden mit "0" und negative Zahlen werden mit "-" bis zur maximalen Länge aufgefüllt, außerdem werden alle negativen Zahlen in ihrer Reihenfolge invertiert. "-" kommt alphabetisch vor allen Zahlen, wodurch negative Zahlen vor positiven sortiert werden. "" (Space) kommt alphabetisch vor "." (Komma²⁶). Dies bewirkt, dass Zahlen mit Nachkommastellen nach Zahlen ohne Nachkommastellen sortiert werden, wenn die nächste Zahl der Spalte in der "Sortiertabelle" durch "" (Space) getrennt ist. In der letzten Spalte würde dies gelten, da Zahlen mit Komma länger sind, jedoch ist die letzte Spalte der ursprüngliche Index, welcher immer eine nicht negative ganze Zahl ist. Generell können unterschiedliche Zeilen der Strings für die Zeilen der "Sortiertabelle" unterschiedlich lang sein, wegen unterschiedlicher Nachkommalängen. Dies ist jedoch kein Problem, da nur der Vergleich von Zeilen mit gleichem Präfix und damit gleicher bisheriger Nachkommalänge relevant ist. Schließlich ist anzumerken, dass boolesche Werte in Nemo als nicht numerisch angesehen werden "true" kommt jedoch korrekt nach "false" alphabetisch.

²⁶Englisches Komma, also Punkt

Die Übersetzungsimplementierung, welche diese Nemo-Programme für beliebige OrderBy Operationen in SPARQL-Queries generiert, umfasst 180 Zeilen. Dabei entfallen 17 Zeilen auf die Berechnung des Type-Scores type_score() welcher dafür sorgt, dass der UNDEF-Marker → als erstes, dann BNodes, IRIs, Zahlen, dann Strings und zum Schluss alle verbleibenden Werte sortiert werden. 48 Zeilen entfallen auf die Implementierung des Radix-sort Algorithmus radix_sort(), 105 Zeilen auf den Sortieralgorithmus wie oben beschreiben translate_order_by_seq() und 10 Zeilen auf das Aufrufen der Implementierung im richtigen fall und Transformation der Ergebnisse für Ergebnistypen außer SolutionSequence.

3.8 Query-Formen

Es werden alle 4 SPARQL-Query-Formen SELECT, DESCRIBE, ASK und CONSTRUCT unterstützt. Spargebra unterstützt dabei, indem bereits die korrekte Projektion als SPARQL-Algebra-Opperation generiert wird. Bei SELECT sind dies die selektierten Variablen. Bei DESCRIBE ist dies die Variable, die die zu beschreibenden Werte enthält. In der Methode translate_query() des QueryTranslator Objekts wird mithilfe eines match Statements die korrekte Funktion zum Übersetzen ausgewählt. Führ SELECT bei dem direkten Kindknoten in der SPARQL-Algebra ein DISTINCT ist, oder ein SLICE von einem DISTINCT, wird die translate_pattern() Methode direkt verwendet. Bei allen anderen SELECT Queries wird die translate_pattern_seq() Methode verwendet. Die anderen Query Formen greifen auf die translate_pattern() Funktion zurück. Diese Funktionen wurden bereits in Abschnitt 3.7 vorgestellt. Die Funktionen für ASK und DESCRIBE führen einfache Post-Prozession durch. Die CONSTRUCT Funktion ist deutlich komplexer.

3.8.1 Describe

Für die DESCRIBE Query ist im SPARQL Standard frei gestellt, wie die Ergebnisse der Query beschreiben werden sollen. Die Implementierung gibt einfach alle Triples, die einen der zu beschreibenden Knoten in Subject position haben:

```
for v in get_vars(&solution){
    nemo_add!(output_graph(v, ?p, ?o) :- input_graph(v, ?p, ?o), {&solution});
}
```

solution wurde zuvor durch die translate_pattern() Methode erzeugt, output_graph ist ein zuvor erzeugtes dreistelliges Prädikat und get_vars() liefert alle Attribute des gegebenen Prädikats.

3.8.2 Ask

ASK gibt einen Boolean zurück, der angibt, ob die zugrundeliegende Query ein Ergebnis hat. Dies kann mit stratifizierter Negation in Nemo umgesetzt werden:

```
nemo_add!(dummy(0));
nemo_def!(ask(true) :- {&solution}; SolutionSet);
nemo_add!(ask(false) :- dummy(0), ~{&solution});
```

Das dummy Prädikat muss erstellt werden, da Nemo in der aktuellen Version keinen *Regel-Körper* ✓ unterstützt, welcher nur aus negierten Atomen besteht. Das solution Prädikat wurde zuvor durch die translate_pattern Methode erstellt.

3.8.3 Construct

Die CONSTRUCT Query ist in der Übersetzung die komplexeste Query Form, da sie BNodes im resultierenden Graphen unterstützt. Diese müssen zunächst erzeugt werden. Außerdem schreibt der SPARQL Standard vor, dass Triples, die nach RDF nicht valide sind, aus dem resultierenden Graph gefiltert werden müssen. Insbesondere sind in subject Position nur BNodes und IRIs und in Prädikat Position nur IRIs erlaubt. Die eigentliche Konstruktion des Graphen geschieht in einer Regel für jedes Triple im gegebenen Pattern. Im Folgenden ist ein Beispiel dargestellt:

Query:

```
prefix ex: <https://example.com/>
prefix rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns#>
CONSTRUCT {
    [a ex:Relation; rdf:subject ?s; rdf:object ?o]
} WHERE {
    ?s ex:rel ?o .
Nemo-Programm: (manuell BNODE VAR unbenannt, Präfixe und Kommentare eingefügt)
@prefix ex: <http://www.example.org/> .
@prefix rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns#> .
@prefix xsd: <http://www.w3.org/2001/XMLSchema#> .
% the guery
bgp(?s, ?o) :- input\_graph(?s, ex:rel, ?o).
% generate bnodes for each result
bnode_solution(?s, ?o, !BNODE_VAR) :- bgp(?s, ?o) .
% generate triples for each pattern triple
proto_graph(?BNODE_VAR, rdf:type, ex:Relation)
:- bnode_solution(?s, ?o, ?BNODE_VAR) .
proto_graph(?BNODE_VAR, rdf:subject, ?s)
:- bnode_solution(?s, ?o, ?BNODE_VAR) .
proto_graph(?BNODE_VAR, rdf:object, ?o)
:- bnode_solution(?s, ?o, ?BNODE_VAR) .
% filter invalid triples
construct(?s, ?p, ?o) :-
    proto_graph(?s, ?p, ?o),
    AND(OR(isNull(?s), isIri(?s)), isIri(?p)) = "true"^^xsd:boolean .
@output construct .
```

Zum Extrahieren der BNodes aus dem Pattern und zum Generieren der Regeln mit den entsprechenden Konstanten aus dem Pattern wird die translate_pattern() Methode verwendet. Diese wurde bereits in Unterabschnitt 3.7.2 vorgestellt.

4 Evaluation

In diesem Kapitel wird die in Kapitel 3 vorgestellte Implementierung hinsichtlich ihrer Korrektheit in Bezug auf den SPARQL Standard (Abschnitt 4.1) und ihren Skalierbarkeit (Abschnitt 4.2) evaluiert.

4.1 Evaluierung der SPARQL Konformität

Um die SPARQL Konformität zu testen, wurden die Queries der SPARQL 1.1 Test Suite [9] ausgeführt und mit den erwarteten Ergebnissen verglichen. Die SPARQL 1.1 Test Suite wurde von der W3C SPARQL Working Group zusammengetragen. Sie umfasst unterschiedliche Gruppen von Tests, wie z.B. eine Gruppe für Tests des Subquery-Features in SPARQL. Zu jeder Gruppe sind Metadaten in Form einer manifest.ttl Datei gegeben. Diese enthält auch Informationen über jeden einzelnen Test-Case, welche dazu verwendet werden können, eine Auswahl von relevanten Tests zu treffen. Beispielsweise sind Update-Queries und Tests unterschiedlicher Ergebnis-Serialisierungen nicht Bestandteil dieser Arbeit.

Folgende RDF Präfixe der Test Suite sind für die Auswahl der Test-Cases relevant:

Prefix	Namespace-IRI
rdf:	http://www.w3.org/1999/02/22-rdf-syntax-ns#
rdfs:	http://www.w3.org/2000/01/rdf-schema#
mf:	http://www.w3.org/2001/sw/DataAccess/tests/test-manifest#
qt:	http://www.w3.org/2001/sw/DataAccess/tests/test-query#
sd:	http://www.w3.org/ns/sparql-service-description#

Es werden alle Test-Cases vom Typ mf: QueryEvaluationTest ausgeführt, welche alle der folgenden Bedingungen erfüllen. Als "Test-Action" wird dabei der Wert der Property mf: action bezeichnet:

- die Test-Action hat keine weiteren Eingabegraphen außer den Standard Graph (gt:graphData)
- die Test-Action referenziert kein Entailment-Regime (sd:entailmentRegime)
- drei Testgruppen wurden manuell von den Tests ausgeschlossen: "Service", "JSON Result Format", "CSV/TSV Result Format"

Außerdem ergeben sich einige weitere Bedingungen durch Features, die nicht von der Testimplementierung unterstützt werden:

- die Test-Action referenziert Eingabewerte (qt:data)
- die erwarteten Ergebnisse (fm:result) sind nicht vom Typ ".ttl" keine Unterstützung von Construct Queries

Ein Test-Case wurde ausgeschlossen, da die erwarteten Ergebnisse in der Testsuite fehlten.

Die Durchführung der Tests wurde in Python implementiert. Die Implementierung wird hier kurz zusammengefasst und jeweils die Zeilenanzahl für den jeweiligen Programmteil genannt, um einen groben Einblick der Komplexität zu geben. Generell ist die Implementierung einfach gehalten und umfasst 344 Zeilen. Davon entfallen 77 Zeilen auf das Lesen und Interpretieren der Test Suite und die Auswahl der Tests. In 8 Zeilen ist eine Transformation der Eingabedaten implementiert, welche dazu verwendet werden, Datentypen mit limitierter Unterstützung in Nemo umzuwandeln. Das eigentliche Ausführen der Programme wurde in 108 Zeilen implementiert. Das zu testende Programm, welches die Übersetzung von SPARQL zu Nemo durchführt, wurde dazu in einem Modus kompiliert, welcher es erlaubt, die SPARQL-Query mittels stdin zu übergeben. Damit das Ergebnis der Übersetzung zu einem vollständigen Nemo-Programm wird, ist das Laden der Eingabedaten und das Exportieren des korrekten Ergebnisprädikats, dem Nemo Code hinzuzufügen. Als Rule-Engine wird Nemo durch das Nemo Command Line Interface aufgerufen. In 82 Zeilen werden die Ergebnisse aus Nemo mit den erwarteten Ergebnissen verglichen. Um den Vergleich durchzuführen, werden die durch Nemo in CSV-Format exportierten Ergebnisse zur RDF Repräsentation der Python Bibliothek rdflib [5] transformiert und die erwarteten Ergebnisse ebenfalls mittels rdflib geparst, wodurch ein Vergleich der gleichen Repräsentationen möglich wird. Falls die Query den String "ORDER BY" enthielt, wird die Reihenfolge der Zeilen überprüft, ansonsten findet ein Vergleich ohne Beachtung der Reihenfolge statt. Enthält die Query den String "select *", ohne Beachtung der groß und Kleinschreibung, wird die Ordnung der Spalten nicht überprüft. Für das Sammeln und Ausgeben des Test-Reports werden 38 Zeilen Code verwendet. Anschließend werden die fehlerhaften Queries manuell analysiert.

Um sicherzustellen, dass das zu testende Programm nicht speziell für die Test-Suite optimiert ist, und sich die Ergebnisse somit nicht verallgemeinern lassen, wird idealerweise das zu testende Programm nach der ersten Ausführung der Evaluation nicht mehr verändert. Allerdings geht dadurch das Potenzial verloren, durch die Tests identifizierte Fehler zu beheben, was zu einem insgesamt besseren Programm führen könnte. Als Kompromiss wird hier der Prozess der Evaluation mit initialen Ergebnissen, daraus resultierenden Änderungen am Programm und wiederum daraus resultierenden Ergebnissen der Evaluation vorgestellt.

Zunächst die initialen Ergebnisse, wie diese bei der Testausführung generiert wurden:

```
Total: 169
Failed: 35
Errored: 86
    MultiPatternNotImplemented(Group) - 26
    SequencePatternNotImplemented(Minus) - 5
    MultiPatternNotImplemented(Minus) - 1
    FunctionNotImplemented - 26
    AggregationNotImplemented - 3
    MultiPatternNotImplemented(Path) - 15
    ParseError - 10
Success: 48
Empty Groups: 22
```

Es erfolgt die Erklärung der einzelnen Anzahlen im Test-Report:

- Total: Anzahl der von der Testimplementierung als relevant ausgewählten Test-Cases
- Failed: Test-Cases, bei denen das erwartete und das tatsächliche Ergebnis nicht übereinstimmen
- Errored: Test-Cases, bei denen die Übersetzung der Query einen Fehler verursachte. Die genauen Fehler werden dabei in Typen kategorisiert. Ein Fehler-Typ ergibt sich aus der Fehlermeldung bis zum ersten "" Zeichen. Diese Fehler-Typen werden mit der jeweiligen Häufigkeit einzeln aufgelistet. "FunctionNotImplemented" und "AggregationNotImplemented" Fehler wurden zu einem Fehler-Typ zusammengefasst
- Success: Erfolgreiche Test-Cases
- Empty Groups: 22 Gruppen testen ausschließlich Features, welche von der Test-Implementierung als nicht relevant verworfen wurden, daher enthalten diese Gruppen keine Tests

Die zehn Fehler beim Parsing der SPARQL-Query (ParseError) werden direkt von der verwendeten spargebra Bibliothek beim Transformieren in SPARQL-Algebra verursacht. Die entsprechenden Oueries sind tatsächlich nicht syntaktisch korrekt und nicht offiziell Teil der Test-Suite. Dies wurde jedoch nicht bei der Testauswahl erkannt. Alle weiteren Errors sind auf nicht implementierte Features zurückzuführen. Die nicht implementierten Funktionen sowie die nicht implementieren Aggregationsfunktionen GroupConcat und Sample sind dabei absichtlich, da diese nicht von Nemo unterstützt werden. Die Implementierungen mit Beachtung der Multiplizität bzw. Reihenfolge (ohne DISTINCT, genannt "MultiPattern" bzw. "SequencePattern") für Group, Minus und Path wurden jedoch bei der Implementierung übersehen und wurden deshalb direkt nachgeholt, und wurden bereits in Kapitel 3 erläutert. Während der Implementierung dieser Features wurden nicht die Queries der Evaluation betrachtet, sondern wie bei allen anderen Features die Rust-Tests, wie in Abschnitt 2.5 beschrieben, erweitert. Außerdem wurde erst nach diesem initialen Test Durchlauf die Nichtbeachtung der Spaltenreihenfolge für Queries mit SELECT * beim Vergleichen der Ergebnisse implementiert. Durch diese Änderungen ergibt sich folgendes Ergebnis. Die Statistiken für leere Gruppen ändern sich nicht und werden daher nicht angegeben:

```
Total: 169
Failed: 41
Errored: 46
    FunctionNotImplemented - 26
    AggregationNotImplemented(GroupConcat) - 3
    AggregationNotImplemented(Avg) - 4
    AggregationNotImplemented(Sample) - 3
    ParseError - 10
Success: 82
```

Es ist zu beobachten, dass damit alle Fehler durch fehlende Features in Nemo erklärt werden können. Die Failed queries wurden manuell analysiert und nach Sorten von Fehlern eingeteilt:

- 16 Fehler: fehlende Unterstützung von Strings mit Language Tags in Nemo-Funktion
- 13 Fehler: fehlerhafter Umgang mit Datentypen in Nemo
- 7 Fehler: Bug in der ORDER-BY Übersetzung
- 2 Fehler: 0-Tupel statt leere Ergebnisse
- · 2 Fehler: Fehler in der Testimplementierung

Der Bug in der ORDER-BY Übersetzung wurde darauf hin behoben. Die meisten Fehler resultieren durch fehlende Implementierung für bestimmte Literale in Nemo. Da dies nicht die Übersetzung von SPARQL nach Nemo, sondern Nemo selbst evaluiert, wurde eine "Soft" Modus der Test-Cases eingeführt. Ein Test Case ist im Soft-Modus erfolgreich, wenn er erfolgreich ist, nachdem im Eingabe-Graph alle Zahlen zu xsd: double konvertiert werden und alle Strings zu Plain-Strings konvertiert werden. Da die erwarteten Ausgabedaten damit nicht mehr gültig sind, wurden neue erwartete Ausgabedaten für den Soft-Modus durch Ausführen der Query mittels rdflib generiert. Dieser Soft-Modus sorgte für eine bessere Evaluation der Übersetzung, da einige Fehler durch Fehler in Nemo verdeckt wurden. In der Übersetzung konnte so ein Fehler im Umgang mit dem UNDEF-Marker → in der MINUS Implementierung gefunden und behoben werden. Im Folgenden ist der finale Test-Report im Soft-Modus dargestellt:

Total: 169
Failed: 14
Errored: 46

FunctionNotImplemented - 26 AggregationNotImplemented - 10

ParseError - 10

Success: 109

Die 14 Fehler wurden wieder manuell analysiert und kategorisiert:

- 1 Fehler: Fehlende Unterstützung von Strings mit Language-Tags in Nemofunktion
- 5 Fehler: Fehlerhafter Umgang mit Datentypen in Nemo
- 3 Fehler: 0-Tupel statt leere Ergebnisse
- 3 Fehler: Fehler in der Testimplementierung
- · 2 Fehler: Bug in der STRBEFORE Implementierung in Nemo

Es ist zu beobachten, dass die Fehler durch den Umgang mit Literalen in Nemo deutlich weniger geworden sind, diese jedoch dennoch auftreten, da nicht jedes Literal aus den Eingabedaten kommt und somit der Soft-Modus keinen Effekt hat. Die drei Fehler in der Testimplementierung kommen daher, da BNodes beim Vergleich der tatsächlichen Ergebnisse mit den vorgegebenen Ergebnissen nicht richtig zugeordnet wurden, die Ergebnisse in diesen drei Fällen sind jedoch korrekt. Die zwei Fehler in STRBEFORE treten durch fehlerhafte Unicode Unterstützung in dieser Funktion auf. STRBEFORE ("français", "s") ergibt den String "frança" mit fehlendem "i" in der verwendeten Version von Nemo. In drei Fehlerfällen ist das scheinbar erwartete Ergebnis? eine leere Menge jedoch das tatsächliche Ergebnis eine einelementige Menge mit dem leeren Tupel. Dies konnte auf einen Fehler in rdflib zurückgeführt werden, welche das Query Ergebnis in diesem Sonderfall nicht korrekt einliest, die Übersetzung ist korrekt. Insgesamt 6 der 14 Fehler sind also keine Fehler in der Übersetzung. Alle verbleibenden 8 Fehler sind Fehler in Nemo bzw. könnten durch einen verbesserten Soft-Modus gelöst werden.

Die ermittelten Ergebnisse können unterschiedlich interpretiert werden. Zum einen wurde, mit dem beschriebenen Verlauf, die Implementierung für die Testsuite optimiert. Dadurch ist theoretisch nicht auszuschließen, dass auf einer anderen Test Suite ähnlich viele Fehler wie bei den initialen Testergebnissen auftreten würden. Die SPARQL 1.1 Test Suite deckt andererseits einen signifikanten Anteil der SPARQL Features ab, auch wenn einige in Kapitel 3 erwähnte Abweichungen vom Standard nicht gefunden wurden. Sodass, als Ergebnis der Evaluierung, die Übersetzung der SPARQL-Queres im weitgehend als standardkonform angesehen werden kann. Die Laufzeit aller 169 Test-Cases beträgt etwa 7 Sekunden.

4.2 Evaluierung der Skalierbarkeit

Zum Evaluieren der Skalierbarkeit wurden Wikidata Beispielqueries übersetzt und mit Nemo ausgeführt. Da Nemo alle Daten vollständig im Arbeitsspeicher vorhält, ist dafür, aufgrund der Größe von Wikidata, ein spezielles Testsystem notwendig. Das verwendete Testsystem verfügt über 768 GiB RAM (Quad-Channel DDR4, 1866 MT/s) und zwei Intel Xeon E5-2637 v4 CPUs. Als Eingabe Graph wurde der latest-truthy Wikidata Dump vom 22.11.2024 genutzt und daraus alle Triples entfernt, welche nicht-englische Language Tags beinhalten. Dies führt zu einem Datensatz mit etwa 3,3 Milliarden Tripel.

Das Programm zum Ausführen der Tests ist grundlegend ähnlich zu dem in Abschnitt 4.1 vorgestellten. Jedoch wurden einige zusätzliche Features erforderlich:

- Das Programm zum Ausführen der Testsuite ist in der Lage nach einem Crash oder absichtlichen Beenden die Arbeit wieder aufzunehmen. Dabei wird mit der nächsten Query nach der Query, welche den Crash verursachte begonnen.
- Es wurden zahlreiche Daten zur späteren Auswertung erfasst und inkrementell in json-Format in eine Datei geschrieben.
- Zum Vergleich der Ergebnisse werden die Queries außer in Nemo auch auf einer Blazegraph-Instanz (aufgesetzt, mit den im Quick_Start Guide¹ angegebenen Parametern) ausgeführt.
- Ein Python Script überwacht den Speicher und startet das Script, welches die Tests ausführt neu, falls zu viel Speicher verwendet wird.
- Ein separates Bash-Script schreibt alle 5 Minuten die Speichernutzung in eine Log-Datei zur späteren Nachvollziehbarkeit und dem Erkennen von Fehlern beim Neustarten des Programms.
- Ein Cron-Job sendet Benachrichtigungen über neu begonnene Queries. Zu lange laufende Queries wurden manuell (frühestens nach 30 Stunden) abgebrochen.
- Um eine gleichmäßige Verteilung der ausgeführen Queries zu gewehrleisten, wird jede 10. Query ausgeführt. Beim Starten des Programmes kann ein Offset angegeben werden, welche Query als erstes ausgeführt werden soll.

Die Wikidata Example Queries wurden über die Wikidata Wiki API angefragt und mittels des beautiful soup Paketes² extrahiert. Zu jeder Query wurde aus dem darüberliegenden Titeln ein Name generiert. Aus den ersten drei Wörtern des Titels und einem Hash wurde für jede Query eine ID, der "unique_name" generiert. Die somit erstellte Test Suite umfasst 374 Queries. Damit die extrahierten SPARQL-Queries übersetzt werden können, müssen ihnen noch die Wikidata IRI-Präfixe angefügt werden. Außerdem müssen die SERVICE Operationen entfernt werden. Dies geschieht mit einem regulären Ausdruck. SPARQL ist keine reguläre Sprache, wodurch in komplexeren Fällen die SERVICE Operation nicht korrekt entfernt wurde.

¹https://github.com/blazegraph/database/wiki/Quick_Start

²https://www.crummy.com/software/BeautifulSoup/bs4/doc/

Innerhalb etwa eines Monats wurden etwa ein Drittel, konkret 121 von 374, der Queries evaluiert. Davon wurden 22 Queries vorzeitig abgebrochen und lieferten somit keine Ergebnisse. 9 davon wurden aufgrund ihrer langen Ausführungszeit abgebrochen und die restlichen 13 aufgrund von hohem Speicherbedarf. Die restlichen 99 Queries lieferten Ergebnisse, wobei 62 davon erfolgreich waren und 37 einen Fehler beim Übersetzen lieferten. Im Folgenden sind die auftretenden Fehler beim Übersetzen dargestellt und in Kategorien eingeteilt:

- 10 Queries: Invalide Query durch Entfernen der SERVICE Operation
- 9 Queries: Fehlende Implementierung von Aggregationen (7x Sample, 2x GroupConcat)
- 8 Queries: Parse Error in spargebra (auch teilweise durch falsches entfernen der SERVICE Operation)
- 6 Queries: Fehlende Standard Funktionen (2x Replace(), 2x Now(), 1x LangMatches(), 1x Rand())
- · 4 Queries: Fehlende Funktionen, welche Erweiterungen des SPARQL Standards sind

Für die 62 erfolgreich ausgeführten Queries wurde die Korrektheit der Ergebnisse abgeschätzt, indem die Anzahl der Ergebnisse von Nemo und Blazegraph verglichen wurde. Bei 55 der 62 Queries gibt es übereinstimmende Ergebnisse, bei sechs Queries gibt es kein Blazegraph-Ergebnis und bei einer Query ist das Ergebnis falsch, da diese einen Vergleich zwischen Datum-Literals ausführt, welcher in Nemo nicht unterstützt wird. Somit lässt sich, auch unter Berücksichtigung der Evaluation in Abschnitt 4.1 abschätzen, dass etwa die Hälfte der Queries, welche getestet wurden, erfolgreich mit korrektem Ergebnis beantwortet werden konnten. Dies ist ein leicht besseres Ergebnis als auf den konstruierten Tests in Abschnitt 4.1 ohne Soft-Modus.

Etwa 10 Tage wurden für die erfolgreichen Queries zusammen an Nemo-Reasoning-Zeit benötigt. Davon wurden 8 Tage für das Laden der Eingabedaten benötigt. Die meiste Zeit wurde jedoch für die Queries verwendet, welche später abgebrochen wurden. Die Zeit, die das Übersetzen der Query in Nemo in Anspruch nimmt, ist vernachlässigbar. Sie betrug insgesamt, inklusive der Queries, die zu einem Fehler beim Übersetzen führten oder Abgebrochen wurden, 0,3 Sekunden.

Im Folgenden werden Ausführungszeit ohne Laden der Eingabedaten betrachtet. Das geometrische Mittel für die Ausführungszeit in Nemo beträgt 5,8 min (345 s) und für Blazegraph 273 ms. Aus dieser Perspektive ist die Query Ausführung in Nemo etwa 3 Größenordnungen langsamer. Die längste erfolgreiche Query in Nemo dauerte 11,6 stunden. Die längste erfolgreiche Query in Blazegraph dauerte 29,2 min. Es war für Blazegraph nicht nötig, eine Query wegen langer Dauer abzubrechen. Eine der Queries hängt nicht von den Eingabedaten ab und benötigt somit signifikant weniger Zeit. In Nemo benötigte diese 9 ms und in Blazegraph, inklusive Netzwerklatenz zu localhost, 12 ms.

Hier die Histogramme für die Ausführungszeiten der einzelnen Queries:




Abbildung 4.1: Histogramm der Ausführungszeiten der mit Nemo ohne Fehler ausgeführten Queries




Abbildung 4.2: Histogramm der Ausführungszeiten der mit Blazegraph ohne Fehler ausgeführten Queries

Die Nemo-Zeitstatistiken wurden mit den Regeln zusammengeführt, aus deren Namen auf die SPARQL Features geschlossen werden konnte. Hier die Gesamtausfürungszeit der jeweiligen Features während aller erfolgreichen Queries:

Name	Zeit Gesamt	Anzahl mit Zeit ≥ 1 ms	Gesamtanzahl
sort_string	10 ms	2	16
child_index	12 ms	4	32
left_join	19 ms	2	30
effective_boolean_value	20 ms	7	56
left_join_proto	24 ms	3	30
dummy_dependency	30 ms	1	32
has_child	32 ms	6	64
sum_aggregate	36 ms	1	1
count_aggregate	39 ms	2	5
collect_aggregations	41 ms	2	7
str	46 ms	1	5
regex	49 ms	1	1
index	61 ms	12	96
filter	119 ms	4	21
and	371 ms	12	36
lang	473 ms	6	16
equal	741 ms	22	75
if_expression	742 ms	8	8
extend	958 ms	9	34
multi	2.3 s	3	14
proto_extend	2.5 s	10	34
path_alternative	5.9 s	11	12
map	12.4 s	10	41
sequence_start	32.7 s	4	47
base_join	42.1 s	4	24
lcase	53.3 s	1	4
var	1.1 min	13	73
partial_exists	1.1 min	7	30
diff	1.1 min	4	26
recursive	1.3 min	3	4
reverse_recursive	1.7 min	20	28
exists	1.8 min	9	60
pre_index	2.1 min	10	92
sequence_shifted	2.1 min	7	47
sequence_proto	3.2 min	7	47
projection	3.3 min	7	64
proto_projection	3.4 min	6	42
union	3.5 min	12	80
sequence	6.3 min	12	93
one_or_more_path	1.3 h	9	18
join	7.2 h	31	76
path_property	9.2 h	29	29
bgp	9.4 days	126	129

In der Tabelle ist der Name des Features (normalisierter Name des Prädikats im Regel-Kopf, siehe Kapitel 3 für Erklärungen der Features), die Gesamtzeit des Features, die Anzahl, wie

oft das Feature mit einer Zeit über gerundet 0 ms und wie oft es insgesamt aufgetreten ist. Etwa die Hälfte der Features hat eine Gesamtzeit von unter 10ms und wird daher nicht in der Tabelle gelistet. Es ist anzumerken, dass Nemo die Importzeit der Daten mit zum jeweiligen Prädikat zählt, bei dem der Import stattgefunden hat. Dennoch ist nahezu die gesamte Ausführungszeit auf die Basic Graph Pattern Evaluierung zurückzuführen.

Die Beobachtung, dass die meiste Zeit durch Join-Opperationen des Input-Graphen mit sich selbst aufgewandt wird, motiviert folgende Grafik. Sie stellt die durchschnittliche Ausführungszeit einer Query in Abhängigkeit der Anzahl des Strings "input_graph" im Programm dar:




Abbildung 4.3: Durchschnittliche Ausführungszeit in Abhängigkeit der Anzahl, mit welcher der Eingabe Graph im Nemo-Programm verwendet wird

Die einzelnen Punkte stehen für die einzelnen Queries. Es wurden erfolgreiche Queries betrachtet. Es ist zu beobachten, dass sich im Durchschnitt eine gleichmäßige Kurve ergibt. Insbesondere für den Bereich bis etwa vier Verwendungen des input_graph Prädikats ist dies eine sehr gute Heuristik, um eine effiziente Query zu erkennen. Die Grafik ist in beide positiven Richtungen abgeschnitten. Das höchste Vorkommen an input_graph Prädikaten beträgt 11. Dort existiert ein weiterer Durchschnittswert, welcher deutlich über der sich ergebenden Kurve liegt, ähnlich wie bei 7. Bei 7 liegen zwei Queries über 120 min. Als besonderes Feature konnte für diese identifiziert werden, dass BNodes im Basic Graph Pattern enthalten und somit eine Aggregation zur Berechnung der Multiplizität in Nemo ausgeführt werden muss. Ob dies der tatsächliche Grund für die Spitze bei 7 ist, ist nicht endgültig geklärt. Die beiden lange laufenden Queries mit 7 Verwendungen des input_graph Prädikats werden wie die meisten anderen Queries auch von der Ausführung eines Basic Graph Patterns dominiert. Zufall wäre bei der geringen Datenlage und hohem Spread auch eine valide Erklärung.

Im Gegensatz zur Anzahl der input_graph Vorkommen ist die Anzahl der Ergebnisse der Query eher ein schlechter Indikator für die Laufzeit:

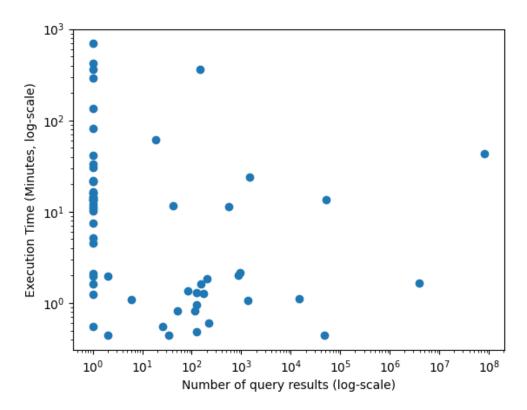


Abbildung 4.4: Keine Abhängigkeit zwischen Ausführungszeit und Anzahl der Ergebnissen

Um die Grafik zu erzeugen wurde die Query, welche nicht vom Eingabe-Graph abhängt, entfernt, da sie selbst auf der logarithmischen Achse stark von den restlichen Ergebnissen abweicht. Außerdem wurden alle Ergebnis-Anzahlen um eins erhöht, um die Queries ohne Ergebnisse auf der logarithmischen Achse darstellen zu können. Es ist zu beobachten, dass viele Queries keine Ergebnisse haben. Dies liegt daran, dass auf dem truthy Wikidata Graphen evaluiert wurde, welcher ein Subset des Gesamtgraphen darstellt und einige Prädikate nicht enthält. Dennoch ist zu beobachten, dass diese Queries teilweise lange Laufzeiten haben. Dies ist der Fall, obwohl manche im Basic Graph Pattern verwendeten Konstanten, insbesondere Prädikate, welche nicht im truthy Wikidata Graphen vorkommen, fast sofort zu einem leeren Ergebnis führen könnten.

Die bisherigen Betrachtungen haben sich auf die Ausführungszeit ohne Laden der Daten konzentriert. Hier das Histogramm für die Zeiten, für das Laden der Daten wie von Nemo angegeben:

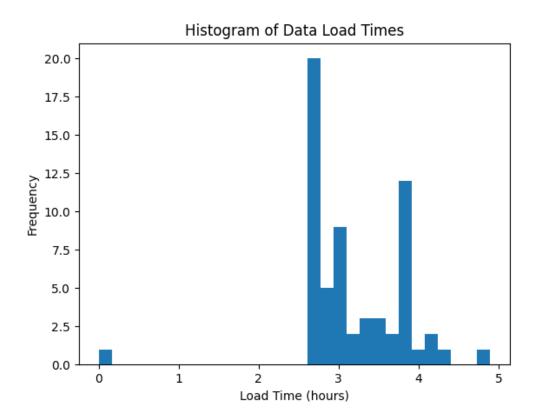


Abbildung 4.5: Histogramm der Ladezeiten des Eingabegraphen

Es ist zu sehen, dass das Laden der Daten etwa drei Stunden dauert. Zudem fällt wieder die Query, welche nicht von den Eingabedaten abhängt, auf. Dem gegenüber steht eine Ladezeit von drei Tagen in Blazegraph nach Befolgen des Quick Start Guides von Blazegraph auf dem oben beschriebenen Testsystem.

Zum Abschluss hier noch ein Ausschnitt aus der Visualisierung des belegten Speichers auf dem Testsystem in Abhängigkeit von der Zeit:




Abbildung 4.6: Ausschnitt aus dem Verlauf der Arbeitsspeichernutzung während der Evaluation

Auf der x-Achse ist das Datum dargestellt. Zwei vertikale Linien der Untergrundlinien ergeben einen Tag Ausführungszeit. Es ist ein charakteristisches Muster für das Laden des Eingabe-Graphen, beginnend mit einem linearen Anstieg, zu erkennen. Die langen horizontalen Linien im Verlauf des Graphen sind die Basic Graph Pattern Evaluierungen. Diese sind im gezeigten Ausschnitt eher unterdurchschnittlich lang. Die meisten anderen Features, außer Basic Graph Pattern, sind wie oben bereits, gezeigt mit der Abtastrate von 5 min. nicht sichtbar, da selbst alle Ausführungen des Features zusammen über alle Queries unter 5 min benötigt haben. Die roten Pfeile zeigen den Zeitpunkt zu dem der Datenerfassungs-Rekord, am Ende jeder Query Ausführung, mit entsprechenden "unique_name" erstellt wurde. Auf diese Weise lassen sich die einzelnen Peaks zu den Wikidata Example Queries zuordnen. Für Queries mit Fehler bei der Übersetzung wurde dies als "Error" in der Grafik erwähnt. Es ist zu sehen, dass der zweite Error, bei der Query mit Hash "3a780", nicht sofort nach der vorherigen Query auftrat. Dies liegt daran, dass für diese Query die Evaluierung in Blazegraph etwas mehr Zeit in Anspruch genommen hat. Alle Queries wurden zunächst auf Blazegraph und dann in Nemo ausgeführt. Am Ende der Query mit dem hohen Peak in der Arbeitsspeichernutzung existiert kein roter Pfeil und kein Datenerfassungs-Rekord. Dies liegt daran, dass das Programm wegen zu hoher Speicherauslastung vorzeitig abgebrochen und neu gestartet wurde. Dennoch kann aufgrund der bekannten Reihenfolge der Queries festgestellt werden, dass es sich bei dieser um die Query "Computer Science and Technology/Return a bubble chart of mediatypes by count of file formats" mit dem unique_name "computer-science-and-2ae07" handelt. Eine naheliegende Vermutung ist, dass der enorme Speicherbedarf durch den in dieser

Query verwendeten Property Path verursacht wird, welcher alle Dinge findet, deren Typ ein File Format oder eine Subklasse von File Format ist. Da in keiner erfolgreichen Query der Speicherbedarf eines Prädikats höher als der für den Eingabe-Graphen ist³ und im Peak der Speicherbedarf andere Queries über das Doppelte übersteigt, ist es sehr wahrscheinlich, dass der hohe Speicherbedarf durch temporären Zwischenergebnisse verursacht wird. Genaue Aussagen sind allerdings generell sehr schwierig, da das manuelle debuggen von Wikidata Queries in Nemo durch die dreistündige Wartezeit beim Importieren der Daten, sehr erschwert wird.

Zusammenfassend ist festzuhalten, dass einige Queries die Grenzen des Speichers oder der akzeptablen Verarbeitungszeit überschreiten. Dies könnte in einer anderen Nemo Version unter Umständen durch folgende Ansätze verbessert werden:

- Optimierung der Import Zeit, z.B. durch ein Feature, welches es erlaubt, Daten einmalig zu importieren und für mehrere Nemo-Programme zu verwenden. Dies würde die Gesamtausführungszeit deutlich reduzieren und das Debuggen deutlich vereinfachen.
- Optimierung der Regel-Körper Evaluierung, z.B. durch stärkere Berücksichtigung von Konstanten. Basic Graph Patterns können häufig durch Einschränken der betrachteten Daten durch konstante IRIs in Prädikat Position effizienter evaluiert werden. Die durchgeführte Evaluierung bietet Evidenz, dass dies in der verwendeten Version von Nemo häufig noch nicht geschieht.
- Optimierung temporärer Zwischenergebnisse, z.B. durch Ausführung von Regeln in kleineren Schritten. Dies könnte in vielen Fällen verhindern, dass ein Datalog-Programm aufgrund des Speicherlimits nicht ausgeführt werden kann.

Es kann in der Evaluierung gezeigt werden, dass in zahlreichen Fällen der Ansatz in dieser Arbeit selbst bis zu über 3 Miliarden Tripels skaliert.

³die Query, welche nicht vom Eingabe-Graphen abhängt, bildet die einzige Ausnahme, da Nemo den Eingabe-Graphen erst lädt, wenn dieser benötigt wird

5 Zusammenfassung und Ausblick

In dieser Arbeit konnte gezeigt werden, wie sich fast alle SPARQL-Query Features zu Nemo übersetzen lassen. Als besonders herausfordernd erwies sich dabei der SPARQL konforme Umgang mit nicht gebundenen Variablen, wie etwa durch ein OPTIONAL in SPARQL. Die Übersetzung wurde konkret implementiert. Um die zahlreichen Features in der gegebenen Zeit implementieren zu können, wurde eine Nemo Template Language entwickelt, welche verallgemeinerte Nemo Regeln mittels Rust-Makros erzeugen kann. Durch eine Evaluation konnte gezeigt werden, dass die Übersetzung in weiten Teilen SPARQL konform ist und für viele Queries bis zu Milliarden von Tripels im Eingabegraphen skaliert.

Die Übersetzung fand grundsätzlich bottom up entlang der SPARQL-Algebra Baumstruktur statt. Dieser Ansatz zeichnete sich durch seine Einfachheit aus, erlaubte jedoch nicht eine vollständig SPARQL konforme Implementierung des Exists filters, da durch diesen Expressions auch von Variablen aus Operationen, welche im SPARQL-Algebra-Baum oberhalb angeordnet sind, abhängen können.

Es wäre interessant, Ansätze zu betrachten, durch welche Zwischenergebnisse nicht nur in übergeordneten Operationen im SPARQL Algebra Baum beachtet werden. Auf diese Weise könnte der Exists filter korrekt implementiert werden. Außerdem ist dadurch ein Effizienzgewinn zu erwarten, da die Größe der Zwischenergebnisse durch die zusätzlichen Einschränkungen reduziert werden kann. Dies ist insbesondere relevant für Property Paths, welche zu großen Zwischenergebnissen neigen.

Eine weitere Optimierung könnte betrachtet werden, mit welcher Regeln aus dem Nemo-Programm entfernt werden, indem diese in andere Regeln direkt eingebettet werden. Ist beispielsweise ein Prädikat p durch die Prädikate u und v definiert, könnte in einer Regel, welche das Prädikat p im Regel- $K\"{o}rper$ hat, dieses in einigen Fällen durch die Prädikate u und v ersetzt werden. Dadurch wird Nemo mehr Freiraum für Optimierungen gegeben. Eine umfangreiche Implementierung dieser Optimierung könnte auch Expressions in Nemo berücksichtigen. Dies kann einen weiteren Geschwindigkeitsgewinn erbringen, da in Nemo typischerweise eine zusammengesetzte Expression effizienter ist als die jeweiligen Teilepressions in einzelnen Regeln.

Eine direkte Anwendung der Übersetzung von SPARQL-Queries nach Nemo könnte auch das Generieren von Teilen einer Test-Suite zum Optimieren von Nemo sein. Beispielsweise bilden die Nemo-Programme der übersetzten Wikidata Beispielqueries, wie in der Evaluation dieser Arbeit beschrieben, zahlreiche realitätsnahe Testfälle mit hoher Komplexität. Dabei ist zu beachten, dass zyklische Abhängigkeiten von Prädikaten mit großer Zyklen Länge in den aus SPARQL-Queries resultierenden Nemo Programmen nicht vorkommen.

Literatur

- [1] Renzo Angles und Claudio Gutierrez. "The expressive power of SPARQL". In: *International Semantic Web Conference*. Springer. 2008, S. 114–129.
- [2] Renzo Angles u. a. "SparqLog: A System for Efficient Evaluation of SPARQL 1.1 Queries via Datalog [Experiment, Analysis and Benchmark]". In: *arXiv preprint arXiv:2307.06119* (2023).
- [3] Stefano Ceri, Georg Gottlob, Letizia Tanca u.a. "What you always wanted to know about Datalog (and never dared to ask)". In: *IEEE transactions on knowledge and data engineering* 1.1 (1989), S. 146–166.
- [4] Alex Ivliev u. a. "Nemo: Your Friendly and Versatile Rule Reasoning Toolkit". In: *Proceedings of the 21st International Conference on Principles of Knowledge Representation and Reasoning (KR 2024)*. Hrsg. von Pierre Marquis, Magdalena Ortiz und Maurice Pagnucco. Proceedings of the International Conference on Principles of Knowledge Representation and Reasoning. IJCAI Organization, Nov. 2024, S. 743–754. DOI: https://doi.org/10.24963/kr.2024/70.
- [5] rdflib 7.1.2. URL: https://rdflib.readthedocs.io/en/stable/ (besucht am 17.01.2025).
- [6] Simon Schenk. "A sparql semantics based on datalog". In: *Annual Conference on Artificial Intelligence*. Springer. 2007, S. 160–174.
- [7] *spargebra Rust*. URL: https://docs.rs/spargebra/latest/spargebra/ (besucht am 22.01.2025).
- [8] SPARQL 1.1 Query Language. URL: https://www.w3.org/TR/sparql11-query/ (besucht am 19.12.2024).
- [9] SPARQL 1.1 Test Suite. URL: https://www.w3.org/2009/sparql/docs/tests/summary.html (besucht am 19.12.2024).
- [10] Martin Voigt. SPARQL2NEMO. URL: https://github.com/eilmiv/SPARQL2NEMO.

Abbildungsverzeichnis

1.1	Ergebnisse für den Graphen	11
2.1 2.2	Transformation von SPARQL-Query zu Nemo-Programm	18
2.3 2.4 2.5 2.6	Prädikate Übersicht der internen Nemo-Repräsentation Übersicht der Binding-Enumeration für Positionen in Prädikaten High-Level Queryevaluierungsablauf SPARQL2Nemo Queryevaluierungsablauf	21 24 25 30 31
3.1 3.2 3.3	Übergang zwischen verschiedenen Variablen	36 72 89
4.1	· ·	101
4.2	Histogramm der Ausführungszeiten der mit Blazegraph ohne Fehler ausgeführten Queries	101
4.3	Durchschnittliche Ausführungszeit in Abhängigkeit der Anzahl, mit welcher der Eingabe Graph im Nemo-Programm verwendet wird	
4.4	Keine Abhängigkeit zwischen Ausführungszeit und Anzahl der Ergebnissen .	
4.5	Histogramm der Ladezeiten des Eingabegraphen	
4.6	Ausschnitt aus dem Verlauf der Arbeitsspeichernutzung während der Evaluation	.106

Anhang

Begriffsverzeichnis

Ergebnis 🔨	Abschnitt 1.5 (S.13)
gebunden 🖍	
Query-Ergebnis 🗥	
Regel-Kopf /	Abschnitt 1.5 (S.13)
Regel-Körper /	Abschnitt 1.5 (S.13)
repräsentiert /	Abschnitt 1.5 (S.13)
steht für 🦯	Abschnitt 1.5 (S.13)
Triple-Graph 🗸	Abschnitt 1.3 (S.11)
UNDEF-Marker [/]	Abschnitt 3.1 (S.35)
<i>zum Tragen </i> Żkommen	Abschnitt 1.5 (S.13)

Abkürzungsverzeichnis

BNode
IRI
RDF Resource Description Framework
SPARQL SPARQL Protocol and RDF Query Language
SQL Structured Query Language
stdin
stdout
URL
w3c